Tuần 01 — Các câu hỏi và Dữ liệu

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Khoa Công nghệ Thông tin (VNU-UET-FIT)

Nguồn và học liệu tham khảo

Bài giảng được **biên soạn mới** cho học phần **UET.MAT1052 — Xác suất thống kê**, dựa trên đề cương chính thức và tham khảo:

- **STAT 20**, University of California, Berkeley;
- Freedman, Pisani & Purves, *Statistics*, 4th ed.;
- Diez, Çetinkaya-Rundel & Barr, *OpenIntro Statistics*, 4th ed.;
- Çetinkaya-Rundel & Hardin, *Introduction to Modern Statistics*, 2nd ed.

Nguồn và giấy phép.
Tài nguyên được tái sử dụng trực tiếp từ nguồn bên ngoài, nếu có, được ghi nguồn và giấy phép tại vị trí tương ứng hoặc trong phần tài liệu tham khảo.

Nội dung chính — Phần 1/5

1. → **Từ câu hỏi đến khẳng định**
2. Từ đối tượng đến biến
3. Từ biến đến khung dữ liệu
4. Cầu nối Python/pandas
5. Tổng hợp và tự kiểm tra

Câu hỏi xuyên suốt: ***Ta có dữ liệu gì, và dữ liệu đó cho phép ta kết luận đến đâu?***

Phần 1

Từ câu hỏi đến khẳng định

Mục tiêu của bài

Sau bài này, bạn cần có khả năng:

- giải thích dữ liệu là kết quả của một **quá trình đo lường và tạo dữ liệu**;
- phân biệt **tóm tắt, tổng quát hóa, khẳng định nhân quả và dự đoán**;
- nhận ra khi dữ liệu chỉ hỗ trợ **mối liên hệ** nhưng câu hỏi lại đòi hỏi kết luận mạnh hơn;
- từ câu hỏi nghiên cứu, xác định **đơn vị, biến và mức chi tiết của mỗi hàng**;
- xác định **biến, giá trị và đơn vị quan sát** trong một bộ dữ liệu;
- phân loại biến theo hệ thống **biến số/phân loại** và các nhóm con;
- đọc cấu trúc cơ bản của một **khung dữ liệu** và phân biệt loại biến thống kê với `dtype`.

W01-Q01 — Một dữ liệu, hai kết luận

Trong một **khảo sát lớp học STAT20**, sinh viên được hỏi về kinh nghiệm viết mã trước khi học môn. Trong số những người đã trả lời, **70% cho biết họ chưa có kinh nghiệm viết mã**.

Giả sử đây là toàn bộ thông tin ta có. Xét hai kết luận:

1. "70% **người đã trả lời khảo sát** chưa có kinh nghiệm viết mã."
2. "70% **sinh viên Berkeley** chưa có kinh nghiệm viết mã."

Câu hỏi: Hai câu khác nhau ở đâu? Câu nào đi xa hơn dữ liệu đã quan sát?

Chuyển thể từ STAT20 tiếng Việt, Chương 1 §1.1.1.

Đáp án W01-Q01

- Câu (1) là **tóm tắt**: chỉ mô tả các đơn vị đã quan sát.
- Câu (2) là **tổng quát hóa**: mở rộng kết luận sang một tập đơn vị rộng hơn.

Điểm mấu chốt: cùng một con số 70% nhưng **phạm vi của khẳng định** khác nhau.

Câu hỏi dùng xuyên suốt khóa học: ***Ta có dữ liệu gì, và dữ liệu đó cho phép ta kết luận đến đâu?***

Từ câu hỏi đến khẳng định: chuỗi suy luận

Một bảng dữ liệu không xuất hiện tự nhiên. Trước khi có bảng, đã có **đối tượng, phép đo và cách thu thập**.

Câu hỏi $\to$ **Đơn vị và biến** $\to$ **Quá trình tạo dữ liệu** $\to$ **Dữ liệu** $\to$ **Phân tích** $\to$ **Khẳng định**

Quá trình tạo dữ liệu bao gồm những quyết định như: lấy ai/cái gì, đo bằng cách nào, đo bao nhiêu lần, có can thiệp hay chỉ quan sát, và có gộp dữ liệu trước khi phân tích hay không.

> *Muốn đánh giá một kết luận, phải đi **ngược chuỗi**: khẳng định này đòi hỏi loại dữ liệu và quá trình tạo dữ liệu nào?*

Bốn loại khẳng định

Loại khẳng định	Mục tiêu cốt lõi
Tóm tắt	Mô tả dữ liệu **đang có**
Tổng quát hóa	Nói về một tập đơn vị **rộng hơn dữ liệu đã quan sát**
Khẳng định nhân quả	Nói rằng **thay đổi một biến làm thay đổi biến khác**
Dự đoán	Đoán **giá trị chưa biết** từ các biến đã biết

Đừng tìm từ khóa. Hãy hỏi: Đối tượng của kết luận là ai/cái gì? Có nói về can thiệp không? Giá trị nào đang chưa biết?

Hệ thống phân loại khẳng định theo STAT20 tiếng Việt, Chương 1 §1.1.1.

Đọc một khẳng định theo hai lớp

Hệ thống bốn loại ở trên là khung chính của bài. Khi gặp một câu về **mối liên hệ giữa hai biến**, nên hỏi thêm hai câu độc lập:

1. **Phạm vi:** câu đang mô tả dữ liệu đã quan sát hay tổng quát hóa ra ngoài dữ liệu?
2. **Vai trò của mối quan hệ:** chỉ mô tả sự đi cùng nhau, dùng để dự đoán, hay tuyên bố một biến làm thay đổi biến kia?

Ví dụ với `temperature` và `latency`:

- "Trong log đã có, nhiệt độ cao đi cùng độ trễ cao hơn" $\rightarrow$ mô tả **mối liên hệ** trong dữ liệu;
- "Biết nhiệt độ, dự đoán độ trễ của lần chạy mới" $\rightarrow$ **dự đoán**;
- "Tăng nhiệt độ sẽ làm độ trễ tăng" $\rightarrow$ **nhân quả**.
  Mối liên hệ không phải là bằng chứng tự động cho nhân quả. *Cùng hai cột, nhưng thiết kế thu thập dữ liệu khác nhau có thể cho phép các mức kết luận khác nhau.*

Năm lầm tưởng cần phá ngay từ Tuần 01

Lầm tưởng	Cách sửa
"Nhiều hàng hơn luôn cho bằng chứng mạnh hơn."	Số hàng không thay thế thiết kế lấy mẫu/đo lường và tính độc lập.
"Cột nhìn như số thì là biến số."	Mã định danh hoặc mức thứ bậc vẫn có thể được lưu bằng số.
"Một hàng luôn là một quan sát độc lập."	Một thiết bị có thể đóng góp hàng nghìn phép đo lặp.
"Mối liên hệ, dự đoán và nhân quả là như nhau."	Chúng trả lời các câu hỏi khác nhau và đòi hỏi bằng chứng khác nhau.
"`dtype` quyết định loại biến thống kê."	`dtype` nói cách lưu; loại biến phụ thuộc ý nghĩa của giá trị.

Tóm tắt và Tổng quát hóa

Tóm tắt

- Phạm vi: các đơn vị **đã quan sát**.
- Có thể bằng số, hình hoặc lời.
- Không tự động nói về quần thể lớn hơn.

Mẫu: "Trong dữ liệu này, ..."

Tổng quát hóa

- Đi từ dữ liệu tới **tập đơn vị rộng hơn**.
- Độ tin cậy phụ thuộc mạnh vào cách thu thập dữ liệu.
- Tuần 09 mới học sâu "mẫu $\rightarrow$ quần thể".

Mẫu: "Trong quần thể ..., ..."

Khẳng định nhân quả và Dự đoán

Khẳng định nhân quả

- Hỏi về **tác động của việc thay đổi/can thiệp**.
- Mạnh hơn việc chỉ thấy hai biến đi cùng nhau.
- Công cụ nhân quả được học sâu ở Tuần 12–13.

Mẫu: "Nếu ta thay đổi X, Y sẽ ..."

Dự đoán

- Mục tiêu là **một giá trị chưa biết**.
- Có thể dự đoán tốt mà không chứng minh nhân quả.
- Mô hình dự đoán được học sâu ở Tuần 14–15.

Mẫu: "Biết X, ta đoán Y của trường hợp mới ..."

W01-Q02 — Phân loại khẳng định

Bốn câu dưới đây minh họa bốn mục tiêu khác nhau của phân tích dữ liệu. **Không giả định thêm** thông tin về cách lấy mẫu hay thiết kế nghiên cứu ngoài những gì câu chữ cho biết.

A. "Trong tập dữ liệu đang có, `species` nhận ba mức Adelie, Chinstrap, Gentoo."
B. "Từ khảo sát lớp, ta kết luận 70% sinh viên Berkeley chưa có kinh nghiệm viết mã."
C. "Dùng thuốc mới làm thay đổi xác suất khỏi bệnh."
D. "Từ các biến đã biết, ta đoán điểm bài kiểm tra ngắn của một sinh viên chưa biết điểm."

Yêu cầu: gán mỗi câu vào một trong bốn loại khẳng định và giải thích bằng **mục tiêu/phạm vi** của câu, không chỉ bằng từ khóa.

Đáp án W01-Q02

- **A — Tóm tắt:** chỉ mô tả tập dữ liệu đang có.
- **B — Tổng quát hóa:** từ người khảo sát sang toàn bộ sinh viên Berkeley.
- **C — Khẳng định nhân quả:** nói việc dùng thuốc **làm thay đổi** kết quả.
- **D — Dự đoán:** mục tiêu là một điểm bài kiểm tra ngắn chưa biết.

Dễ nhầm: dự đoán cũng dùng dữ liệu cũ để nói về điều chưa quan sát, nhưng đích thường là **một giá trị/trường hợp mới**, không phải một đặc trưng của cả quần thể.

W01-CH01 — Tổng quát hóa hay dự đoán?

Một thành phố muốn hiểu tình trạng kết nối Internet của các hộ dân. Hai nhóm phân tích dùng dữ liệu đã thu thập theo hai cách:

- **A:** khảo sát một số hộ rồi ước lượng tỷ lệ **tất cả hộ trong thành phố** có Internet.
- **B:** dùng đặc điểm của các hộ đã biết để đoán **một hộ mới cụ thể** có Internet hay không.

Vì sao A và B không cùng loại khẳng định, dù cả hai đều "dùng dữ liệu đã có để nói về điều chưa quan sát"?

Đáp án W01-CH01

- **A là tổng quát hóa:** mục tiêu là một đặc trưng của **toàn bộ quần thể hộ**.
- **B là dự đoán:** mục tiêu là **giá trị chưa biết của một hộ cụ thể**.

Tiêu chí phân biệt: hỏi kết quả cuối cùng là **đặc trưng của một tập đơn vị rộng hơn** hay **giá trị chưa biết của một đơn vị/trường hợp cụ thể**.

Thời gian ("hiện tại/tương lai") không phải tiêu chí quyết định.

W01-OI01 — Tên thú cưng đăng ký tại Seattle

Thành phố Seattle có **cổng dữ liệu mở** về các thú cưng đã đăng ký. Mỗi bản ghi chứa **tên thú cưng** và **loài** (chó/mèo). OpenIntro dùng dữ liệu này để so sánh độ phổ biến của tên giữa hai loài.

1. Đơn vị quan sát trong dữ liệu gốc là gì?
2. `name` và `species` thuộc loại biến nào?
3. "Trong **dữ liệu đã đăng ký**, một số tên phổ biến hơn ở chó so với mèo" là loại khẳng định nào?
4. "Dữ liệu đăng ký phản ánh **tất cả thú cưng ở Seattle**" đi xa hơn dữ liệu theo cách nào? Nêu một lý do cần thận trọng.

Chuyển thể từ OpenIntro Statistics 4e, Chương 1, Bài 1.35 "Pet names".

Đáp án W01-OI01 — Tên thú cưng ở Seattle

1. Đơn vị quan sát: **một thú cưng đã đăng ký với thành phố Seattle**.
2. `name` và `species` đều là **biến phân loại danh nghĩa** trong ngữ cảnh này: giá trị là nhãn, không phải độ lớn số học và không có thứ tự tự nhiên.
3. Đây là **tóm tắt** vì câu chỉ mô tả các bản ghi đang có.
4. Đây là một **tổng quát hóa**: từ thú cưng **đã đăng ký** sang **tất cả thú cưng đang sống ở Seattle**. Cần thận trọng vì thú cưng không đăng ký không xuất hiện trong dữ liệu; do đó nhóm quan sát có thể không đại diện cho toàn bộ quần thể quan tâm.

Bài học: trước khi mở rộng một kết luận, phải hỏi **ai/cái gì có mặt trong dữ liệu và ai/cái gì bị bỏ ngoài dữ liệu**.

Bài tập từ OI4e — Thời gian thư giãn sau giờ làm

Khảo sát Xã hội Tổng quát (**General Social Survey**) hỏi một **mẫu ngẫu nhiên 1.155 người Mỹ** câu: "Sau một ngày làm việc trung bình, bạn có khoảng bao nhiêu giờ để thư giãn hoặc làm những hoạt động mình yêu thích?" Trung bình trong mẫu là **1,65 giờ**.

W01-OI02 — Chuyển thể từ bài cuối chương

1. Đơn vị quan sát là gì?
2. Biến được đo là gì và thuộc loại nào?
3. "Trong 1.155 người trả lời, trung bình là 1,65 giờ" là loại khẳng định nào?
4. "Người Mỹ trung bình có 1,65 giờ thư giãn sau ngày làm việc" là loại khẳng định nào?

Chuyển thể từ OpenIntro Statistics 4e, Chương 1, Bài tập 1.17.

Đáp án W01-OI02 — Thời gian thư giãn

1. Đơn vị quan sát: **một người trả lời khảo sát**.
2. Biến: số giờ thư giãn sau ngày làm việc; **biến số liên tục** về mặt khái niệm.
3. Câu về 1.155 người đã trả lời là **tóm tắt**.
4. Câu về toàn bộ người Mỹ là **tổng quát hóa**.

Việc mẫu được chọn ngẫu nhiên làm tổng quát hóa có cơ sở hơn, nhưng **định lượng độ bất định của tổng quát hóa** thuộc Tuần 09.

Nội dung chính — Phần 2/5

1. Từ câu hỏi đến khẳng định
2. → **Từ đối tượng đến biến**
3. Từ biến đến khung dữ liệu
4. Cầu nối Python/pandas
5. Tổng hợp và tự kiểm tra

Câu hỏi xuyên suốt: ***Ta có dữ liệu gì, và dữ liệu đó cho phép ta kết luận đến đâu?***

Phần 2

Từ đối tượng đến biến

Từ khẳng định đến dữ liệu: biến, giá trị, đơn vị

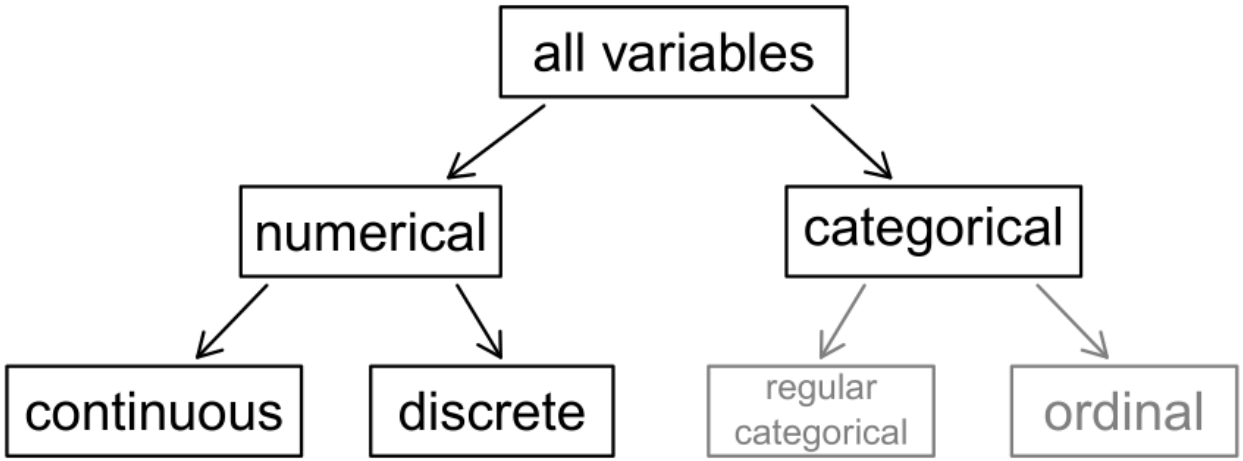
- **Biến:** đặc tính của một đối tượng/đơn vị quan sát có thể đo và ghi lại.
- **Giá trị:** kết quả cụ thể của biến trên một quan sát.
- **Đơn vị quan sát:** lớp đối tượng mà trên đó các biến được quan sát.

Ví dụ: với dữ liệu từng sinh viên, `nganh_hoc` là biến; `"Khoa học máy tính"` có thể là một giá trị; **một sinh viên** là đơn vị quan sát.

> *Một hàng có thể đại diện cho **sinh viên–môn học–học kỳ**, không nhất thiết chỉ "một sinh viên".*

Theo STAT20 tiếng Việt, Chương 1 §§1.2–1.2.2.

Một hệ thống phân loại biến



Trong khóa học này dùng hệ thống phân loại:

biến số → liên tục / rời rạc
biến phân loại → danh nghĩa / thứ bậc

Hình minh họa từ OpenIntro; hệ thống phân loại và thuật ngữ chính theo STAT20 tiếng Việt.

Biến số: độ lớn phải có ý nghĩa

Biến số nhận giá trị số và **độ lớn của con số có ý nghĩa định lượng**.

- **Liên tục:** giá trị nằm trên một khoảng của trục số thực, ví dụ nhiệt độ, chiều dài.
- **Rời rạc:** nhận các giá trị tách rời, thường là số đếm, ví dụ số người trong hộ.

Cảnh báo: "được lưu bằng số nguyên" không đồng nghĩa "biến số rời rạc".

- `ma_sinh_vien = 24001234` vẫn có thể chỉ là nhãn định danh.
- mức đánh giá 1–5 có thể là các mức có thứ tự.

Biến phân loại: số chưa chắc là số

Biến phân loại nhận các **mức** (categories) làm giá trị.

- **Danh nghĩa:** các mức không có thứ tự tự nhiên, ví dụ `species`, `state`.
- **Thứ bậc:** các mức có thứ tự tự nhiên, ví dụ mức học vấn hoặc mức đồng ý.

Một biến mã hóa bằng `1,2,3,4,5` vẫn có thể là **thứ bậc** nếu các con số chỉ là mã mức.

W01-CH02 — 1,2,3,4,5 nói được gì?

Bạn nhận một tệp dữ liệu chỉ có một cột `x`. Tài liệu mô tả biến bị thiếu; ta chỉ thấy các giá trị trong cột là `1, 2, 3, 4, 5`. Phần mềm báo cột này được lưu dưới dạng số nguyên.

1. Ta có đủ thông tin để kết luận `x` là **biến số rời rạc** không?
2. Hãy đưa ra **hai diễn giải thực tế** có cùng cách biểu diễn `1–5` nhưng khác loại biến thống kê.
3. Nếu phần mềm báo `dtype = int64`, kết luận có thay đổi không?

Đáp án W01-CH02

Không đủ thông tin. Cách biểu diễn bằng số không quyết định loại biến thống kê.

Hai diễn giải:

- 1–5 = **số lỗi** trong một bài kiểm thử → biến số rời rạc;
- 1–5 = mức "rất không đồng ý" → "rất đồng ý" → biến phân loại thứ bậc.

`dtype = int64` chỉ nói cách phần mềm lưu dữ liệu; nó không cho biết phép toán số học có ý nghĩa thống kê hay các số chỉ là mã mức.

Tại sao loại biến quan trọng?

Loại biến định hướng:

1. **cách ghi nhận**: đơn vị đo hay các mức phân loại;
2. **cách trực quan hóa**: loại biểu đồ phù hợp;
3. **cách tóm tắt**: phép toán nào có ý nghĩa;
4. **cách mô hình hóa**: vai trò và cách mã hóa biến.

Tuần 01 chỉ xây hệ thống phân loại. Tuần 02–04 sẽ dùng hệ thống này để lựa chọn cách tóm tắt và mô hình.

Nội dung chính — Phần 3/5

1. Từ câu hỏi đến khẳng định
2. Từ đối tượng đến biến
3. → **Từ biến đến khung dữ liệu**
4. Cầu nối Python/pandas
5. Tổng hợp và tự kiểm tra

Câu hỏi xuyên suốt: ***Ta có dữ liệu gì, và dữ liệu đó cho phép ta kết luận đến đâu?***

Phần 3

Từ biến đến khung dữ liệu

Khung dữ liệu: một cấu trúc cho dữ liệu

Khung dữ liệu liên kết:

- **hàng quan sát**;
- **cột biến**;
- **ô giá trị quan sát được** của một biến trên một quan sát.

Một trong những câu hỏi đầu tiên khi gặp một bảng mới:
Mỗi hàng đại diện cho điều gì?

Nếu không trả lời được câu này, ta chưa hiểu cấu trúc dữ liệu.

STAT20 tiếng Việt, Chương 1 §1.2.2; IMS 2e, Chương 1 §1.2.1.

Ví dụ từ dữ liệu mở OI4e — email50

OpenIntro cung cấp bộ dữ liệu email50, gồm **50 thư điện tử** và **21 biến** mô tả đặc điểm của từng thư. Mục tiêu ở đây chưa phải xây bộ lọc thư rác; ta chỉ luyện đọc **đơn vị quan sát và loại biến**.

Biến	Ý nghĩa
spam	thư điện tử có phải thư rác hay không
cc	số người nhận bản sao
image	số ảnh đính kèm
number	không có số / số nhỏ / số lớn

W01-EX01

1. Đơn vị quan sát là gì?
2. Phân loại bốn biến trên.
3. Vì sao không thể phân loại number chỉ dựa vào tên cột?

Đáp án W01-EX01 — `email50`

1. Đơn vị quan sát: **một thư điện tử**.
2. Phân loại:
   - `spam`: phân loại danh nghĩa (nhị phân);
   - `cc`: biến số rời rạc;
   - `image`: biến số rời rạc;
   - `number`: phân loại thứ bậc vì các mức "không có / nhỏ / lớn" có thứ tự tự nhiên.
3. Tên `number` gây nhiễu: nó không lưu một độ lớn số trực tiếp mà lưu **nhóm kích thước của số xuất hiện trong thư điện tử**.

Ví dụ từ dữ liệu mở IMS2e — `loan50`

Introduction to Modern Statistics 2e giới thiệu `loan50`: một mẫu **50 khoản vay** từ Lending Club. Mỗi dòng lưu các đặc điểm của một khoản vay, như lãi suất, kỳ hạn, xếp hạng tín dụng và bang của người vay.

term	grade	state	interest_rate
60	B	NJ	10.90
36	B	CA	9.92
36	E	SC	26.30

W01-EX02

1. Đơn vị quan sát là gì?
2. Phân loại `term`, `grade`, `state`, `interest_rate`.
3. Với mỗi biến, giải thích **ý nghĩa thực tế của giá trị** thay vì suy luận chỉ từ cách nó được lưu.

Đáp án W01-EX02 — `loan50`

1. Đơn vị quan sát: **một khoản vay**.
2. Phân loại:
   - `term`: biến số rời rạc — số tháng của kỳ hạn vay;
   - `grade`: biến phân loại **thứ bậc** — các mức A–G có thứ tự về chất lượng khoản vay;
   - `state`: biến phân loại **danh nghĩa** — mã bang chỉ là nhãn;
   - `interest_rate`: biến số, thường được xử lý như **liên tục** trong mô hình thống kê.
3. Điểm quyết định là **ý nghĩa của giá trị**: `60` ở `term` là 60 tháng; `B` ở `grade` là một mức có thứ tự; `CA` ở `state` là nhãn; `10.90` ở `interest_rate` là độ lớn định lượng.

Điểm mấu chốt: cùng một hàng có thể chứa đồng thời nhiều loại biến.

Bài tập từ IMS2e — Các phim Marvel

W01-IMS01 — Các phim Marvel

Một khung dữ liệu trong IMS2e mô tả **23 phim thuộc Vũ trụ Điện ảnh Marvel (MCU) trong Infinity Saga**. Mỗi phim có các thông tin về tiêu đề, thời lượng, ngày phát hành và doanh thu:

`Title`, `Hrs`, `Mins`, `Release Date`, `Opening Wknd US`, `US`, `World`.

1. Khung dữ liệu có bao nhiêu quan sát?
2. Có bao nhiêu biến?
3. Đơn vị quan sát là gì?
4. `Title` là biến hay giá trị? Một tên phim cụ thể đóng vai trò gì?

Introduction to Modern Statistics 2e, Chương 1 §1.4, Bài tập 1.

Đáp án W01-IMS01 — Các phim Marvel

1. **23 quan sát**.
2. **7 biến**.
3. Đơn vị quan sát: **một phim MCU**.
4. `Title` là **biến**; một tiêu đề như "Iron Man" là **một giá trị** của biến đó.

Nhắc lại: số hàng và số cột chỉ có ý nghĩa khi ta hiểu mỗi hàng/cột đại diện cho gì.

Bài tập từ IMS2e — Bộ dữ liệu Palmer penguins

W01-IMS02 — Bộ dữ liệu Palmer penguins

Bộ dữ liệu Palmer penguins ghi nhận **344 chim cánh cụt** tại ba đảo Torgersen, Biscoe và Dream. Với mỗi cá thể, dữ liệu lưu nhóm biến nhận dạng/phân loại và các phép đo hình thái:

- `island`, `species`, `sex`;
- `bill_length_mm`, `bill_depth_mm`, `flipper_length_mm`, `body_mass_g`.

1. Có bao nhiêu biến số? Chúng nên được xem là liên tục hay rời rạc?
2. Có bao nhiêu biến phân loại? Danh nghĩa hay thứ bậc?
3. Một hàng của khung dữ liệu đại diện cho gì?

Introduction to Modern Statistics 2e, Chương 1 §1.4, Bài tập 11; Gorman và cộng sự (2014).

Đáp án W01-IMS02 — Palmer penguins

- **4 biến số:** `bill_length_mm`, `bill_depth_mm`, `flipper_length_mm`, `body_mass_g`; đều được xem là **liên tục**.
- **3 biến phân loại:** `island`, `species`, `sex`; đều **danh nghĩa** trong ngữ cảnh này.
- Một hàng đại diện cho **một chim cánh cụt được đo**.

Bài này minh họa rõ: **đơn vị quan sát không phải là một biến**; nó là lớp đối tượng mà các biến được ghi nhận trên đó.

W01-CH03 — Hai mức độ chi tiết trong cùng một bảng

Phòng đào tạo xuất một bảng lịch sử đăng ký học. Mỗi dòng ghi **một sinh viên học một học phần trong một học kỳ**:

sinh_vien	hoc_phan	hoc_ky	diem
An	MAT1052	2026A	8.5
An	PHY1001	2026A	7.5
Bình	MAT1052	2026A	9.0

1. Đơn vị quan sát có phải "một sinh viên" không?
2. Nếu thêm `birth_year` của sinh viên vào bảng, điều gì xảy ra?
3. Nếu muốn lưu **một dòng cho mỗi sinh viên**, cấu trúc dữ liệu phải thay đổi thế nào?

Đáp án W01-CH03

1. Không. Một hàng là **một lượt sinh viên–môn học–học kỳ**.
2. `birth_year` là đặc tính ở mức **sinh viên**, nên giá trị sẽ lặp lại trên nhiều dòng của cùng sinh viên.
3. Muốn một hàng/một sinh viên, cần một bảng khác ở **mức chi tiết sinh viên**; dữ liệu điểm theo môn không thể giữ nguyên dạng nhiều môn trong một ô nếu vẫn muốn mỗi ô chứa một giá trị của một biến.

Ý chính: cùng số hàng/cột không đảm bảo cùng **đơn vị quan sát**.

W01-R01 — Từ câu hỏi suy ra cấu trúc hàng

Một phòng thí nghiệm theo dõi **40 bộ pin**. Mỗi bộ pin có **3 cảm biến nhiệt độ**; mỗi cảm biến ghi một giá trị sau mỗi 10 phút trong 7 ngày.

Hai câu hỏi nghiên cứu:

A. Khi một cảm biến ghi nhiệt độ tăng đột ngột, hai cảm biến còn lại của **cùng bộ pin** thay đổi thế nào trong cùng thời điểm?
B. Bộ pin nào có **nhiệt độ trung bình cả tuần** cao nhất?

1. Với câu A, một hàng nên đại diện cho `bộ pin`, `cảm biến`, `bộ pin × cảm biến`, hay `bộ pin × cảm biến × thời điểm`?
2. Với câu B, có thể tạo một bảng một hàng/một bộ pin không?
3. Vì sao không có một cấu trúc hàng duy nhất tối ưu cho mọi câu hỏi?

Đáp án W01-R01 — Từ câu hỏi suy ra cấu trúc hàng

1. Với A, mức chi tiết tự nhiên là **bộ pin × cảm biến × thời điểm**. Muốn so sánh các cảm biến trong cùng bộ pin tại cùng thời điểm, phải giữ cả ba chiều này.
2. Với B, **có thể** tạo bảng một hàng/một bộ pin sau khi tính nhiệt độ trung bình tuần của từng bộ pin.
3. Cấu trúc dữ liệu phải phục vụ **câu hỏi**. Nếu gộp sớm thành một hàng/một bộ pin, ta mất dao động theo thời gian và khác biệt giữa các cảm biến; ngược lại, giữ dữ liệu quá chi tiết khi chỉ cần trung bình thiết bị có thể làm câu hỏi đơn giản trở nên rườm rà.
   Nguyên tắc: *chọn đơn vị quan sát và mức chi tiết sao cho mỗi hàng giữ đúng thông tin cần để trả lời câu hỏi.*

W01-R02 — Dữ liệu và câu hỏi không khớp nhau

Một trường thu thập **dữ liệu quan sát** của 600 sinh viên. Mỗi hàng là một sinh viên, gồm:

`study_hours_week`, `GPA`, `major`, `year`.

Không có ai được gán ngẫu nhiên số giờ học; `study_hours_week` là số giờ sinh viên tự báo cáo.

Nhóm phân tích hỏi:

> *"Nếu cùng một sinh viên học thêm **1 giờ mỗi tuần**, GPA của bạn ấy sẽ tăng bao nhiêu?"*

1. Bảng hiện có có thể mô tả điều gì về `study_hours_week` và `GPA`?
2. Vì sao câu hỏi trên mạnh hơn điều bảng quan sát trực tiếp?
3. Nêu ít nhất hai yếu tố có thể làm mối liên hệ quan sát được khác với tác động của việc học thêm một giờ.

Đáp án W01-R02 — Dữ liệu và câu hỏi không khớp nhau

1. Bảng có thể mô tả **mối liên hệ quan sát được** giữa giờ học và GPA trong các sinh viên đã ghi nhận; nếu mẫu có thiết kế phù hợp, có thể cân nhắc tổng quát hóa mối liên hệ đó.
2. Câu hỏi "nếu cùng một sinh viên học thêm 1 giờ" là **câu hỏi nhân quả**: nó hỏi về kết quả dưới một can thiệp. Dữ liệu hiện có chỉ cho biết các sinh viên vốn học nhiều/ít khác nhau thế nào.
3. Ví dụ: năng lực nền, mức độ khó của học phần, khối lượng môn học, động cơ học tập, sức khỏe, việc làm thêm, hoặc sai số tự báo cáo. Các yếu tố này có thể liên quan đồng thời tới giờ học và GPA. *Thấy một mối liên hệ không đủ để thay thế cho câu hỏi "điều gì sẽ xảy ra nếu ta can thiệp?".*

W01-R03 — Gộp dữ liệu làm thay đổi câu hỏi

Một trung tâm dữ liệu ghi **độ trễ mạng mỗi phút** cho từng máy chủ. Bảng gốc có dạng `server_id` × `time` với biến `latency_ms`. Sau đó, nhóm vận hành tạo bảng mới chỉ còn **một hàng cho mỗi máy chủ**, chứa `mean_latency_ms`.

1. Thông tin nào biến mất khi chuyển từ bảng gốc sang bảng đã gộp?
2. "Độ trễ trung bình" trong hai bảng có cùng ý nghĩa không?
3. Nếu một số máy chủ có 1.000 phép đo còn máy khác chỉ có 100 phép đo, trung bình của các **trung bình máy chủ** có nhất thiết bằng trung bình của **tất cả phép đo gốc** không?

Đáp án W01-R03 — Gộp dữ liệu làm thay đổi câu hỏi

1. Ta mất vị trí theo thời gian, các đỉnh bất thường, dao động trong từng máy chủ và số phép đo chi tiết tại mỗi thời điểm.
2. Không hoàn toàn. Ở bảng gốc, trung bình có thể được hiểu là trung bình trên **các phép đo theo thời gian**. Ở bảng đã gộp, mỗi hàng là **một máy chủ**, nên một phép trung bình tiếp theo có thể coi mỗi máy chủ là một đơn vị.
3. **Không nhất thiết.** Nếu số phép đo trên mỗi máy chủ khác nhau, "trung bình của các trung bình" cho mỗi máy chủ trọng số bằng nhau, còn trung bình của mọi phép đo gốc cho máy chủ có nhiều phép đo trọng số lớn hơn.

Kết luận: gộp dữ liệu không chỉ làm bảng ngắn hơn; nó có thể thay đổi **đơn vị quan sát, thông tin còn lại và ý nghĩa của đại lượng được tóm tắt**.

Nội dung chính — Phần 4/5

1. Từ câu hỏi đến khẳng định
2. Từ đối tượng đến biến
3. Từ biến đến khung dữ liệu
4. → **Cầu nối Python/pandas**
5. Tổng hợp và tự kiểm tra

Câu hỏi xuyên suốt: ***Ta có dữ liệu gì, và dữ liệu đó cho phép ta kết luận đến đâu?***

Phần 4

Cầu nối Python/pandas

Python/pandas: cầu nối để đọc cấu trúc dữ liệu

Trong bài này, Python chỉ giúp **nhìn cấu trúc dữ liệu**:

- một biến trong bảng `pandas.Series`;
- nhiều biến cùng đơn vị quan sát `pandas.DataFrame`.

Bốn thao tác đọc cấu trúc thường gặp:

```
loan_demo.head()
loan_demo.shape
loan_demo.columns
loan_demo.dtypes
```

Ý nghĩa cần nhớ, không phải cú pháp:

- `head()` → xem vài hàng đầu;
- `shape` → số hàng × số cột;
- `columns` → tên các biến;
- `dtypes` → kiểu lưu trữ mà phần mềm đang dùng.

Đầu ra đã chuẩn bị — một lát cắt của `loan50`

Với lát cắt **3 hàng × 4 biến**, đầu ra được chuẩn bị sẵn:

```
shape: (3, 4)
columns: term, grade, state, interest_rate

term              int64
grade            object
state            object
interest_rate   float64
```

Đọc theo ngữ nghĩa của dữ liệu:

- một hàng = **một khoản vay**;
- `term` = số tháng → biến số rời rạc;
- `grade` = mức A–G có thứ tự → biến phân loại thứ bậc;
- `state` = mã bang → biến phân loại danh nghĩa;
- `interest_rate` = lãi suất → biến số.

W01-PY01 — Đọc shape, tên biến và dtype

Giả sử một bảng quản lý sinh viên đã được đọc vào pandas. Ta chỉ xem đầu ra, không cần viết code:

```
shape: (1200, 6)
columns: ma_sinh_vien, muc_danh_gia, nganh_hoc, ...

ma_sinh_vien   int64
muc_danh_gia   int64
nganh_hoc      object
```

1. `shape: (1200, 6)` nói điều gì về cấu trúc bảng?
2. Vì `ma_sinh_vien` có `dtype = int64`, có nên xem đây là biến số rời rạc không?
3. `muc_danh_gia` cũng là `int64`. Cần biết thêm điều gì để phân loại nó?
4. Tại sao `dtype` hữu ích cho phần mềm nhưng không đủ để quyết định loại biến thống kê?

Đáp án W01-PY01 — Đọc đầu ra pandas

1. Bảng có **1.200 hàng và 6 cột**; con số này chưa cho biết 1.200 hàng có phải 1.200 đơn vị độc lập hay không.
2. **Không.** `ma_sinh_vien` là mã định danh, nên về thống kê là biến phân loại **danh nghĩa** dù được lưu bằng số nguyên.
3. Cần biết **ý nghĩa của thang**. Nếu 1–5 chỉ thứ tự mức đánh giá, đó là biến phân loại **thứ bậc**; nếu là số lỗi đếm được, nó có thể là biến số rời rạc.
4. `dtype` giúp máy tính chọn cách lưu và thao tác dữ liệu; loại biến thống kê phụ thuộc vào **ngữ nghĩa đo lường** và phép toán nào có ý nghĩa trên giá trị.

Không có thử thách nào trong bài này đòi hỏi nhớ cú pháp pandas.

Nội dung chính — Phần 5/5

1. Từ câu hỏi đến khẳng định
2. Từ đối tượng đến biến
3. Từ biến đến khung dữ liệu
4. Cầu nối Python/pandas
5. → **Tổng hợp và tự kiểm tra**
   Câu hỏi xuyên suốt: ***Ta có dữ liệu gì, và dữ liệu đó cho phép ta kết luận đến đâu?***

Phần 5

Tổng hợp và tự kiểm tra

Tổng hợp và tự kiểm tra

W01-D01 — Tự thiết kế một khung dữ liệu tối thiểu

Một nhóm nghiên cứu muốn tìm hiểu liệu **nhiệt độ phòng** có liên quan đến **thời gian hoàn thành một tác vụ kỹ thuật** hay không. Mỗi người có thể làm nhiều tác vụ, và cùng một người có thể được đo ở nhiều phiên.

Không có sẵn sơ đồ bảng. Hãy đề xuất một khung dữ liệu tối thiểu:

1. Mỗi hàng nên là đơn vị gì?
2. Biến kết quả là gì?
3. Biến giải thích chính là gì?
4. Cần cột nào để nhận biết phép đo lặp?
5. Đề xuất ít nhất **hai biến phụ trợ** có thể giúp diễn giải dữ liệu.
6. Nếu mục tiêu đổi từ "có liên hệ hay không?" sang "tăng nhiệt độ **làm** thời gian hoàn thành thay đổi bao nhiêu?", chỉ thay bảng dữ liệu có đủ không?

Đáp án W01-D01 — Một thiết kế hợp lý

Một phương án:

- **một hàng:** một `người × phiên × tác_vụ`;
- **kết quả:** `completion_time_s`;
- **giải thích chính:** `room_temperature_c`;
- **nhận biết lặp:** `participant_id`, `session_id`, `task_id`;
- **biến phụ trợ:** độ khó tác vụ, thứ tự tác vụ, mức kinh nghiệm, thời gian trong ngày, độ ồn, thiết bị sử dụng, ...

Mục (6): **không đủ.** Chuyển từ câu hỏi về mối liên hệ sang câu hỏi nhân quả đòi hỏi thay đổi **quá trình tạo dữ liệu/thiết kế nghiên cứu**, chẳng hạn một cơ chế can thiệp và so sánh phù hợp; không thể chỉ đổi tên cột hay định dạng bảng.

W01-CH04 — Cùng tên cột, khác đơn vị quan sát

Hai nhóm đều có ba cột:

`id`, `temperature_c`, `latency_ms`.

Hãy **xây dựng hai nghiên cứu khác nhau** sao cho:

- tên cột hoàn toàn giống nhau;
- `id` mang ý nghĩa khác nhau;
- một hàng đại diện cho loại đơn vị khác nhau;
- "trung bình `latency_ms`" vì thế có cách diễn giải khác nhau.

Không được đổi tên cột.

Đáp án W01-CH04 — Cùng tên cột, khác ý nghĩa

Ví dụ 1 — **máy chủ:**

- `id` = mã máy chủ;
- mỗi hàng = một máy chủ sau một bài kiểm thử;
- `temperature_c` = nhiệt độ trung bình khi kiểm thử;
- `latency_ms` = độ trễ trung bình của máy chủ.

Ví dụ 2 — **gói tin:**

- `id` = mã gói tin;
- mỗi hàng = một gói tin;
- `temperature_c` = nhiệt độ máy chủ tại thời điểm gói tin được xử lý;
- `latency_ms` = độ trễ của chính gói tin đó.

Do đó, trung bình `latency_ms` ở nghiên cứu 1 là trung bình **giữa máy chủ/bài kiểm thử**, còn ở nghiên cứu 2 là trung bình **giữa các gói tin**. Tên cột không đủ để xác định ý nghĩa thống kê.

W01-CH05 — Nấc thang khẳng định từ cùng một bộ dữ liệu

Giả sử ta có log máy chủ với `temperature_c`, `latency_ms`, `load`, `server_id`, `time`. Hãy viết bốn câu, mỗi câu có một mục tiêu khác nhau:

1. một **tóm tắt** dữ liệu đã có;
2. một câu về **mối liên hệ** giữa nhiệt độ và độ trễ;
3. một **dự đoán** cho một lần chạy mới;
4. một **khẳng định nhân quả** về việc thay đổi nhiệt độ.

Sau đó, nêu **bằng chứng bổ sung** cần có trước khi tin vào các câu mạnh hơn.

Đáp án W01-CH05 — Bốn kiểu câu từ cùng dữ liệu

Một bộ câu hợp lệ:

1. **Tóm tắt:** "Trong log tuần này, độ trễ trung vị là ... ms."
2. **Mối liên hệ:** "Trong log tuần này, các thời điểm nhiệt độ cao thường đi cùng độ trễ cao hơn."
3. **Dự đoán:** "Từ nhiệt độ và tải hiện tại, ta dự đoán độ trễ của lần chạy kế tiếp."
4. **Nhân quả:** "Nếu chủ động tăng nhiệt độ máy chủ thêm 5°C, độ trễ sẽ tăng."

Điểm khác nhau không nằm ở tên cột, mà ở **mục tiêu của câu** và **bằng chứng mà câu đòi hỏi**.

Đáp án W01-CH05 — Bằng chứng cần tăng theo độ mạnh

- **Tóm tắt:** cần phép đo và xử lý dữ liệu đáng tin cậy.
- **Mối liên hệ:** cần mô tả/so sánh quan hệ; nếu muốn nói rộng hơn dữ liệu đã quan sát, cần cơ chế lấy dữ liệu phù hợp.
- **Dự đoán:** cần kiểm tra dự đoán trên các trường hợp mới có liên quan.
- **Nhân quả:** cần một thiết kế cho phép tách tác động của nhiệt độ khỏi các yếu tố khác.

Lưu ý quan trọng: câu về "mối liên hệ" có thể vẫn là **tóm tắt** hoặc **tổng quát hóa** tùy phạm vi. "Mối liên hệ" vì thế không phải một nhãn thứ năm thay thế hệ thống bốn loại của STAT20.

> *Cùng một bảng có thể gợi ra nhiều câu hỏi, nhưng* ***không phải mọi câu hỏi đều được bảng đó trả lời với cùng mức độ tin cậy****.*

W01-CH06 — Phản ví dụ: 100.000 hàng có nghĩa là (n=100{,}000)?

Một công ty theo dõi **100 thiết bị**. Mỗi thiết bị được đo **1.000 lần**, nên bảng có đúng **100.000 hàng**.

Hãy bác bỏ phát biểu:

> *"Bảng có 100.000 hàng, vì vậy kích thước mẫu thống kê chắc chắn là (n=100{,}000)."*

Yêu cầu:

1. chỉ ra đơn vị nào đang được đo lặp;
2. nêu ít nhất một câu hỏi nghiên cứu mà 100 thiết bị, không phải 100.000 hàng, mới là số đơn vị độc lập quan trọng;
3. giải thích vì sao số hàng vẫn là thông tin hữu ích nhưng không đồng nghĩa với lượng thông tin độc lập.

Đáp án W01-CH06 — Số hàng số đơn vị độc lập

- Mỗi **thiết bị** xuất hiện 1.000 lần, nên các hàng trong cùng thiết bị là **phép đo lặp**, thường có liên hệ với nhau.
- Nếu câu hỏi là "thiết bị thuộc loại A có nhiệt độ trung bình khác thiết bị loại B không?", đơn vị so sánh cốt lõi là **thiết bị**; có 100 cụm thiết bị, không phải 100.000 thiết bị độc lập.
- 100.000 vẫn là **số phép đo** và có thể rất hữu ích để mô tả biến thiên theo thời gian. Nhưng nó không tự động tạo ra 100.000 mẩu thông tin độc lập về khác biệt giữa thiết bị.
  Trong phân tích nâng cao, có thể đồng thời nói `n_obs = 100000` *và* `n_devices = 100`. *Vì thế, trước khi dùng ký hiệu (n), phải nói rõ* ***đơn vị nào đang được đếm***.

Tình huống tổng hợp — `email50` và câu hỏi lọc thư rác

Một nhóm muốn dùng các đặc điểm thư điện tử để hỗ trợ **phân loại thư rác**. Họ bắt đầu với `email50`: mỗi hàng là một thư điện tử; các cột gồm `spam`, `cc`, `image`, `attach`, `number`, …

W01-CASE01

1. "Trong 50 thư hiện có, có bao nhiêu thư rác?" là loại khẳng định nào?
2. Đoán `spam` cho một thư mới là loại khẳng định nào?
3. "Tăng số dấu chấm than sẽ **làm** thư trở thành thư rác" là loại nào? `email50` có đủ để chứng minh không?
4. Đơn vị quan sát là gì?
5. Chọn ba biến và phân loại chúng.
6. Vì sao các cột trong pandas phải mô tả **cùng 50 thư theo cùng chỉ mục (`index`)**?

Đáp án W01-CASE01

1. Đếm/tỷ lệ thư rác **trong 50 thư điện tử** $\rightarrow$ **tóm tắt**.
2. Dự đoán nhãn của thư điện tử mới $\rightarrow$ **dự đoán**.
3. "Tăng dấu chấm than làm..." $\rightarrow$ **khẳng định nhân quả**; dữ liệu quan sát đơn thuần không đủ chứng minh.
4. Đơn vị quan sát: **một thư điện tử**.
5. Ví dụ:
   - `spam`: phân loại danh nghĩa;
   - `cc`: số rời rạc;
   - `number`: phân loại thứ bậc.
6. Nếu các cột không cùng đơn vị/chỉ mục, một hàng sẽ ghép giá trị của **các thư điện tử khác nhau**, phá hỏng ý nghĩa của khung dữ liệu.

Bản đồ khái niệm Tuần 01

câu hỏi

↓

đơn vị + biến cần đo

↓

quá trình tạo dữ liệu

↓

khung dữ liệu và mức chi tiết của hàng

↓

phân tích

↓

khẳng định hợp lệ

Bốn phân biệt cần giữ:

1. **tóm tắt tổng quát hóa**;
2. **mối liên hệ dự đoán nhân quả**;
3. **số hàng số đơn vị độc lập** trong mọi bài toán;

W01-Q05 — Câu hỏi cuối buổi

Một bạn mới nhận một bảng dữ liệu và đưa ra hai nhận xét:

1. "Cột được lưu bằng kiểu số nguyên nên đó là biến số."
2. "Mỗi hàng luôn là một người."

W01-Q05

- Hãy sửa từng phát biểu để nó trở nên đúng.
- Sau đó trả lời: **Khi mở một bộ dữ liệu mới, bốn câu hỏi đầu tiên bạn nên hỏi là gì?**

Đáp án W01-Q05

1. **Sai vì:** kiểu số nguyên chỉ là cách phần mềm lưu dữ liệu. Muốn biết biến số hay phân loại phải hiểu **ý nghĩa của giá trị**.
2. **Sai vì:** mỗi hàng là một **quan sát**, nhưng đơn vị quan sát có thể là người, thư điện tử, khoản vay, quốc gia–năm, sinh viên–môn học–học kỳ, ...

Bốn câu hỏi nên hỏi trước:

1. **Mỗi hàng đại diện cho gì?**
2. **Mỗi cột đo/ghi nhận điều gì?**
3. **Dữ liệu được tạo ra bằng cách nào?**
4. **Ta muốn dùng dữ liệu để đưa ra loại khẳng định nào?**

Nguồn học liệu chính

- **STAT20 tiếng Việt:** nguồn chính cho hệ thống phân loại khẳng định, phân loại biến và khung dữ liệu.
- **OpenIntro Statistics 4e:** `email50`; bài tên thú cưng đăng ký tại Seattle; bài thời gian thư giãn; hình minh họa phân loại biến.
- **Introduction to Modern Statistics 2e:** `loan50`; bài các phim Marvel; bài Palmer penguins.
- **Đề cương UET.MAT1052:** xác định phạm vi học thuật bắt buộc của Tuần 01.

Những điều cần nhớ sau Tuần 01

1. **Bắt đầu từ câu hỏi, không bắt đầu từ bảng.** Câu hỏi quyết định đơn vị, biến và mức chi tiết cần giữ.
2. Dữ liệu là sản phẩm của một **quá trình tạo dữ liệu**: ai/cái gì được đo, đo thế nào, lặp bao nhiêu lần, có can thiệp hay chỉ quan sát.
3. **Sức mạnh của khẳng định phụ thuộc vào thiết kế**, không chỉ vào số hàng: tóm tắt tổng quát hóa; mối liên hệ dự đoán nhân quả.
4. Một hàng là một **quan sát trong bảng**, nhưng không nhất thiết là một **đơn vị độc lập**. Phép đo lặp cần được nhận diện.
5. Gộp dữ liệu có thể làm mất thông tin và thay đổi **đơn vị quan sát** hoặc ý nghĩa của đại lượng được tóm tắt.
6. **Kiểu lưu trữ không quyết định loại biến thống kê.** Một cột số vẫn có thể là mã hoặc thang thứ bậc.

   Bốn câu hỏi đầu tiên: ***Mỗi hàng là gì? Mỗi cột là gì? Dữ liệu được tạo ra thế nào? Ta muốn đưa ra khẳng định nào?***

Chuẩn bị cho Tuần 02 — Tóm tắt dữ liệu

Tuần 02 sẽ chuyển từ câu hỏi **"dữ liệu gồm những gì?"** sang **"dữ liệu trông như thế nào?"**.

Trước buổi học, hãy ôn lại:

- biến phân loại và biến số;
- hàng, cột, đơn vị quan sát và phép đo lặp;
- sự khác nhau giữa **tóm tắt dữ liệu đang có** và **tổng quát hóa ra ngoài dữ liệu**;
- vì sao một cách gộp dữ liệu có thể làm mất thông tin cần cho câu hỏi.

Khi đọc trước, hãy tự hỏi:

*Với từng loại biến, ta nên dùng **bảng, đại lượng tóm tắt hay biểu đồ** nào để mô tả dữ liệu một cách trung thực?*