Tuần 04 — Tóm tắt dữ liệu (3/3)

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Khoa Công nghệ Thông tin (VNU-UET-FIT)

Nguồn và giấy phép

- UC Berkeley STAT20 — bản dịch tiếng Việt dùng cho cấu trúc khái niệm và thuật ngữ.
- OpenIntro Statistics, 4th ed., Chapters 8–9 — khung ví dụ, công thức và hình minh họa.
- Introduction to Modern Statistics, 2nd ed., Chapters 7–8 — phần dư, bình phương tối thiểu, biến giải thích phân loại và hồi quy nhiều biến.

Nội dung chuyển thể từ OpenIntro được sử dụng theo giấy phép tương ứng của nguồn; các hình giữ nguyên đường dẫn project-relative từ slide nguồn.

Nội dung chính

1. **Từ biểu đồ phân tán đến hệ số tương quan**
2. **Mô hình hồi quy tuyến tính đơn giản**
3. **Phần dư và bình phương tối thiểu**
4. **Hồi quy tuyến tính đa biến**
5. **Diễn giải hệ số và các bẫy thường gặp**
6. **Thực hành và bài toán tổng hợp**

Phần 1

Từ biểu đồ phân tán đến hệ số tương quan

Mục tiêu học tập (1/2)

Sau bài này, bạn có thể:

- mô tả quan hệ giữa hai biến số bằng biểu đồ phân tán và hệ số tương quan;
- giải thích đúng ý nghĩa và giới hạn của hệ số tương quan Pearson;
- viết, đọc và diễn giải mô hình hồi quy tuyến tính đơn giản;
- hiểu giá trị khớp, phần dư và tiêu chuẩn bình phương tối thiểu;
- suy ra các **điều kiện chuẩn** và liên hệ chúng với b_0, b_1.

Mục tiêu học tập (2/2)

Sau bài này, bạn cũng có thể:

- chẩn đoán phi tuyến, điểm ảnh hưởng mạnh và cấu trúc nhóm;
- giải thích hệ số nhiều biến theo nghĩa **giữ các biến còn lại cố định**;
- xử lý biến phân loại bằng biến chỉ báo và mức tham chiếu;
- dùng Python để tính tương quan, khớp mô hình và đọc hệ số/phần dư;
- phân biệt **mô tả mối liên hệ**, **kết luận nhân quả** và **đánh giá dự đoán**.

Nội dung chính

1. **Từ biểu đồ phân tán đến hệ số tương quan** ← phần hiện tại
2. Mô hình hồi quy tuyến tính đơn giản
3. Phần dư và bình phương tối thiểu
4. Hồi quy tuyến tính đa biến
5. Diễn giải hệ số và các bẫy thường gặp
6. Thực hành và bài toán tổng hợp

Phần 2

Từ biểu đồ phân tán đến hệ số tương quan

Hai biến số có thể liên hệ như thế nào?

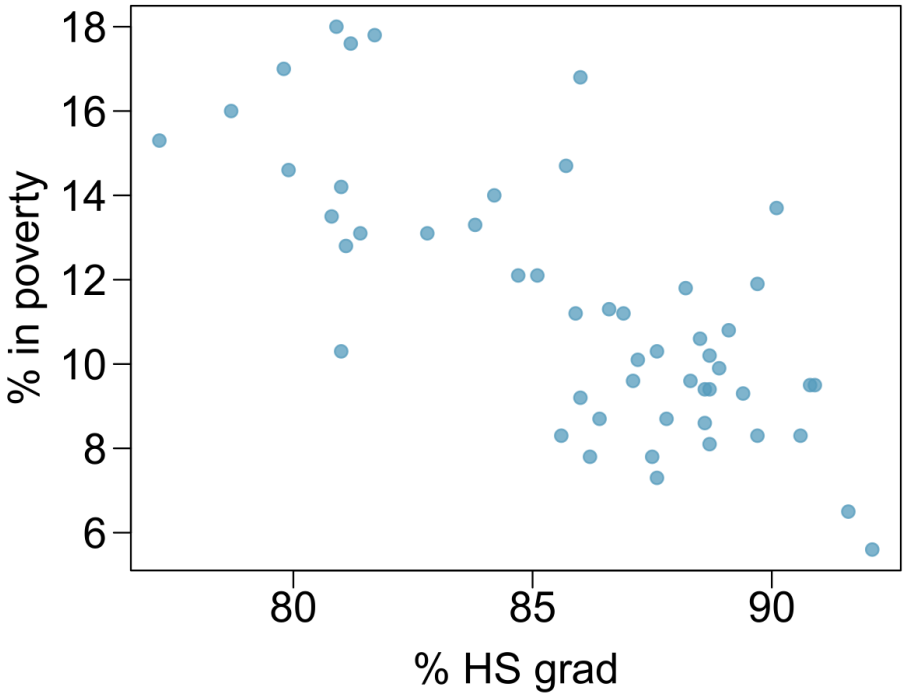
Khi xem một biểu đồ phân tán, hãy đọc theo bốn câu hỏi:

1. **Hướng:** dương hay âm?
2. **Dạng:** tuyến tính hay phi tuyến?
3. **Độ mạnh:** các điểm bám sát một cấu trúc đến mức nào?
4. **Quan sát bất thường:** có điểm nào khác hẳn đám mây dữ liệu?
   Một con số tóm tắt chỉ có ý nghĩa sau khi ta đã nhìn cấu trúc dữ liệu.

Tỷ lệ nghèo đói và tốt nghiệp trung học

Dữ liệu gồm **50 bang của Hoa Kỳ và Đặc khu Columbia**:

- `Graduates`: tỷ lệ tốt nghiệp trung học;
- `Poverty`: tỷ lệ sống dưới ngưỡng nghèo.



- Biến đáp ứng: `Poverty`; biến giải thích: `Graduates`.
- Mối liên hệ có **hướng âm, khá tuyến tính**, với độ mạnh **vừa đến**

W04-Q01 Mức độ 1 — Ước lượng hệ số tương quan

Từ biểu đồ trên, giá trị nào hợp lý nhất cho hệ số tương quan giữa `Poverty` và `Graduates`?

- (a) 0.60
- (b) -0.75
- (c) -0.10
- (d) 0.02
- (e) -1.50

Giải thích lựa chọn bằng **hướng**, **độ mạnh** và **miền giá trị hợp lệ** của hệ số tương quan.

Đáp án — W04-Q01

(b) -0.75.

- Dấu âm phù hợp với xu hướng đi xuống.
- Độ lớn khoảng 0.75 phù hợp với một mối liên hệ tuyến tính khá mạnh nhưng không hoàn hảo.
- Hệ số tương quan luôn nằm trong $[-1, 1]$, nên -1.50 là bất khả thi.

Trong STAT20, giá trị tính từ dữ liệu là xấp xỉ $r = -0.747$.

Hệ số tương quan Pearson

Với hai biến số x và y, hệ số tương quan mẫu là

$$r = \frac{1}{n-1} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right).$$

Cách đọc công thức:

- mỗi biến được **chuẩn hóa** về đơn vị độ lệch chuẩn;
- hai độ lệch cùng dấu đóng góp dương;
- hai độ lệch trái dấu đóng góp âm;
- tổng các tích chuẩn hóa đo mức độ các điểm cùng đi theo một **xu hướng tuyến tính**.

Những gì r nói được — và không nói được

- $-1 \le r \le 1$.
- $r > 0$: mối liên hệ tuyến tính dương.
- $r < 0$: mối liên hệ tuyến tính âm.
- $|r|$ càng gần 1: các điểm càng gần một đường thẳng.
- r **không có đơn vị**.
- $r = 0$ chỉ có nghĩa là **không có mối liên hệ tuyến tính theo thước đo này**.
  Không được rút gọn thành "$r = 0$ nghĩa là hai biến không liên hệ".

W04-EX01 Mức độ 2 — Đổi đơn vị có làm đổi tương quan?

Giả sử thay x bởi

$$x' = a + bx.$$

Hãy dự đoán $r(x', y)$ so với $r(x, y)$ trong ba trường hợp:

1. chỉ cộng hằng số: $b = 1$;
2. đổi đơn vị bằng hệ số dương: $b > 0$;
3. đảo chiều thang đo: $b < 0$.

Không cần tính lại công thức từ đầu; hãy lập luận từ phép chuẩn hóa.

Đáp án — W04-EX01

- Cộng hằng số không đổi tương quan: $r(x + a, y) = r(x, y)$.
- Nhân bởi số dương không đổi tương quan: $r(bx, y) = r(x, y)$ nếu $b > 0$.
- Nhân bởi số âm đổi dấu tương quan: $r(bx, y) = -r(x, y)$ nếu $b < 0$.

Lý do: chuẩn hóa loại bỏ thay đổi vị trí và độ lớn của thang đo; riêng phép nhân âm đảo dấu mọi độ lệch chuẩn hóa của x.

W04-CH01 Mức độ 3 — Tự xây phản ví dụ cho "$r = 0$"

Chứng minh hoặc bác bỏ:

Nếu $r = 0$, biết x không cung cấp thông tin có cấu trúc nào về y.

1. Hãy **tự xây một bộ dữ liệu nhỏ** có quan hệ xác định mạnh giữa x và y nhưng tương quan bằng 0 hoặc rất gần 0.
2. Sau đó kiểm tra một cấu hình đối xứng điển hình:

$$x = (-2, -1, 0, 1, 2), \qquad y = (4, 1, 0, 1, 4).$$

Gợi ý: thử một quan hệ phi tuyến đối xứng quanh $x = 0$.

Lời giải — W04-CH01

Khẳng định **sai**.

Ở đây $y = x^2$: biết x xác định chính xác y, nhưng mối liên hệ là **phi tuyến và đối xứng**.

Vì $\bar{x} = 0$ và $\sum x_i y_i = \sum x_i^3 = 0$, hiệp phương sai bằng 0, do đó $r = 0$.

Kết luận đúng là:

> $r = 0$ *không cho thấy mối liên hệ* ***tuyến tính****; nó không loại trừ một cấu trúc phi tuyến mạnh.*

W04-EX02 Mức độ 2 — Một điểm có thể đổi cả r lẫn đường khớp

Dữ liệu minh họa. Năm điểm đầu có

$$x = (1, 2, 3, 4, 5), \quad y = (1.2, 1.8, 3.1, 3.9, 5.1).$$

Với 5 điểm này:

$$r \approx 0.995, \qquad \hat{y} \approx 0.05 + 0.99x.$$

Thêm điểm $(10, 0)$. Không dùng phần mềm trước khi dự đoán:

1. dấu của tương quan và hệ số góc có thể đổi không?
2. điểm mới có **đòn bẩy** cao không?
3. một đường hồi quy duy nhất sau khi thêm điểm có còn mô tả tốt 5 điểm ban đầu không?

Đáp án — W04-EX02

Sau khi thêm $(10, 0)$:

$$r \approx -0.259, \qquad \hat{y} \approx 3.149 - 0.152x.$$

- Cả dấu của r lẫn hệ số góc đều đảo từ dương sang âm.
- Điểm mới nằm rất xa trung tâm theo trục x, nên có đòn bẩy cao và ảnh hưởng mạnh đến đường khớp.
- Đường mới mô tả kém xu hướng gần tuyến tính dương của 5 điểm đầu.

Bài học: luôn xem biểu đồ phân tán và so sánh mô hình **có/không có** điểm ảnh hưởng mạnh trước khi tin một tóm tắt tuyến tính.

Nội dung chính

1. Từ biểu đồ phân tán đến hệ số tương quan
2. **Mô hình hồi quy tuyến tính đơn giản** ← phần hiện tại
3. Phần dư và bình phương tối thiểu
4. Hồi quy tuyến tính đa biến
5. Diễn giải hệ số và các bẫy thường gặp
6. Thực hành và bài toán tổng hợp

Phần 3

Mô hình hồi quy tuyến tính đơn giản

Một đường thẳng để tóm tắt dữ liệu

Mô hình tuyến tính đơn giản có dạng

$$\hat{y} = b_0 + b_1 x.$$

Trong đó:

- $\hat{y}$: giá trị khớp của biến đáp ứng;
- b_0: hệ số chặn;
- b_1: hệ số góc;
- x: biến giải thích.

Hai con số b_0, b_1 nén một xu hướng hai biến thành một đường thẳng.

Ví dụ: mô hình nghèo đói–tốt nghiệp

OpenIntro cho mô hình xấp xỉ

$$\widehat{Poverty} = 64.68 - 0.62\, Graduates.$$

Diễn giải hệ số góc:

> *Với mỗi **1 điểm phần trăm** tăng của tỷ lệ tốt nghiệp trung học, tỷ lệ nghèo đói khớp bởi mô hình thấp hơn trung bình khoảng **0.62 điểm phần trăm**.*

Đây là mô tả mối liên hệ trong dữ liệu — chưa phải kết luận nhân quả.

W04-Q02 Mức độ 1 — Tính một giá trị khớp

Theo mô hình

$$\widehat{Poverty} = 64.68 - 0.62\,Graduates,$$

một bang có `Graduates = 85.1` được khớp với tỷ lệ nghèo đói khoảng bao nhiêu?

Sau khi tính, hãy nói rõ đó là **giá trị quan sát** hay **giá trị khớp**.

Đáp án — W04-Q02

$$\widehat{Poverty} = 64.68 - 0.62(85.1) \approx 11.92.$$

Đây là **giá trị khớp** từ mô hình, không phải tỷ lệ nghèo đói quan sát thực tế của bang đó.

Hệ số góc phụ thuộc đơn vị, tương quan thì không

Nếu đổi `Graduates` từ "điểm phần trăm" sang "tỷ lệ từ 0 đến 1":

- các giá trị x nhỏ đi 100 lần;
- hệ số góc phải lớn lên 100 lần để biểu diễn cùng một đường thẳng;
- nhưng r không đổi.
  Độ lớn của hệ số góc không thể được dùng như độ mạnh mối liên hệ nếu bỏ qua đơn vị.

Hệ số chặn có luôn đáng diễn giải?

Trong mô hình

$$\widehat{Poverty} = 64.68 - 0.62\, Graduates,$$

$b_0 = 64.68$ tương ứng với `Graduates = 0`.

Nhưng dữ liệu không có bang nào gần 0% tốt nghiệp trung học.

Vì vậy:

- hệ số chặn cần thiết về đại số;
- nhưng diễn giải thực tế của nó **không đáng tin và không hữu ích** trong ngữ cảnh này.

W04-EX03 Mức độ 2 — Có nên diễn giải hệ số chặn?

Một sinh viên nói:

> *"Nếu một bang có 0% dân số tốt nghiệp trung học, mô hình chứng minh tỷ lệ nghèo đói sẽ là 64.68%."*

Hãy chỉ ra **hai lỗi** trong câu này.

Đáp án — W04-EX03

Có ít nhất hai lỗi:

1. `Graduates = 0` nằm rất xa phạm vi dữ liệu, nên đây là **ngoại suy**.
2. Mô hình mô tả một mối liên hệ; từ đó không thể nói "chứng minh" một giá trị thực tế hoặc tác động nhân quả.

Diễn giải an toàn hơn: 64.68 là vị trí đường khớp cắt trục y, nhưng không có ý nghĩa thực tiễn đáng tin trong dữ liệu này.

Nội dung chính

1. Từ biểu đồ phân tán đến hệ số tương quan
2. Mô hình hồi quy tuyến tính đơn giản
3. **Phần dư và bình phương tối thiểu** ← phần hiện tại
4. Hồi quy tuyến tính đa biến
5. Diễn giải hệ số và các bẫy thường gặp
6. Thực hành và bài toán tổng hợp

Phần 4

Phần dư và bình phương tối thiểu

Phần dư: dữ liệu còn lại sau mô hình

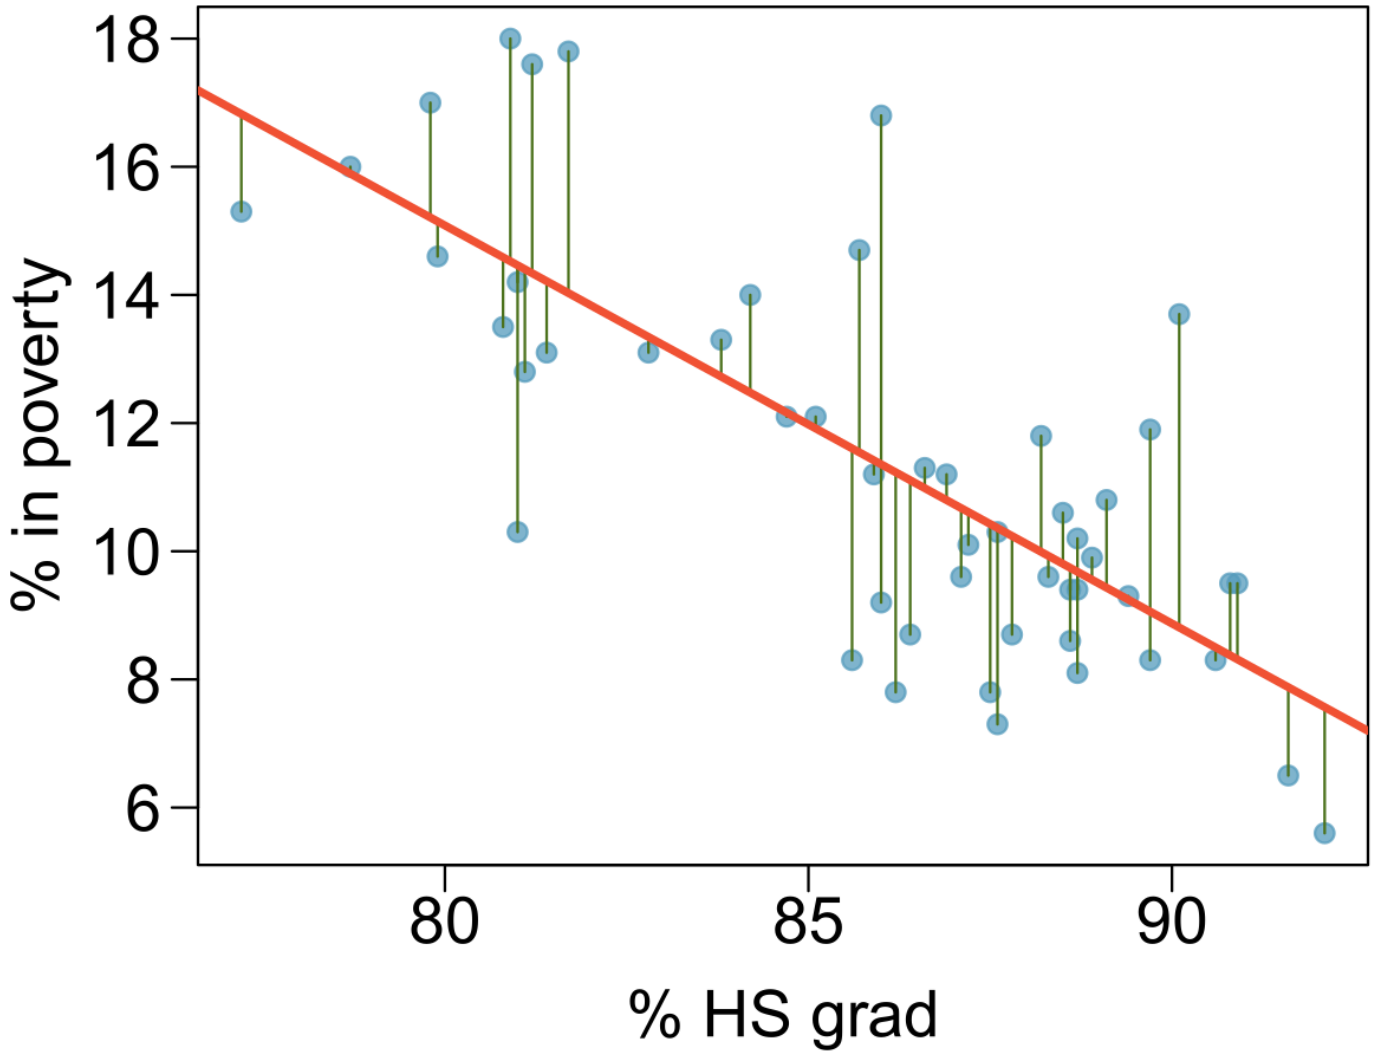
$$\text{Dữ liệu} = \text{Giá trị khớp} + \text{Phần dư}.$$

Với quan sát thứ i:

$$e_i = y_i - \hat{y}_i.$$

- $e_i > 0$: điểm nằm **trên** đường hồi quy;
- $e_i < 0$: điểm nằm **dưới** đường hồi quy;
- $|e_i|$ càng lớn: mô hình khớp quan sát đó càng kém.

Hình học của phần dư



Khoảng cách thẳng đứng từ một điểm đến đường khớp chính là phần dư

W04-WP01 Mức độ 2 — Tính và diễn giải phần dư

Trong dữ liệu nguồn, Rhode Island có

$$Graduates = 81, \qquad Poverty = 10.3.$$

Mô hình là

$$\widehat{Poverty} = 64.68 - 0.62\,Graduates.$$

1. Tính $\hat{y}$.
2. Tính phần dư e.
3. Diễn giải dấu và độ lớn của phần dư bằng ngữ cảnh.

Lời giải — W04-WP01

$$\hat{y} = 64.68 - 0.62(81) = 14.46.$$

$$e = y - \hat{y} = 10.3 - 14.46 = -4.16.$$

Diễn giải:

*Tỷ lệ nghèo đói quan sát của Rhode Island thấp hơn giá trị khớp từ mô hình khoảng **4.16 điểm phần trăm**.*

Dấu âm không có nghĩa là "sai số âm 4.16%"; đơn vị là **điểm phần trăm của biến đáp ứng**.

Từ "một hằng số tốt nhất" đến hồi quy

Trước khi tìm đường thẳng tốt nhất, xét bài toán đơn giản hơn:

Chọn một hằng số a để đại diện cho tất cả y_i. Hằng số nào làm tổng bình phương sai số nhỏ nhất?

$$S(a) = \sum_{i=1}^{n} (y_i - a)^2.$$

Suy ra — trung bình tối thiểu hóa sai số bình phương

$$\frac{dS}{da} = -2\sum_{i=1}^{n}(y_i - a).$$

Điều kiện cực tiểu:

$$\sum_{i=1}^{n}(y_i - a) = 0 \quad \Longrightarrow \quad na = \sum_{i=1}^{n} y_i.$$

Do đó

$$\boxed{a = \bar{y}}.$$

*Trung bình mẫu là **mô hình hằng số** tối ưu theo tiêu chuẩn tổng bình phương sai số.*

Từ mô hình hằng số đến mô hình đường thẳng

Mô hình hằng số:

$$\hat{y} = a.$$

Mô hình tuyến tính:

$$\hat{y} = b_0 + b_1 x.$$

Thay vì chỉ chọn một số, ta chọn hai số b_0, b_1 để giảm

$$SSE = \sum_{i=1}^{n} \left[y_i - (b_0 + b_1 x_i) \right]^2.$$

Đó là **phương pháp bình phương tối thiểu**.

Vì sao bình phương phần dư?

Hai tiêu chuẩn tự nhiên:

$$\sum |e_i| \qquad \text{và} \qquad \sum e_i^2.$$

Bình phương tối thiểu:

- phạt mạnh hơn các phần dư lớn;
- có cấu trúc đại số thuận tiện;
- được hỗ trợ rộng rãi trong phần mềm thống kê;
- tạo nền tảng cho nhiều kết quả hồi quy sau này.

Tuần này ta dùng nó như một **tiêu chuẩn khớp mô tả**.

Bình phương tối thiểu: hai điều kiện chuẩn

Đặt

$$S(a,b) = \sum_{i=1}^{n} (y_i - a - bx_i)^2, \qquad e_i = y_i - a - bx_i.$$

Tại điểm cực tiểu, hai đạo hàm riêng bằng 0:

$$\frac{\partial S}{\partial a} = -2\sum e_i = 0, \qquad \frac{\partial S}{\partial b} = -2\sum x_i e_i = 0.$$

Do đó:

$$\boxed{\sum e_i = 0}, \qquad \boxed{\sum x_i e_i = 0}.$$

Diễn giải: phần dư cân bằng quanh 0 và không còn xu hướng tuyến tính

Từ điều kiện chuẩn đến b_0, b_1

Từ $\sum e_i = 0$:

$$\bar{y} = b_0 + b_1 \bar{x} \quad \Longrightarrow \quad \boxed{b_0 = \bar{y} - b_1 \bar{x}}.$$

Thế vào điều kiện $\sum x_i e_i = 0$ và gom theo độ lệch quanh trung bình:

$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}.$$

Dùng định nghĩa hiệp phương sai và độ lệch chuẩn:

$$\boxed{b_1 = r \frac{s_y}{s_x}}.$$

Do đó đường khớp đi qua $(\bar{x}, \bar{y})$ và dấu của b_1 luôn cùng dấu với r.

W04-WP02 Mức độ 2 — Suy ra đường hồi quy từ thống kê tóm tắt

Với dữ liệu nghèo đói–tốt nghiệp, OpenIntro cho:

$$\bar{x} = 86.01, \quad s_x = 3.73,$$
$$\bar{y} = 11.35, \quad s_y = 3.10, \quad r = -0.75.$$

1. Tính b_1.
2. Tính b_0.
3. Kiểm tra dấu của b_1 có phù hợp với r không.

Lời giải — W04-WP02

$$b_1 = r\frac{s_y}{s_x} = -0.75\frac{3.10}{3.73} \approx -0.62.$$

$$b_0 = \bar{y} - b_1\bar{x} = 11.35 - (-0.62)(86.01) \approx 64.68.$$

Vậy

$$\widehat{Poverty} = 64.68 - 0.62\,Graduates.$$

Dấu hệ số góc luôn cùng dấu với r vì $s_x, s_y > 0$.

Ngoại suy: đường thẳng không có "giấy phép" vô hạn

Một mô hình tuyến tính chỉ được khớp trên phạm vi dữ liệu đã quan sát.

Dùng nó rất xa ngoài phạm vi đó đòi hỏi một giả định mạnh:
cấu trúc gần tuyến tính sẽ tiếp tục đúng ở vùng chưa có dữ liệu.

Đó thường là một giả định không thể kiểm tra bằng chính dữ liệu hiện có.

W04-EX04 Mức độ 2 — Ngoại suy có đáng tin?

Mô hình nghèo đói–tốt nghiệp được xây từ các bang có tỷ lệ tốt nghiệp quanh vùng quan sát thực tế.

Một người dùng mô hình để "ước lượng" `Poverty` khi `Graduates = 20`.

Hãy đánh giá phép tính này theo hai lớp:

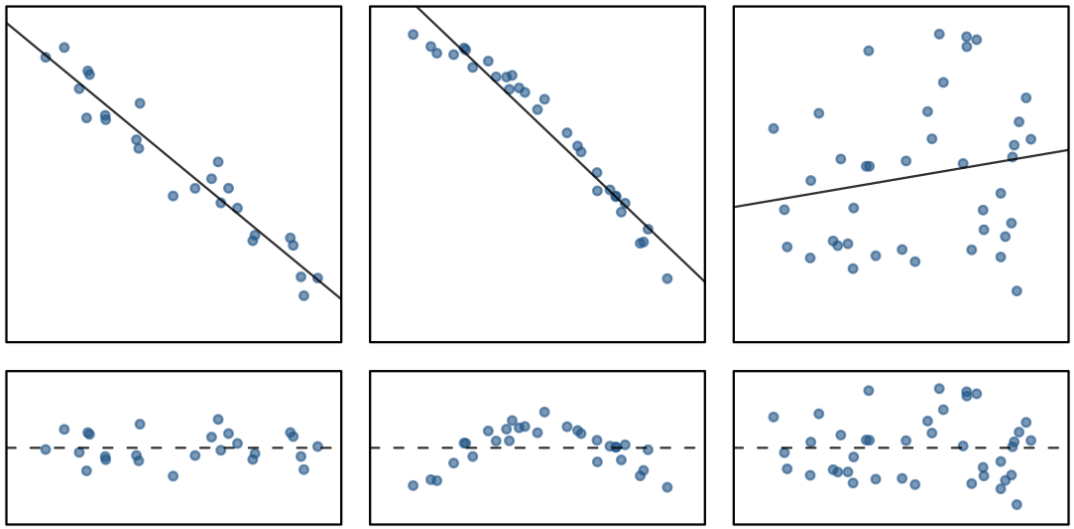
1. **đại số:** có tính được không?
2. **thống kê:** có đáng tin không?

Đáp án — W04-EX04

- **Đại số:** có thể thay $x = 20$ vào phương trình.
- **Thống kê:** kết quả rất đáng nghi vì đây là ngoại suy xa khỏi đám mây dữ liệu.

Một con số do phương trình trả về không đồng nghĩa với một ước lượng có cơ sở dữ liệu tốt.

Biểu đồ phần dư giúp phát hiện mô hình bỏ sót cấu trúc

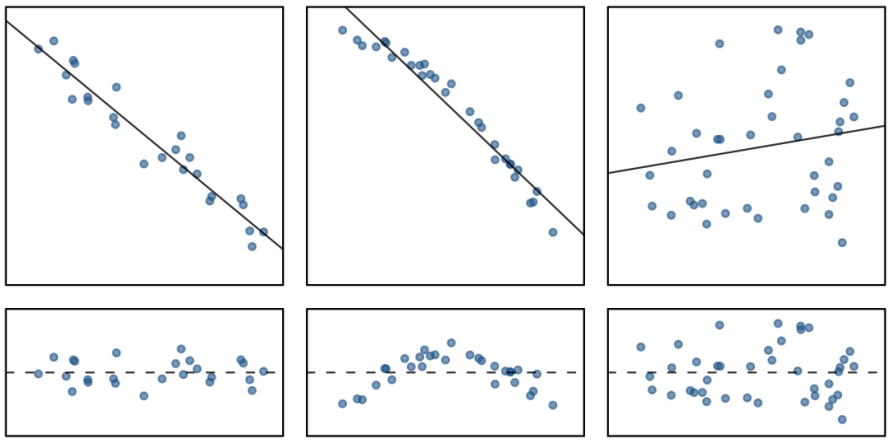


Nếu phần dư còn một hình dạng hệ thống theo x, đường thẳng chưa tóm tắt hết cấu trúc.

Tuần 04 chỉ dùng biểu đồ phần dư như một **công cụ chẩn đoán mô tả**, không phát triển suy luận hồi quy.

W04-CH04 Mức độ 3 — Chẩn đoán từ biểu đồ phần dư

Một mô hình tuyến tính phù hợp nên để phần dư rải quanh 0 mà **không còn cấu trúc có hệ thống**.



Hãy chẩn đoán:

1. đường cong rõ rệt $\rightarrow$ giả định nào về dạng quan hệ đang thất bại?
2. dạng "phễu" $\rightarrow$ mô hình bỏ sót điều gì về độ biến thiên?
3. đám mây ngẫu nhiên quanh 0 có đủ để kết luận nhân quả không?

Lời giải — W04-CH04

1. Đường cong có hệ thống cho thấy **dạng tuyến tính** chưa tóm tắt hết quan hệ; cần xem xét cấu trúc phi tuyến.
2. Dạng "phễu" cho thấy độ biến thiên của Y quanh đường khớp thay đổi theo x; một mức độ phân tán cố định là mô tả kém.
3. Không. Biểu đồ phần dư chỉ chẩn đoán chất lượng của **tóm tắt tuyến tính**, không cung cấp thiết kế nhân quả.

Biểu đồ phần dư tốt không chứng minh mô hình "đúng"; nó chỉ cho thấy chưa thấy một số kiểu thất bại rõ ràng.

Nội dung chính

1. Từ biểu đồ phân tán đến hệ số tương quan
2. Mô hình hồi quy tuyến tính đơn giản
3. Phần dư và bình phương tối thiểu
4. **Hồi quy tuyến tính đa biến** ← phần hiện tại
5. Diễn giải hệ số và các bẫy thường gặp
6. Thực hành và bài toán tổng hợp

Phần 5

Hồi quy tuyến tính đa biến

Từ một biến giải thích đến nhiều biến

Hồi quy tuyến tính đa biến mở rộng mô hình thành

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \cdots + b_p x_p.$$

Mỗi hệ số trả lời một câu hỏi **có điều kiện trên các biến đang có trong mô hình**.

Đọc b_j: khi x_j tăng 1 đơn vị, giá trị khớp của y thay đổi bao nhiêu, ***giữ các biến giải thích khác cố định****?*

Cùng một tiêu chuẩn bình phương tối thiểu

Trong hồi quy nhiều biến, các hệ số vẫn được chọn để tối thiểu hóa

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Với

$$\hat{y}_i = b_0 + b_1 x_{i1} + \cdots + b_p x_{ip}.$$

Ý tưởng cốt lõi không đổi; chỉ có không gian mô hình trở nên nhiều chiều hơn.

Một biến giải thích phân loại: biến chỉ báo

Nếu `cover` có hai mức:

$$D = \begin{cases} 0, & \text{bìa cứng (mức tham chiếu),} \\ 1, & \text{bìa mềm.} \end{cases}$$

Mô hình

$$\widehat{weight} = 197.96 + 0.72\, volume - 184.05 D.$$

là một mô hình có:

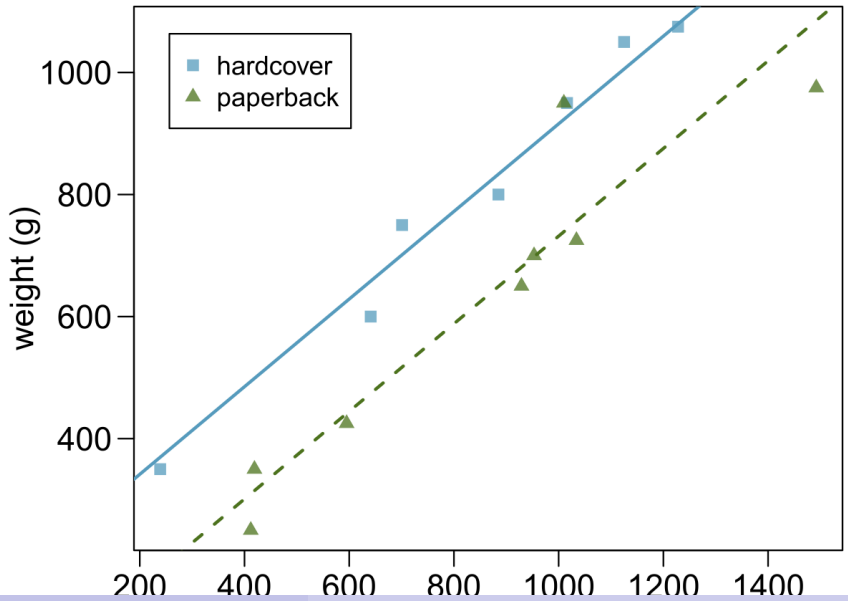
- biến đáp ứng số: `weight`;
- biến giải thích số: `volume`;
- biến giải thích phân loại hai mức: `cover`.

Hai đường song song từ một mô hình

Hai mức của biến chỉ báo cho hai đường:

$$D = 0 \text{ (bìa cứng)}: \quad \widehat{weight} = 197.96 + 0.72\, volume,$$
$$D = 1 \text{ (bìa mềm)}: \quad \widehat{weight} = 13.91 + 0.72\, volume.$$

Không có tương tác nên hai nhóm có **cùng hệ số góc** và khác **hệ số chặn**.



W04-Q04 Mức độ 1 — Mức tham chiếu là gì?

Trong

$$\widehat{weight} = 197.96 + 0.72\, volume - 184.05 D,$$

với $D = 1$ cho bìa mềm, mức tham chiếu của `cover` là gì?

Giải thích bằng cách đặt $D = 0$.

Đáp án — W04-Q04

Mức tham chiếu là **bìa cứng**.

Khi $D = 0$, hạng tử của `cover` biến mất và mô hình trở thành đường dành cho sách bìa cứng:

$$\widehat{weight} = 197.96 + 0.72\, volume.$$

W04-WP03 Mức độ 2 — Diễn giải ba hệ số

Với

$$\widehat{weight} = 197.96 + 0.72\,volume - 184.05D,$$

hãy diễn giải:

1. hệ số `volume`;
2. hệ số `cover`;
3. hệ số chặn.

Đơn vị: `weight` tính bằng gram, `volume` tính bằng cm^3.

Lời giải — W04-WP03

1. `volume`: giữ loại bìa cố định, sách lớn hơn 1 cm^3 được mô hình khớp nặng hơn trung bình khoảng **0.72 g**.
2. `cover`: giữ thể tích cố định, sách bìa mềm được mô hình khớp nhẹ hơn sách bìa cứng khoảng **184.05 g**.
3. **Hệ số chặn:** khối lượng khớp cho sách bìa cứng có thể tích 0 cm^3; đại lượng này không có ý nghĩa thực tế hợp lý.

W04-EX05 Mức độ 2 — Giá trị khớp cho sách bìa mềm

Một cuốn sách bìa mềm có `volume = 600` cm^3.

Dùng mô hình

$$\widehat{weight} = 197.96 + 0.72\,volume - 184.05D$$

để tính khối lượng khớp.

Đáp án — W04-EX05

Với bìa mềm, $D = 1$:

$$\widehat{weight} = 197.96 + 0.72(600) - 184.05 = 445.91 \text{ g}.$$

Đây là **giá trị khớp của mô hình**, không phải cân nặng chắc chắn của cuốn sách.

Ba biến số: ví dụ nhà hàng Zagat

STAT20 xét dữ liệu đánh giá nhà hàng, với:

- `price`: giá trung bình một bữa ăn;
- `food`: điểm chất lượng đồ ăn;
- `decor`: điểm trang trí.

Mô hình trong nguồn:

$$\widehat{price} = -24.5 + 1.64\, food + 1.88\, decor.$$

Đây là ví dụ đúng cấu trúc **ba biến số**: một biến đáp ứng và hai biến giải thích số.

W04-Q05 Mức độ 2 — "Giữ biến còn lại cố định"

Diễn giải hệ số 1.64 của `food` trong

$$\widehat{price} = -24.5 + 1.64\, food + 1.88\, decor.$$

Hãy viết câu trả lời sao cho có đủ:

- đối tượng so sánh;
- 1 đơn vị thay đổi;
- biến đáp ứng thay đổi bao nhiêu;
- điều kiện "giữ biến còn lại cố định".

Đáp án — W04-Q05

So sánh hai nhà hàng có **cùng điểm** `decor`, nhà hàng có `food` cao hơn 1 điểm được mô hình khớp với `price` cao hơn trung bình khoảng **1.64 đơn vị tiền tệ** của dữ liệu nguồn.

Đây là **mối liên hệ đã điều chỉnh theo** `decor`, không tự động là tác động nhân quả của chất lượng đồ ăn lên giá.

Nội dung chính

1. Từ biểu đồ phân tán đến hệ số tương quan
2. Mô hình hồi quy tuyến tính đơn giản
3. Phần dư và bình phương tối thiểu
4. Hồi quy tuyến tính đa biến
5. **Diễn giải hệ số và các bẫy thường gặp** ← phần hiện tại
6. Thực hành và bài toán tổng hợp

Phần 6

Diễn giải hệ số và các bẫy thường gặp

Hệ số đơn biến và hệ số đã điều chỉnh không giống nhau

So sánh hai mô hình:

$$Y \sim X_1$$

và

$$Y \sim X_1 + X_2.$$

Hệ số của X_1 có thể thay đổi khi thêm X_2, vì câu hỏi đã đổi:

- mô hình đơn: mối liên hệ tổng thể giữa X_1 và Y;
- mô hình nhiều biến: mối liên hệ giữa X_1 và Y **ở cùng mức** X_2.

Vì sao hệ số có thể đổi?

Nếu X_1 và X_2 liên hệ với nhau, mô hình đơn có thể trộn lẫn:

- phần mối liên hệ riêng của X_1;
- cấu trúc mà X_1 cùng chia sẻ với X_2.

Khi thêm X_2, hệ số của X_1 được đọc trong một so sánh khác.
"Đã điều chỉnh" là một mô tả của mô hình — không phải bảo đảm đã loại bỏ mọi nhiễu.

W04-CH02 Mức độ 3 — Một đường chung che mất cấu trúc nhóm

Dữ liệu minh họa:

- Nhóm A: $(1, 3), (2, 2), (3, 1)$;
- Nhóm B: $(4, 13), (5, 12), (6, 11)$.
- Bỏ qua nhóm: $\widehat{Y} = -1.20 + 2.343X$.
- Giữ nhóm bằng $I(B)$: $\widehat{Y} = 4.00 - 1.00X + 13.00I(B)$.

Hãy giải thích:

1. vì sao hệ số của X đổi dấu;
2. hệ số -1 đang so sánh những quan sát nào;
3. đường hồi quy chung đã che mất cấu trúc gì.

Lời giải — W04-CH02

- Khi gộp hai nhóm, nhóm B vừa có X lớn hơn vừa có mức Y nền cao hơn; đường chung chủ yếu nối **hai cụm** và có hệ số góc dương 2.343.
- Trong từng nhóm, mỗi khi X tăng 1 thì Y giảm đúng 1; sau khi giữ nhóm cố định, hệ số của X là -1.
- Biến nhóm làm thay đổi **phép so sánh**: từ so sánh tổng thể sang so sánh trong cùng nhóm.

Đây là một dạng đảo dấu kiểu Simpson trong hồi quy. Nó cho thấy một đường hồi quy duy nhất có thể che mất cấu trúc phân nhóm.

Không hệ số nào, tự thân, chứng minh tác động nhân quả.

"Giữ các biến khác cố định" không phải phép thuật nhân quả

Một hệ số hồi quy nhiều biến thường được đọc như:

> *so sánh các quan sát có cùng giá trị của các biến giải thích khác trong mô hình.*

Nhưng điều đó không bảo đảm:

- tất cả biến gây nhiễu quan trọng đã được đo;
- mô hình tuyến tính là đúng;
- dữ liệu có thiết kế cho phép diễn giải nhân quả.

Tuần 12–13 mới phát triển các điều kiện nhân quả có hệ thống.

Tương quan và hồi quy không tự động cho quan hệ nhân quả

Mô tả mối liên hệ trả lời:

Các biến cùng thay đổi như thế nào trong dữ liệu quan sát?

Câu hỏi nhân quả hỏi:

Điều gì sẽ thay đổi nếu ta can thiệp vào một biến, giữ các yếu tố thích hợp khác như cũ?

Hệ số tương quan và hồi quy từ dữ liệu quan sát, tự thân, không đủ để chuyển từ câu hỏi thứ nhất sang câu hỏi thứ hai.

W04-Q06 Mức độ 2 — Phản biện một diễn giải sai

Một sinh viên đọc hệ số `food = 1.64` trong mô hình Zagat rồi viết:

> *"Tăng điểm chất lượng đồ ăn thêm 1 sẽ làm giá bữa ăn tăng 1.64 đô-la."*

Hãy sửa câu này để phù hợp với thông tin mà mô hình thực sự cung cấp.

Đáp án — W04-Q06

Cách nói phù hợp hơn:

> *So sánh các nhà hàng có cùng điểm `decor`, nhà hàng có điểm `food` cao hơn 1 được mô hình khớp với giá cao hơn trung bình khoảng 1.64 đơn vị giá.*

Câu sửa bỏ ngôn ngữ can thiệp "làm tăng" và thêm điều kiện giữ `decor` cố định.

W04-CH05 Mức độ 3 — Cùng đường hồi quy, hai câu chuyện khác nhau

Một biểu đồ phân tán giữa `bandwidth` và `download_time` cho xu hướng âm gần tuyến tính, và hai nghiên cứu khác nhau đều cho gần cùng đường khớp.

Hãy **xây dựng hai cơ chế sinh dữ liệu hợp lý**:

1. một cơ chế mà đường hồi quy chỉ phản ánh mối liên hệ quan sát;
2. một cơ chế mà thay đổi `bandwidth` thực sự có thể tạo ra thay đổi ở `download_time`.

Sau đó trả lời: chỉ từ biểu đồ phân tán và đường hồi quy, ta có phân biệt được hai cơ chế này không?

Lời giải — W04-CH05

Một cặp câu chuyện khả dĩ:

- **Quan sát:** kết nối băng thông cao chủ yếu được cấp cho máy chủ mới hơn, đồng thời các máy này có lưu trữ nhanh hơn. Đường hồi quy âm có thể trộn ảnh hưởng của phần cứng với `bandwidth`.
- **Can thiệp có kiểm soát:** cùng loại máy chủ được chạy dưới các mức giới hạn băng thông khác nhau; thay đổi băng thông có thể trực tiếp làm thay đổi thời gian tải.

Hai bộ dữ liệu có thể tạo biểu đồ phân tán và hệ số hồi quy rất giống nhau nhưng **ý nghĩa nhân quả khác nhau**.

Chỉ từ hồi quy mô tả, ta không xác định được cơ chế nào đúng; thông tin về cách dữ liệu được tạo ra là thiết yếu.

Nội dung chính

1. Từ biểu đồ phân tán đến hệ số tương quan
2. Mô hình hồi quy tuyến tính đơn giản
3. Phần dư và bình phương tối thiểu
4. Hồi quy tuyến tính đa biến
5. Diễn giải hệ số và các bẫy thường gặp
6. **Thực hành và bài toán tổng hợp** ← phần hiện tại

Phần 7

Thực hành và bài toán tổng hợp

Python: tính hệ số tương quan

Đề cương gốc dùng R; deck này dùng Python tương đương về thống kê.

```
r = df["Poverty"].corr(df["Graduates"])
r
```

Kết quả trên dữ liệu STAT20/OpenIntro xấp xỉ:

```
-0.747
```

Câu hỏi quan trọng không phải là cú pháp, mà là:

-0.747 *tóm tắt điều gì và bỏ sót điều gì?*

W04-PY01 Mức độ 1 — Đọc kết quả Python

Từ kết quả

```
r = -0.747
```

hãy đánh giá bốn phát biểu:

1. mối liên hệ tuyến tính là âm;
2. đổi `Graduates` từ phần trăm sang tỷ lệ 0–1 sẽ làm $|r|$ nhỏ đi 100 lần;
3. r chứng minh tốt nghiệp trung học làm giảm nghèo;
4. nên xem biểu đồ phân tán trước khi chốt diễn giải.

Đáp án — W04-PY01

1. **Đúng.**
2. **Sai.** Tương quan không đổi dưới phép đổi đơn vị tuyến tính với hệ số dương.
3. **Sai.** Tương quan không tự thiết lập quan hệ nhân quả.
4. **Đúng.** Cần kiểm tra dạng phi tuyến, điểm cực đoan và cấu trúc nhóm.

Python: hồi quy tuyến tính đơn giản

```
import statsmodels.formula.api as smf

m1 = smf.ols(
    "Poverty ~ Graduates",
    data=df
).fit()

m1.params
```

Ta ưu tiên xem các hệ số cần diễn giải, thay vì chiếu toàn bộ `model.summary()` với các mục suy luận chưa học.

Python: giá trị khớp và phần dư

```
fitted = m1.fittedvalues
resid = m1.resid
```

Hai đại lượng thỏa:

$$y_i = \hat{y}_i + e_i.$$

STAT20 dùng `fitted()` và `resid()` trong R; đây là các thao tác Python tương đương về ý nghĩa thống kê.

W04-PY02 Mức độ 2 — Phần dư dương nghĩa là gì?

Giả sử

```
fitted.iloc[i] == 11.36
resid.iloc[i]  == 5.44
```

và biến đáp ứng là `Poverty` tính theo điểm phần trăm.

Hãy suy ra giá trị quan sát và diễn giải phần dư.

Đáp án — W04-PY02

$$y_i = 11.36 + 5.44 = 16.80.$$

Phần dư dương 5.44 nghĩa là tỷ lệ nghèo đói quan sát cao hơn giá trị khớp từ mô hình **5.44 điểm phần trăm**.

Python: hồi quy với nhiều biến giải thích

```
m2 = smf.ols(
    "price ~ food + decor",
    data=zagat
).fit()

m2.params
```

Ý nghĩa thống kê cần đọc:

- `food`: mối liên hệ với `price` khi giữ `decor` cố định;
- `decor`: mối liên hệ với `price` khi giữ `food` cố định.

Python: biến giải thích phân loại

```
m3 = smf.ols(
    "weight ~ volume + C(cover)",
    data=books
).fit()

m3.params
```

`C(cover)` yêu cầu phần mềm mã hóa các mức thành biến chỉ báo. Khi đọc kết quả, phải xác định **mức tham chiếu** trước khi diễn giải hệ số nhóm.

W04-PY03 Mức độ 2 — Hồi quy đơn và hồi quy nhiều biến

Bạn chạy:

```
m_simple = smf.ols("Y ~ X1", data=df).fit()
m_multi  = smf.ols("Y ~ X1 + X2", data=df).fit()
```

và hệ số `X1` khác nhau đáng kể.

Điều nào sau đây là phản ứng đúng nhất?

- (a) một trong hai phần mềm tính sai;
- (b) hai hệ số đang trả lời hai câu hỏi điều kiện khác nhau;
- (c) phải chọn hệ số có trị tuyệt đối lớn hơn;
- (d) hồi quy nhiều biến tự động cho tác động nhân quả.

Đáp án — W04-PY03

(b) là đúng nhất.

Mô hình đơn và mô hình nhiều biến định nghĩa hai phép so sánh khác nhau. Không được chọn hệ số chỉ vì nó lớn hơn, và hồi quy nhiều biến không tự động biến mối liên hệ thành tác động nhân quả.

W04-CASE01 Mức độ 3 — Tình huống tổng hợp

Tình huống minh họa: với mô hình Zagat

$$\widehat{price} = -24.5 + 1.64\, food + 1.88\, decor,$$

xét một nhà hàng có `food = 24`, `decor = 20`, `price = 60`.

1. Tính giá trị khớp và phần dư.
2. Diễn giải hệ số `food`.
3. Nếu chỉ fit `price ~ food`, hệ số `food` có buộc bằng 1.64 không?
4. Có thể kết luận tăng `food` 1 điểm **làm** giá tăng 1.64 không?

Lời giải — W04-CASE01 (1/2)

Giá trị khớp:

$$\hat{y} = -24.5 + 1.64(24) + 1.88(20) = 52.46.$$

Phần dư:

$$e = 60 - 52.46 = 7.54.$$

Nhà hàng có giá quan sát cao hơn giá trị khớp từ hai biến giải thích khoảng 7.54 đơn vị giá.

Lời giải — W04-CASE01 (2/2)

- Hệ số `food = 1.64`: với cùng `decor`, cao hơn 1 điểm `food` liên hệ với giá khớp cao hơn khoảng 1.64.
- Hệ số từ `price ~ food` **không bắt buộc** bằng 1.64 vì mô hình đó không giữ `decor` cố định.
- Không thể chuyển câu trên thành "nâng food sẽ làm price tăng" chỉ từ hồi quy quan sát.

Đây là khác biệt giữa **mối liên hệ tổng thể** và **mối liên hệ đã điều chỉnh**.

W04-CH03 Mức độ 3 — Chọn công cụ tóm tắt

Bạn có ba bộ dữ liệu:

- A: biểu đồ phân tán gần đường thẳng, không có điểm cực đoan;
- B: quan hệ rõ dạng chữ U;
- C: phần lớn điểm gần đường thẳng nhưng có một điểm rất xa theo trục x.

Không được tính toán trước. Với mỗi bộ, hãy quyết định:

1. hệ số tương quan có phải tóm tắt đủ tốt không?
2. hồi quy tuyến tính đơn có hợp lý để mô tả không?
3. cần xem thêm điều gì trước khi tin một con số tóm tắt?

Lời giải — W04-CH03

- **A:** tương quan và hồi quy tuyến tính có thể phù hợp, sau khi kiểm tra phần dư.
- **B:** tương quan có thể gần 0 dù quan hệ mạnh; đường thẳng bỏ sót cấu trúc phi tuyến.
- **C:** điểm có đòn bẩy cao có thể làm thay đổi mạnh tương quan và hệ số góc; cần xem mô hình có và không có điểm đó.

Nguyên tắc chung: **đồ thị → mô hình/tóm tắt số → kiểm tra phần dư → diễn giải trong ngữ cảnh.**

Những điều quan trọng cần nhớ (1/2)

1. **Xem biểu đồ trước khi đọc một con số.**
2. r đo hướng và độ mạnh của **mối liên hệ tuyến tính**, không phải mọi dạng quan hệ.
3. Bình phương tối thiểu tối thiểu hóa $\sum e_i^2$ và thỏa $\sum e_i = 0$, $\sum x_i e_i = 0$.
4. Trong hồi quy đơn, $b_1 = r(s_y/s_x)$ và đường khớp đi qua $(\bar{x}, \bar{y})$.

Những điều quan trọng cần nhớ (2/2)

5. Hệ số góc phải đi cùng **đơn vị và ngữ cảnh**; hệ số chặn có thể không có ý nghĩa thực tế.
6. Điểm ảnh hưởng mạnh, phi tuyến và cấu trúc nhóm có thể làm tóm tắt tuyến tính gây hiểu lầm.
7. Trong hồi quy nhiều biến, mỗi hệ số được đọc khi **giữ các biến còn lại cố định**; hệ số có thể đổi dấu khi phép so sánh thay đổi.
8. Hệ số hồi quy và tương quan từ dữ liệu quan sát **không tự động là tác động nhân quả**.

Chuẩn bị cho tuần sau

Tuần 01–04 tập trung vào:

$$\text{dữ liệu} \to \text{mô tả} \to \text{trực quan hóa} \to \text{mối liên hệ}.$$

Từ Week 05, ta cần một ngôn ngữ mới để mô hình hóa **bất định**:

- biến cố;
- xác suất;
- xác suất có điều kiện;
- độc lập;
- các quy tắc tính xác suất.