Tuần 02 — Tóm tắt dữ liệu (1/3)

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Khoa Công nghệ Thông tin (VNU-UET-FIT)

Nội dung chính — Phần 1/5

1. $\rightarrow$ **Dữ liệu phân loại**
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. Phản biện, bài tập và tình huống tổng hợp
5. Python/pandas và tổng kết

Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Nguồn và học liệu tham khảo

Bài giảng được **biên soạn mới** cho học phần **UET.MAT1052 — Xác suất thống kê**, dựa trên đề cương chính thức và tham khảo:

- **STAT 20**, University of California, Berkeley;
- Freedman, Pisani & Purves, *Statistics*, 4th ed.;
- Diez, Çetinkaya-Rundel & Barr, *OpenIntro Statistics*, 4th ed.;
- Çetinkaya-Rundel & Hardin, *Introduction to Modern Statistics*, 2nd ed.

Nguồn và giấy phép.
Tài nguyên được tái sử dụng trực tiếp từ nguồn bên ngoài, nếu có, được ghi nguồn và giấy phép tại vị trí tương ứng hoặc trong phần tài liệu tham khảo.

Tuần 02 — Ta đang học cách **nén dữ liệu có chủ đích**

Trong tuần này, ta sẽ đi từ dữ liệu thô đến những tóm tắt có thể đọc, so sánh và phản biện:

- **dữ liệu phân loại:** bảng liên hợp, số đếm, tỉ lệ và mối liên hệ mô tả;
- **dữ liệu số:** đồ thị phân phối, trung tâm và độ phân tán;
- **lập luận:** tính bền vững, hàm mất mát, phản ví dụ cùng tóm tắt nhưng khác hình dạng, và biến đổi thang đo.

Câu hỏi xuyên suốt:

*Một tóm tắt có thể hoàn toàn đúng về số học nhưng vẫn trả lời **sai câu hỏi** hay không?*

Mục tiêu học tập của Tuần 02

Sau tuần này, sinh viên cần có thể:

1. chọn tóm tắt theo **loại biến + câu hỏi**;
2. đọc bảng liên hợp: ô, biên, tổng chung;
3. chọn đúng **mẫu số** cho tỉ lệ toàn bộ / theo hàng / theo cột;
4. nhận biết mối liên hệ qua phân phối có điều kiện;
5. mô tả phân phối số bằng **hình dạng – trung tâm – độ phân tán – giá trị bất thường**.
6. giải thích trung bình/trung vị, SD/IQR và tính bền vững;
7. giải thích vì sao **trung bình tối thiểu hóa sai số bình phương**;
8. phản biện tóm tắt/đồ thị gây hiểu nhầm;
9. xây phản ví dụ: **cùng trung bình/SD nhưng khác phân phối**, hoặc trung bình mô tả "điển hình" kém;
10. suy luận tác động của $Y = aX + b$ lên trung bình, trung vị, SD, IQR; dùng pandas ngắn để kiểm chứng.

Nội dung chính — Phần 1/5

1. $\rightarrow$ **Dữ liệu phân loại**
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. Phản biện, bài tập và tình huống tổng hợp
5. Python/pandas và tổng kết

Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Quy ước mức bài tập

- **CORE:** nắm chắc kiến thức bắt buộc.
- **REASONING:** giải thích, so sánh hoặc nhiều bước.
- **CHALLENGE:** không nêu sẵn phương pháp; phải tự chọn cách tiếp cận.
- **DESIGN:** tự xây dữ liệu/phản ví dụ/cấu trúc thỏa yêu cầu.
- **COMPUTE:** dùng tính toán ngắn để kiểm chứng lập luận thống kê.

*Bài khó được làm khó bằng **lập luận và lựa chọn mô hình**, không phải bằng nhiều dòng Python.*

Dữ liệu phân loại — từ số đếm đến tỉ lệ

Từ dữ liệu thô $\to$ *bảng/tỉ lệ* $\to$ *phân phối có điều kiện* $\to$ ***mối liên hệ mô tả***.

W02-Q01 [CORE] — Nhớ lại Tuần 01

Một biến `species` nhận các mức *Adelie*, *Chinstrap*, *Gentoo*; một biến `body_mass_g` ghi khối lượng cơ thể.

1. Biến nào là **phân loại**, biến nào là **số**?
2. Bạn sẽ bắt đầu tóm tắt hai biến này bằng cùng một công cụ hay khác nhau?

Mục tiêu:

loại biến + câu hỏi đang xét → tóm tắt phù hợp → diễn giải.

Đáp án — W02-Q01

`species` là biến phân loại; `body_mass_g` là biến số. Với `species`, bắt đầu bằng số đếm/tỉ lệ; với `body_mass_g`, bắt đầu bằng đồ thị phân phối và trung tâm/độ phân tán.

Tóm tắt dữ liệu là một phép lựa chọn

Một tập dữ liệu thô thường chứa quá nhiều chi tiết để nhìn ra cấu trúc ngay.

dữ liệu thô $\to$ tổ chức / tổng hợp $\to$ bảng · biểu đồ · đặc trưng số $\to$ mẫu hình $\to$ diễn giải

Một tóm tắt luôn bỏ đi một phần thông tin.

Vì vậy câu hỏi quan trọng không chỉ là "tính được con số nào?", mà là:

Tóm tắt nào giữ lại đúng thông tin cần cho câu hỏi?

Chuyển thể từ STAT20 tiếng Việt, Chương 2.

W02-Q02 [CORE] — Cùng dữ liệu, khác câu hỏi

Với dữ liệu chim cánh cụt Palmer, hãy chọn tóm tắt mở đầu hợp lý nhất:

1. Loài nào xuất hiện nhiều nhất?
2. Loài và đảo có mối liên hệ mô tả không?
3. Khối lượng cơ thể có phân phối lệch không?
4. Giá trị nào đại diện hợp lý cho vị trí trung tâm của khối lượng cơ thể?

Các công cụ có thể chọn

- bảng số đếm;
- bảng liên hợp;
- tỉ lệ có điều kiện;
- histogram;
- trung bình;
- trung vị.

*Chọn theo **loại biến** + **câu hỏi**.*

Đáp án — W02-Q02

1. bảng số đếm/biểu đồ cột; (2) bảng liên hợp + tỉ lệ có điều kiện; (3) histogram; (4) trung bình hoặc trung vị tùy hình dạng và mục tiêu.

Từ khung dữ liệu đến số đếm

Trong Palmer Penguins của STAT20, `species` và `island` đều là biến phân loại.

Loài	Biscoe	Dream	Torgersen	Tổng
Adelie	44	55	47	146
Chinstrap	0	68	0	68
Gentoo	119	0	0	119
Tổng	**163**	**123**	**47**	**333**

Từ 333 dòng dữ liệu, bảng làm lộ các mẫu hình mà khung dữ liệu thô khó cho thấy ngay.

Nguồn: STAT20 tiếng Việt, Chương 2. STAT20 dùng "bảng dự phòng"; học phần này dùng "bảng liên hợp".

Bảng liên hợp: đọc trước khi tính

Một **bảng liên hợp** (*contingency table*) tóm tắt hai biến phân loại.

Tuổi	Tử vong	Sống sót	Tổng
Người lớn	1438	654	2092
Trẻ em	52	57	109
Tổng	**1490**	**711**	**2201**

Cần phân biệt:

- **ô:** một tổ hợp hai mức;
- **tổng hàng / tổng cột:** số đếm biên;
- **tổng chung:** toàn bộ quan sát.

Đọc đúng cấu trúc trước khi tính tỉ lệ.

Nguồn số liệu Titanic: OpenIntro Statistics 4e, Chương 2 §2.2.

W02-EX01 [REASONING] — Đọc bảng liên hợp

Dùng bảng Titanic ở slide trước.

1. Con số **654** mô tả nhóm nào?
2. **2092** là tổng gì?
3. **711** là tổng gì?
4. Có bao nhiêu hành khách trong bảng?
5. Viết một câu mô tả dữ liệu dựa trên **một ô**, không dùng từ "tỉ lệ".

Mục tiêu: *phân biệt số đếm ô, tổng hàng, tổng cột và tổng chung.*

Đáp án — W02-EX01

654 = người lớn sống sót; 2092 = tổng người lớn; 711 = tổng sống sót; tổng chung = 2201. Ví dụ mô tả một ô: “Có 52 hành khách là trẻ em và tử vong.”

W02-EX02 [REASONING] — Số đếm hay tỉ lệ?

Một sinh viên kết luận:
"Người lớn có kết quả sống sót tốt hơn vì 654 > 57."

1. Sai ở đâu trong logic so sánh?
2. Hãy chọn mẫu số đúng cho mỗi nhóm.
3. Tính tỉ lệ sống sót của người lớn và trẻ em.
4. Viết lại kết luận bằng ngôn ngữ **mô tả**, không suy diễn nhân quả.

Gợi ý: so sánh trong từng nhóm khi kích thước nhóm khác nhau.

Đáp án — W02-EX02

So sánh 654 với 57 dùng số đếm thô của hai nhóm rất khác kích thước. Tỉ lệ sống sót: người lớn $654/2092 \approx 31.3\%$; trẻ em $57/109 \approx 52.3\%$. Kết luận mô tả: tỉ lệ sống sót của trẻ em cao hơn trong bảng này.

Ba câu hỏi, ba mẫu số

Một ô số đếm có thể sinh ra các tỉ lệ khác nhau.

Với ô "Người lớn & Sống sót" = 654:

- **tỉ lệ trên toàn bộ:** $654/2201$;
- **tỉ lệ trong hàng người lớn:** $654/2092$;
- **tỉ lệ trong cột sống sót:** $654/711$.

Chúng **không** trả lời cùng một câu hỏi.

*Tỉ lệ chỉ có nghĩa khi nói rõ **mẫu số đại diện cho ai**.*

W02-EX03 [REASONING] — Thử thách về mẫu số

Vẫn dùng bảng Titanic. Xác định **mẫu số** trước khi tính:

A. "Trong số **người lớn**, bao nhiêu phần sống sót?"
B. "Trong số **người sống sót**, bao nhiêu phần là trẻ em?"
C. "Trong **toàn bộ hành khách**, bao nhiêu phần là trẻ em sống sót?"

Sau đó viết phân số tương ứng.

Không chấp nhận câu trả lời "lấy số đếm chia cho tổng" nếu chưa chỉ rõ **tổng nào**.

Đáp án — W02-EX03

A: mẫu số 2092, $654/2092$. B: mẫu số 711, $57/711$. C: mẫu số 2201, $57/2201$.

Phân phối biên và phân phối có điều kiện

Phân phối biên (*marginal distribution*) mô tả một biến mà không cố định biến kia.

Ví dụ: phân phối tuổi trong toàn bộ bảng Titanic.

Phân phối có điều kiện (*conditional distribution*) mô tả một biến **trong một mức cụ thể** của biến kia.

Ví dụ: phân phối sống sót **trong nhóm người lớn**.

Trong bảng Palmer Penguins, ta cũng có thể hỏi:

- phân phối `island` trong từng `species`;
- hoặc phân phối `species` trong từng `island`.

Hai hướng điều kiện hóa kể hai câu chuyện khác nhau.

Nhận biết mối liên hệ giữa hai biến phân loại

Hai biến phân loại có **mối liên hệ mô tả (*association*)** nếu phân phối có điều kiện của một biến thay đổi theo mức của biến còn lại.

Titanic:

- người lớn sống sót: $654/2092 \approx 31\%$;
- trẻ em sống sót: $57/109 \approx 52\%$.

Các phân phối có điều kiện khác nhau đáng kể $\rightarrow$ dữ liệu cho thấy **mối liên hệ mô tả** giữa nhóm tuổi và sống sót.

Không suy ra: mối liên hệ $\rightarrow$ nguyên nhân.

W02-Q03 [CORE] — Mối liên hệ không phải quan hệ nhân quả

Chọn phát biểu chặt chẽ hơn:

A. “Tuổi gây ra khác biệt về sống sót.”
B. “Trong dữ liệu Titanic này, tỉ lệ sống sót khác nhau giữa hai nhóm tuổi.”

Vì sao phát biểu còn lại vượt quá điều mà bảng liên hợp tự nó cho phép kết luận?

Kết nối Tuần 01: một **khẳng định mô tả** không tự động trở thành **khẳng định nhân quả**.

Đáp án — W02-Q03

Chọn **B**. Bảng chỉ cho phép nói tỉ lệ sống sót khác nhau giữa hai nhóm tuổi trong dữ liệu; câu A là khẳng định nhân quả và cần logic/thiết kế nhân quả bổ sung.

Ví dụ IMS2e — 10.000 khoản vay Lending Club

Kiểu hồ sơ	Thuê nhà	Có thế chấp	Sở hữu	Tổng
Joint	362	950	183	1495
Individual	3496	3839	1170	8505
Tổng	**3858**	**4789**	**1353**	**10000**

Trong hồ sơ **individual**:

$$\frac{3496}{8505} \approx 41.1\%$$

là người thuê nhà.

Trong số người **thuê nhà**:

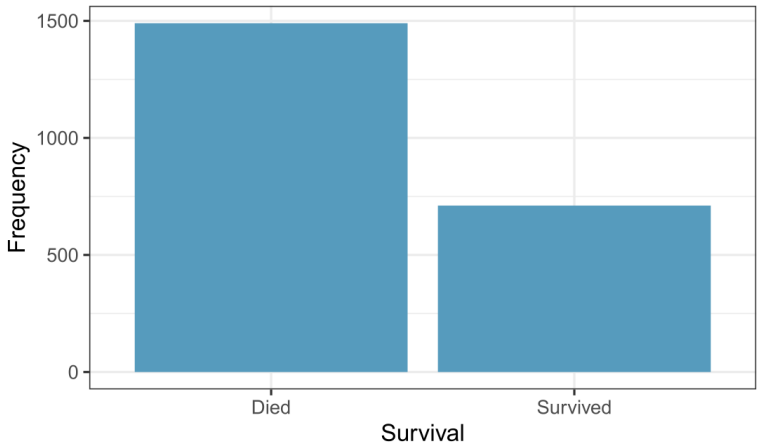
$$\frac{362}{3858} \approx 9.4\%$$

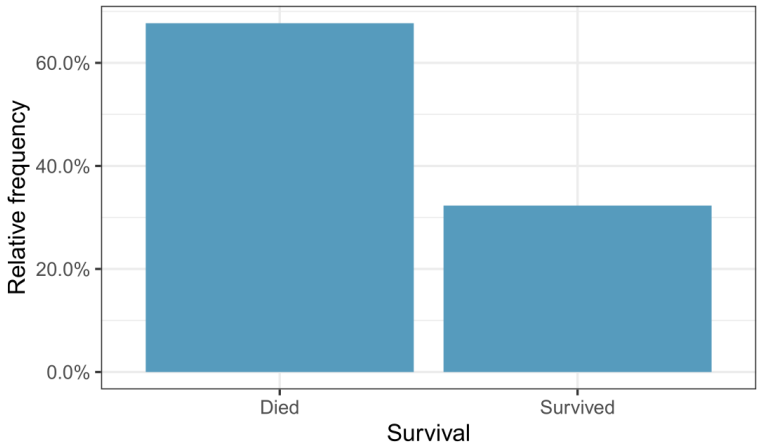
là hồ sơ joint.

Cùng một ô, khác mẫu số $\Rightarrow$ khác câu hỏi.

Nguồn: Introduction to Modern Statistics 2e, Ch. 4 §§4.1–4.3.

Biểu đồ cột: số đếm hay tần suất tương đối?



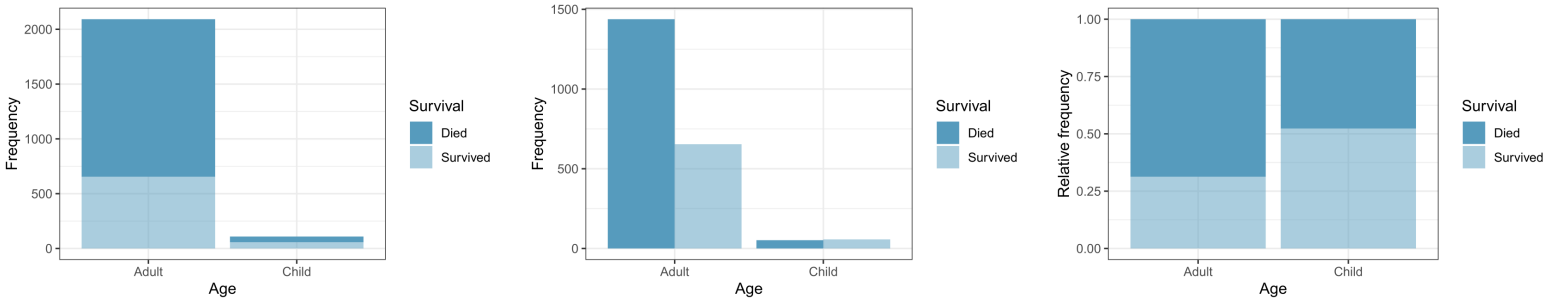


- biểu đồ số đếm nhấn mạnh **quy mô**;
- biểu đồ tần suất tương đối nhấn mạnh **cơ cấu**.

Misconception check. Cả hai hình đều đúng về dữ liệu. Nếu câu hỏi là "nhóm tuổi nào có **tỉ lệ** sống sót cao hơn?", vì sao hình số đếm có thể dẫn mắt tới một kết luận sai? Một đồ thị đúng có thể hỗ trợ một lập luận sai bằng cách nào?

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.2.

Hai biến phân loại: cùng bảng, nhiều cách nhìn



Cùng dữ liệu, nhưng:

- cột chồng theo số đếm cho thấy tổng quy mô;
- cột đặt cạnh nhau theo số đếm thuận tiện so sánh số lượng;
- cột chồng chuẩn hóa làm nổi bật **tỉ lệ có điều kiện**.

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.2.

W02-EX04 [REASONING] — Biểu đồ cột hay histogram?

Không nhìn vào khoảng cách giữa các cột. Hãy dùng **ý nghĩa của trục x** để phân biệt:

1. Một biểu đồ có trục x là `Adelie`, `Chinstrap`, `Gentoo`.
2. Một biểu đồ có trục x là các khoảng `0–5`, `5–10`, `10–15` giờ/tuần.

Biểu đồ nào là **biểu đồ cột**, biểu đồ nào là **histogram**? Vì sao?

Điểm cốt lõi:

- biểu đồ cột $\rightarrow$ các **mức phân loại**;
- histogram $\rightarrow$ các **khoảng trên thang số**; tính kề nhau của khoảng có ý nghĩa.

Đáp án — W02-EX04

`Adelie/Chinstrap/Gentoo` $\rightarrow$ biểu đồ cột vì là các mức phân loại. Các khoảng `0-5, 5-10, ...` $\rightarrow$ histogram vì là khoảng chia trên thang số; tiêu chí bản chất không phải "các cột có chạm nhau không".

Nội dung chính — Phần 2/5

1. Dữ liệu phân loại
2. → **Dữ liệu số: hình dạng và trung tâm**
3. Độ phân tán và biểu đồ hộp
4. Phản biện, bài tập và tình huống tổng hợp
5. Python/pandas và tổng kết

Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Dữ liệu số — hình dạng, trung tâm và độ phân tán

Một đặc trưng số chỉ có ý nghĩa khi ta biết nó đang giữ lại điều gì và bỏ đi điều gì của phân phối.

W02-WP01 [REASONING] — Bài mẫu nhiều bước: một tiêu đề có đúng không?

Một bản tin nhìn bảng Titanic và viết:

> *"Người lớn sống sót tốt hơn trẻ em vì có **654** người lớn sống sót nhưng chỉ **57** trẻ em sống sót."*

Không chọn công thức trước. Hãy lần lượt:

1. xác định đại lượng mà từ "**tốt hơn**" đang ngầm so sánh;
2. chọn đúng hai mẫu số;
3. tính hai tỉ lệ;
4. sau đó đổi câu hỏi thành "trong số người sống sót, bao nhiêu phần là người lớn?";
5. giải thích vì sao cùng ô 654 nhưng câu hỏi mới cần mẫu số khác.

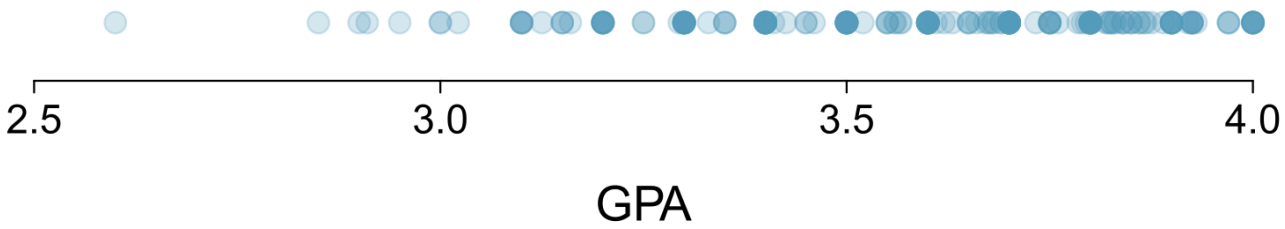
Đáp án — W02-WP01

Tỉ lệ sống sót cần mẫu số theo từng nhóm tuổi: người lớn $654/2092 \approx 31.3\%$, trẻ em $57/109 \approx 52.3\%$. Còn "trong số người sống sót, bao nhiêu phần là người lớn?" là $654/711 \approx 92.0\%$. Cùng tử số nhưng tập đang được điều kiện hóa khác nên ý nghĩa khác.

Dữ liệu số — khi số đếm chưa đủ

Với biến số, **khoảng cách giữa các giá trị có ý nghĩa**.

Ví dụ GPA:



Một bảng đếm từng giá trị có thể giữ nhiều chi tiết nhưng che mất hình dạng chung.

Câu hỏi chuyển tiếp:

> *Ta cần giữ lại những đặc điểm nào của một **phân phối số**?*

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

W02-Q04 [CORE] — Mô tả, đừng chỉ đặt tên biểu đồ

Quan sát biểu đồ chấm GPA ở slide trước. Hãy thử mô tả bằng bốn ý:

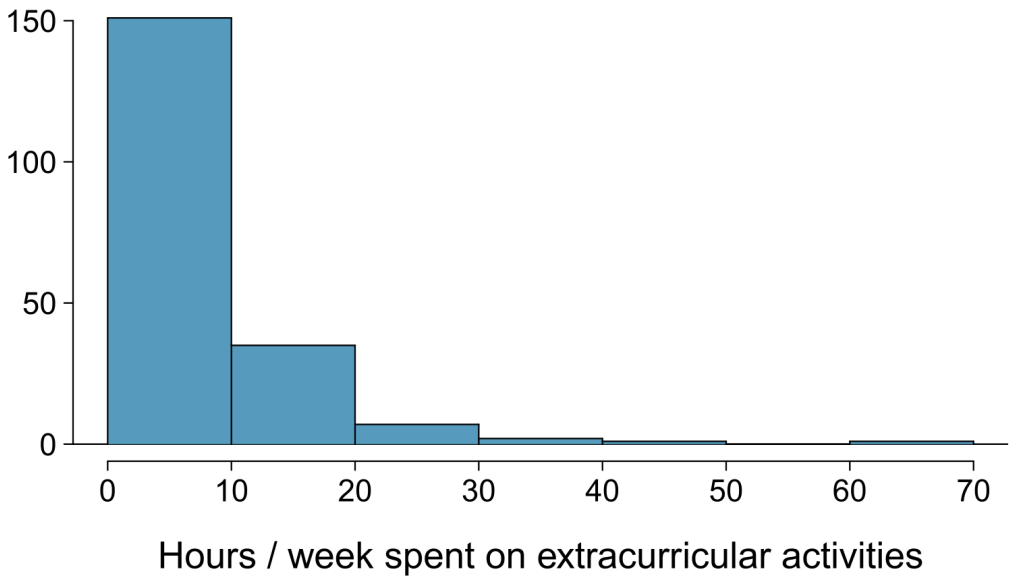
1. **hình dạng (hình dạng)**;
2. **trung tâm (trung tâm)**;
3. **độ phân tán (độ phân tán)**;
4. **giá trị bất thường (quan sát bất thường)** nếu có.

Không cần đưa ra con số chính xác nếu đồ thị không hỗ trợ.

Đáp án — W02-Q04

Một mô tả tốt phải đề cập hình dạng, trung tâm xấp xỉ, độ phân tán và quan sát bất thường; không bịa số chính xác nếu hình không hỗ trợ.

Histogram: nhìn hình dạng của phân phối

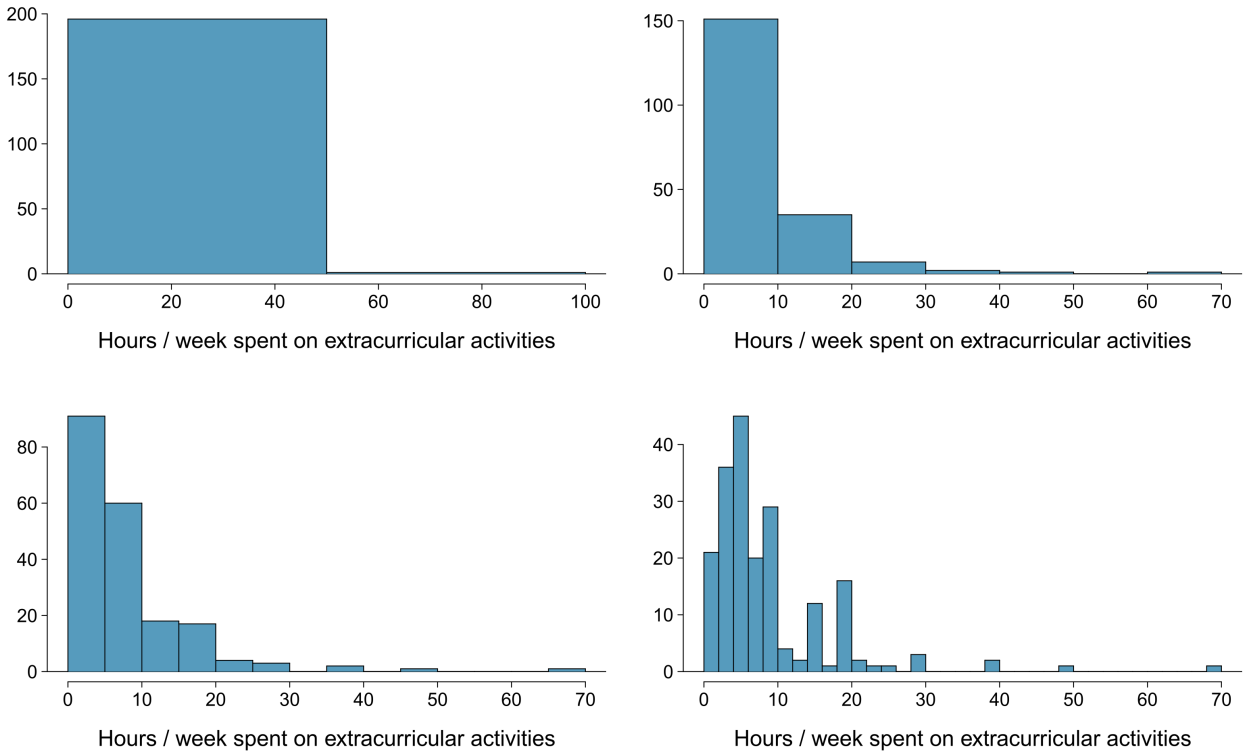


- trục x: các giá trị hoặc **khoảng giá trị**;
- trục y: tần số hoặc tần suất tương đối;
- mỗi quan sát thuộc một **khoảng chia**.

***Độ rộng khoảng chia là một quyết định phân tích**, không chỉ là trang trí.*

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

W02-EX05 [REASONING] — Cùng dữ liệu, khác độ rộng khoảng chia



Điều gì **ổn định** qua các cách chia khoảng? Điều gì thay đổi? Có nên kết luận chắc chắn về số mốt chỉ từ một lựa chọn độ rộng khoảng không?

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

Đáp án — W02-EX05

Vùng giá trị chính và xu hướng đuôi dài thường ổn định hơn; số đỉnh/gap nhỏ có thể thay đổi theo độ rộng khoảng chia. Không nên kết luận số đỉnh từ một cách chia khoảng duy nhất.

Ví dụ IMS2e — lãi suất của `loan50`

Lãi suất	Số khoản vay	Lãi suất	Số khoản vay
(5%, 7.5%]	11	(12.5%, 15%]	4
(7.5%, 10%]	15	(15%, 17.5%]	5
(10%, 12.5%]	8	(17.5%, 20%]	4
trên 20%	3		

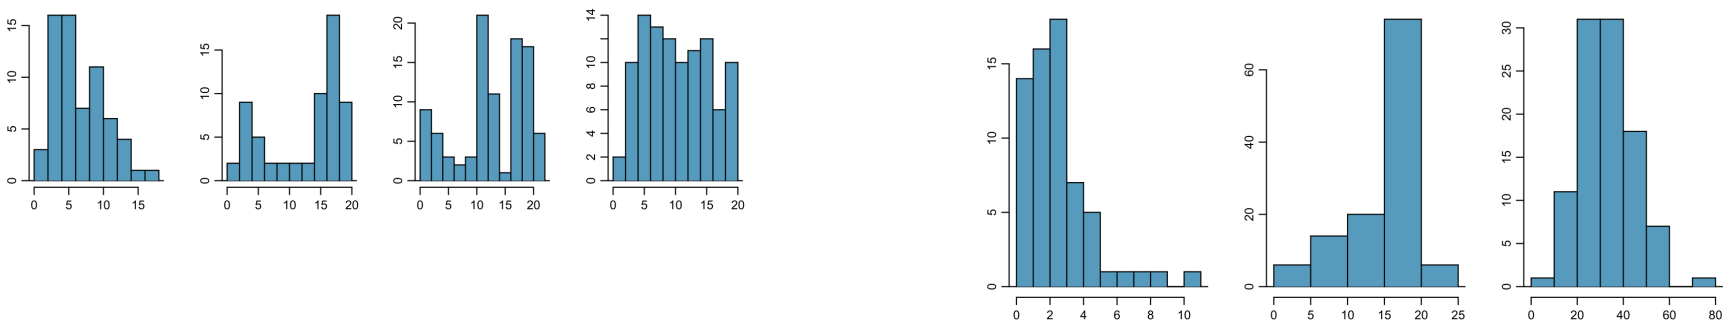
Trung bình của 50 khoản vay là **11.57%**.

Phần lớn quan sát dưới 15%, nhưng có đuôi kéo về phía lãi suất cao: **lệch phải**.

Một con số về trung tâm không thay thế việc nhìn hình dạng.

Nguồn: IMS2e, Ch. 5 §§5.2–5.3; dữ liệu `loan50` thuộc hệ dữ liệu OpenIntro.

Hình dạng: số mốt và độ xiên



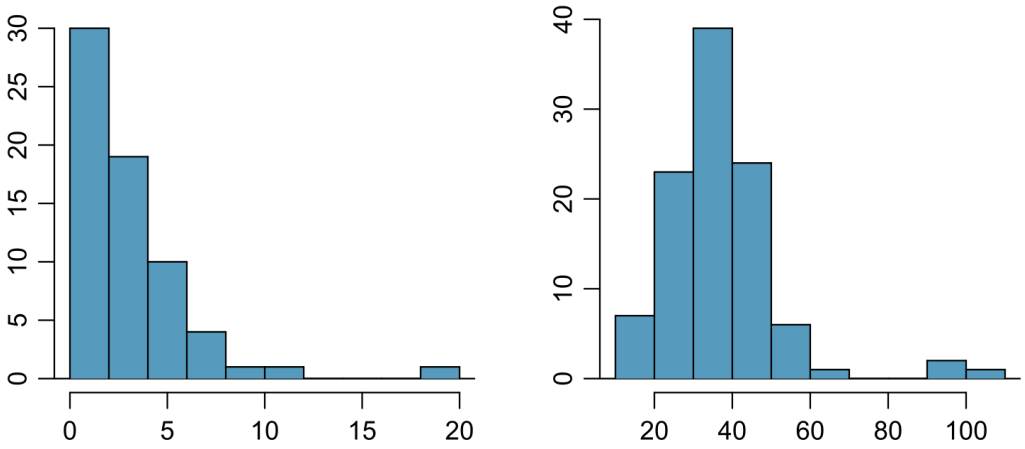
Khi mô tả hình dạng, thường quan tâm:

- **một đỉnh / hai đỉnh / nhiều đỉnh**;
- **đối xứng / lệch phải / lệch trái**.

Đừng biến việc mô tả thành taxonomy máy móc: ưu tiên đặc điểm có liên quan tới câu hỏi.

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

Giá trị bất thường



Một quan sát xa phần lớn dữ liệu có thể là:

- một giá trị thật nhưng hiếm;
- dấu hiệu của một nhóm/hiện tượng khác;
- lỗi đo hoặc lỗi nhập liệu.

Không tự động xóa "ngoại lai" chỉ vì nó gây bất tiện.

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

W02-EX06 [REASONING] — Mô tả một phân phối

Quay lại histogram số giờ hoạt động ngoại khóa.

Viết 2–3 câu mô tả có đủ:

- hình dạng;
- trung tâm ở mức xấp xỉ nếu có thể;
- độ phân tán ở mức quan sát được;
- quan sát bất thường.

Sau đó chỉ ra **một điều bạn không thể biết chính xác chỉ từ histogram**.

Đáp án — W02-EX06

Phân phối giờ hoạt động ngoại khóa có mốt chính, lệch phải và đuôi kéo dài; quan sát khoảng 60 giờ/tuần trông bất thường. Histogram không cho giá trị từng quan sát hay trung bình/trung vị chính xác.

Nội dung chính — Phần 2/5

1. Dữ liệu phân loại
2. → **Dữ liệu số: hình dạng và trung tâm**
3. Độ phân tán và biểu đồ hộp
4. Phản biện, bài tập và tình huống tổng hợp
5. Python/pandas và tổng kết

Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Trung bình: dùng độ lớn của mọi quan sát

Với dữ liệu $x_1, \ldots, x_n$, trung bình mẫu:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

STAT20 dùng ví dụ:

$$8, 11, 7, 7, 8, 11, 9, 6, 10, 7, 9$$

có $\bar{x} \approx 8.45$.

Trực giác: trung bình dùng toàn bộ độ lớn của các giá trị, nên một giá trị cực đoan có thể kéo trung bình mạnh.

Suy dẫn — Trung bình tối thiểu hóa tổng sai số bình phương (1/2)

Với một dự đoán hằng số a, đặt tổng sai số bình phương

$$S(a) = \sum_{i=1}^{n} (x_i - a)^2.$$

Lấy đạo hàm theo a:

$$S'(a) = -2 \sum_{i=1}^{n} (x_i - a) = 2na - 2 \sum_{i=1}^{n} x_i.$$

Điểm dừng thỏa

$$S'(a) = 0 \quad \Longrightarrow \quad \boxed{a = \bar{x}}.$$

Vì $S''(a) = 2n > 0$, đây là **điểm cực tiểu duy nhất**.

Suy dẫn — Kiểm tra bằng đẳng thức phân rã (2/2)

Từ

$$x_i - a = (x_i - \bar{x}) + (\bar{x} - a)$$

và $\sum_i (x_i - \bar{x}) = 0$, suy ra

$$\boxed{\sum_{i=1}^{n} (x_i - a)^2 = \sum_{i=1}^{n} (x_i - \bar{x})^2 + n(a - \bar{x})^2}.$$

Vì vậy:

- phần thứ nhất **không phụ thuộc** vào a;
- phần tăng thêm $n(a - \bar{x})^2 \geq 0$;
- giá trị nhỏ nhất đạt duy nhất tại $a = \bar{x}$.

Giải tích *cho điều kiện cực tiểu;* ***đẳng thức phân rã*** *cho thấy chính xác ta mất thêm bao nhiêu khi chọn* $a \neq \bar{x}$.

Mở rộng: đổi hàm mất mát có thể đổi "tâm tối ưu"; trung vị gắn tự nhiên với mất mát tuyệt đối.

W02-WP02 [REASONING] — Dùng đẳng thức thay vì thử vô hạn giá trị

Với dữ liệu

$$2,\ 4,\ 9,$$

ta có

$$\bar{x} = 5.$$

Nhắc lại:

$$L(c) = L(\bar{x}) + n(c - \bar{x})^2.$$

1. Tính $L(5)$.
2. Suy ra công thức $L(c)$ cho mọi c mà không khai triển lại.
3. So sánh $c = 4, 5, 6$.
4. Vì sao đây là một **lựa chọn mô hình hóa**, không chỉ là mẹo đại số?

Đáp án — W02-WP02

Với $x = (2, 4, 9)$, $\bar{x} = 5$ và $L(5) = 26$.

$$L(c) = 26 + 3(c - 5)^2.$$

Suy ra $L(4) = 29$, $L(5) = 26$, $L(6) = 29$.

*Trung bình tối ưu **vì ta đã chọn mất mát bình phương**; đây là một quyết định mô hình hóa.*

Trung vị: dùng vị trí thứ tự

Trung vị là giá trị chia dữ liệu đã sắp thứ tự thành hai nửa.

Với

$$6, 7, 7, 7, 8, \mathbf{8}, 9, 9, 10, 11, 11,$$

trung vị bằng 8.

Nếu thay 6 bằng -200:

- trung bình: $8.45 \to -10.27$;
- trung vị: $8 \to 8$.

Trung vị bền vững hơn trung bình trước giá trị cực đoan.

Ví dụ chuyển thể từ STAT20 tiếng Việt, phần "Các thước đo tâm".

W02-EX07 [REASONING] — Trung bình hay trung vị?

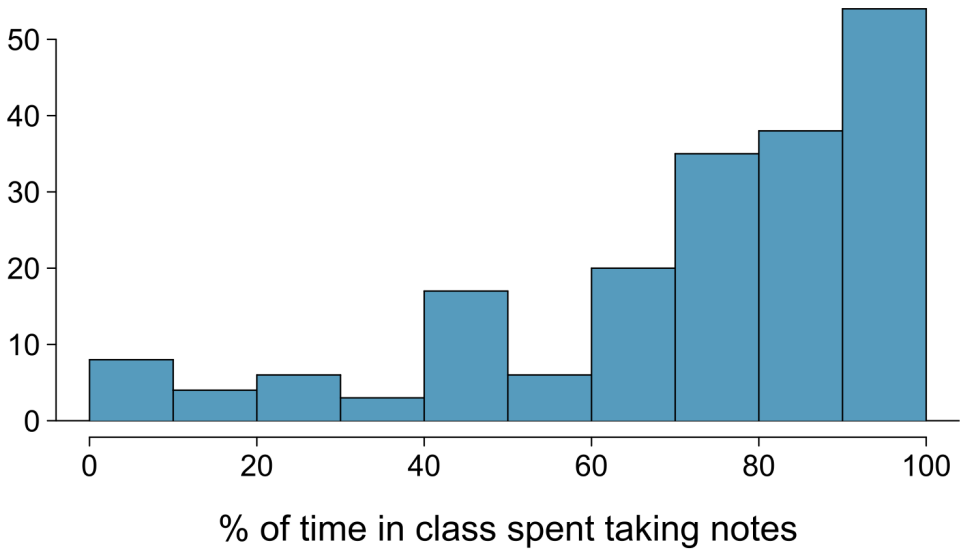
Với dãy của STAT20, thay giá trị 6 bằng -200.

1. Dự đoán trước khi tính: trung bình và trung vị thay đổi theo hướng nào?
2. Thước đo nào đại diện tốt hơn cho "một giá trị điển hình" của 10 quan sát còn lại?
3. Giải thích bằng **cơ chế** của trung bình/trung vị, không chỉ nói "trung vị tốt hơn khi phân phối lệch".
4. Có phải cứ phân phối lệch là **bắt buộc** dùng trung vị không? Vì sao?

Đáp án — W02-EX07

Thay 6 bằng -200 làm trung bình giảm mạnh từ khoảng 8.45 xuống -10.27, còn trung vị vẫn 8. Trung bình dùng độ lớn của mọi quan sát; trung vị chủ yếu phụ thuộc thứ hạng. Trung vị phù hợp hơn nếu mục tiêu là "giá trị điển hình" của phần lớn dữ liệu, nhưng không có luật tuyệt đối "phân phối lệch $\rightarrow$ luôn dùng trung vị".

Ví dụ OpenIntro 4e — trung bình 76%, trung vị 80%



Trong ví dụ về **phần trăm thời gian thực sự ghi chép trong lớp**:

- trung vị = **80%**;
- trung bình = **76%**.

Trung bình nhỏ hơn trung vị phù hợp với đuôi kéo về phía các giá trị thấp.

> *Giá trị cực đoan có thể kéo trung bình theo hướng của đuôi.*

Nguồn ví dụ và hình: OpenIntro Statistics 4e, Chương 2 §2.1.

Nội dung chính — Phần 3/5

1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. $\rightarrow$ **Độ phân tán và biểu đồ hộp**
4. Phản biện, bài tập và tình huống tổng hợp
5. Python/pandas và tổng kết

   Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

W02-EX08 [REASONING] — Cùng trung tâm, khác độ phân tán

Tình huống giả định để cô lập ý tưởng độ phân tán:

- A: $7, 8, 9$
- B: $1, 8, 15$

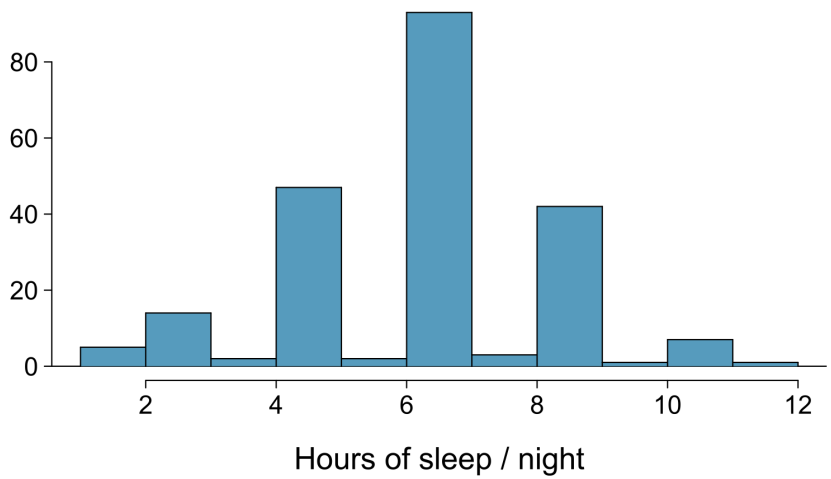
Cả hai đều có trung bình $=$ trung vị $= 8$.

1. Dataset nào phân tán hơn?
2. Range của mỗi bộ dữ liệu là bao nhiêu?
3. Vì sao một số đo trung tâm không đủ để phân biệt A và B?
4. Ta muốn một thước đo độ phân tán có tính chất gì?

Đáp án — W02-EX08

B phân tán hơn. Range A $= 2$; khoảng biến thiên B $= 14$. Hai bộ dữ liệu có cùng trung tâm $= 8$ nên cần một thước đo độ phân tán để phân biệt mức độ trải rộng.

Ví dụ OpenIntro 4e — giấc ngủ của sinh viên



OpenIntro báo cáo cho **217** quan sát:

- trung bình = **6.71 giờ/đêm**;
- phương sai = **4.11 giờ²**;
- SD = **2.03 giờ**.

Độ lệch chuẩn dễ diễn giải hơn phương sai vì trở lại **cùng đơn vị giờ** với dữ liệu.

Nguồn ví dụ và hình: OpenIntro Statistics 4e, Ch. 2 §2.1.

Phương sai và độ lệch chuẩn

Phương sai mẫu

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Độ lệch chuẩn mẫu

$$s = \sqrt{s^2}.$$

Trực giác:

- s nhỏ: các giá trị thường gần trung bình hơn;
- s lớn: phân phối trải rộng hơn;
- s có **cùng đơn vị** với dữ liệu;
- s^2 có đơn vị bình phương.

*Cần hiểu **đại lượng đang đo**, không học thuộc công thức một cách máy móc.*

Tứ phân vị và khoảng tứ phân vị

- Q_1: phân vị 25%;
- trung vị: phân vị 50%;
- Q_3: phân vị 75%.

$$IQR = Q_3 - Q_1.$$

IQR là độ rộng của 50% quan sát ở giữa.

Tóm tắt năm số

$$\min,\ Q_1,\ \text{trung vị},\ Q_3,\ \max.$$

Các cặp thường đi cùng nhau:

- trung bình $\leftrightarrow$ SD;
- trung vị $\leftrightarrow$ IQR.

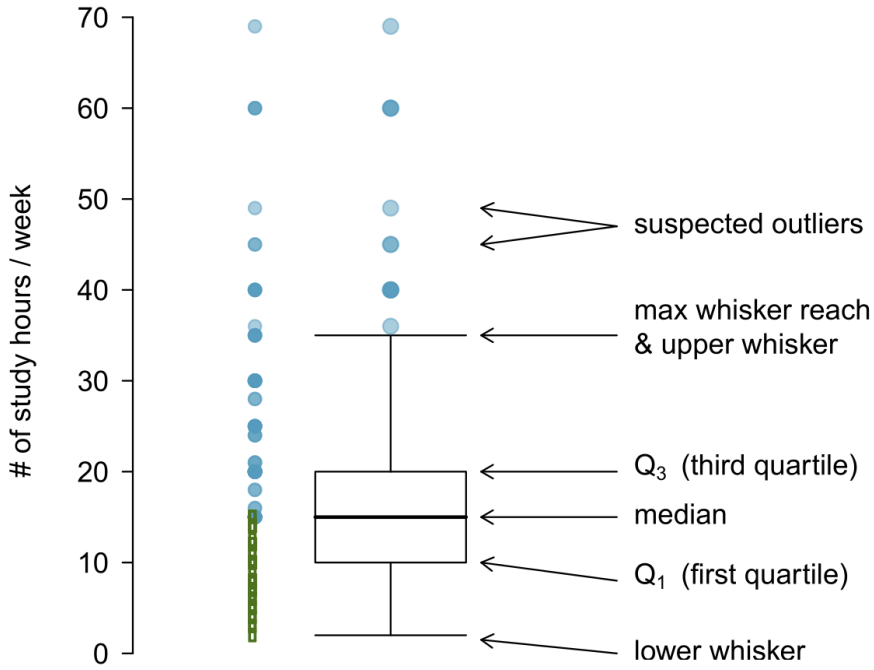
Đây là lựa chọn theo mục tiêu và hình dạng, không phải luật tuyệt đối.

Nội dung chính — Phần 3/5

1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. $\rightarrow$ **Độ phân tán và biểu đồ hộp**
4. Phản biện, bài tập và tình huống tổng hợp
5. Python/pandas và tổng kết

   Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Cấu tạo của biểu đồ hộp



Một biểu đồ hộp làm nổi bật:

- trung vị;
- Q_1, Q_3;
- IQR;
- các râu;
- các điểm bất thường theo quy ước của phần mềm.

*Biểu đồ hộp **nén mạnh hình dạng** của phân phối.*

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

Các râu của biểu đồ hộp không mặc định là nhỏ nhất/lớn nhất

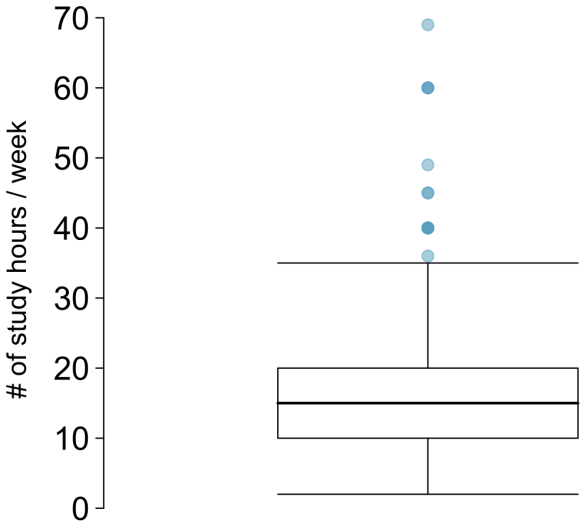
Với quy ước mặc định của Matplotlib (và biểu đồ hộp pandas dựa trên Matplotlib), `whis=1.5`:

$$Q_1 - 1.5IQR, \qquad Q_3 + 1.5IQR$$

là các **hàng rào** tham chiếu; các râu vươn tới quan sát xa nhất vẫn nằm trong phạm vi đó. Các điểm xa hơn có thể được vẽ riêng như *điểm ngoại lai*.

Vì vậy không được đồng nhất "đầu râu" với nhỏ nhất/lớn nhất trong mọi biểu đồ hộp.

W02-EX09 [REASONING] — Biểu đồ hộp cho thấy gì, che mất gì?



1. Chỉ ra trung vị và vùng chứa 50% quan sát giữa.
2. Biểu đồ hộp giúp đọc trung tâm và độ phân tán như thế nào?
3. Nó có thể che mất **số đỉnh, khoảng trống, cụm** hay đặc điểm hình dạng nào?
4. Vì sao nên xem thêm histogram hoặc biểu đồ chấm?

Nguồn hình: OpenIntro Statistics 4e, Chương 2 §2.1.

Đáp án — W02-EX09

Trung vị là đường trong hộp; hộp từ Q_1 đến Q_3 chứa 50% giữa. Biểu đồ hộp giúp so sánh trung tâm/độ phân tán nhanh nhưng có thể che số đỉnh, khoảng trống, cụm quan sát và chi tiết hình dạng. Vì vậy histogram/biểu đồ chấm bổ sung thông tin quan trọng.

W02-Q05 [CORE] — Một tóm tắt không kể toàn bộ câu chuyện

Hai phân phối có thể có cùng trung vị và IQR nhưng hình dạng rất khác nhau không?

Nếu có, hãy nêu một đặc điểm mà biểu đồ hộp có thể bỏ qua nhưng histogram/biểu đồ chấm có thể cho thấy.

Thông điệp:

> ***tóm tắt bằng số + tóm tắt bằng đồ thị*** *thường mạnh hơn mỗi loại đứng riêng.*

Đáp án — W02-Q05

Có. Hai phân phối có thể có cùng trung vị và IQR nhưng khác số mốt, khoảng trống hoặc hành vi ở đuôi phân phối.

Nội dung chính — Phần 4/5

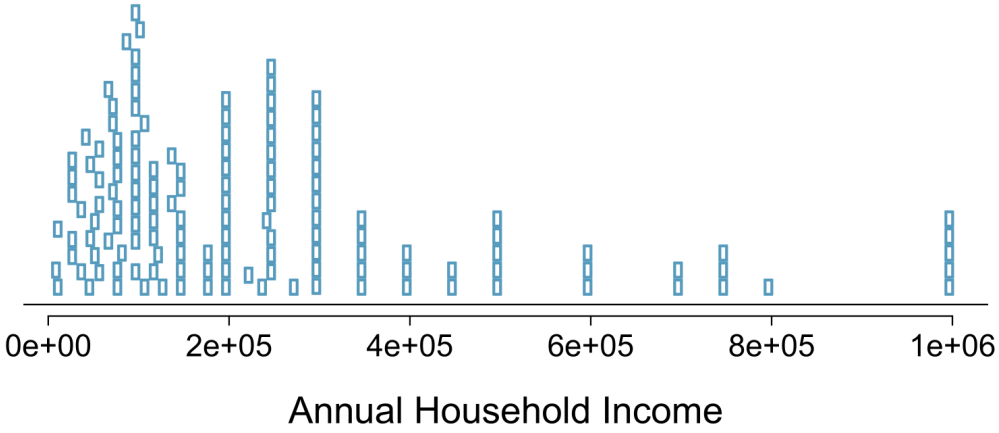
1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. $\rightarrow$ **Phản biện, bài tập và tình huống tổng hợp**
5. Python/pandas và tổng kết

   Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Phản biện và giải quyết vấn đề

Không chỉ "tính theo công thức": hãy ***chọn tóm tắt, phản biện, xây phản ví dụ và hòa giải các kết luận tưởng như xung đột****.*

Giá trị cực đoan tác động không đều



OpenIntro minh họa khi đẩy một quan sát thu nhập lên **10 triệu USD**:

- trung bình và SD thay đổi mạnh;
- trung vị và IQR thay đổi ít hơn.

*Đây là **tính bền vững**, không phải quy tắc "trung vị/IQR luôn tốt hơn".*

Nguồn hình và ý tưởng: OpenIntro Statistics 4e, Chương 2 §2.1.

Chọn tóm tắt theo mục tiêu, không theo khẩu quyết

Một quy tắc kinh nghiệm hữu ích:

- phân phối gần đối xứng, không có giá trị cực đoan chi phối $\rightarrow$ trung bình/SD thường dễ diễn giải;
- phân phối lệch mạnh hoặc có giá trị cực đoan $\rightarrow$ trung vị/IQR thường bền vững hơn.

Nhưng lựa chọn cuối cùng còn phụ thuộc **mục tiêu**:

- cần tổng giá trị/bình quân trên toàn bộ đơn vị? trung bình có thể chính là đại lượng quan tâm;
- cần "một quan sát điển hình"? trung vị có thể phù hợp hơn.

Không dùng quy tắc máy móc "phân phối lệch $\rightarrow$ LUÔN dùng trung vị".

W02-CH02 [CHALLENGE] — Khi một con số "đúng" nhưng gây hiểu nhầm

Dùng dãy STAT20:

$$8, 11, 7, 7, 8, 11, 9, 6, 10, 7, 9.$$

Sau đó thay **6** bằng -200.
Hãy nghĩ trước:

> *Một quan sát cực đoan tác động như nhau lên mọi tóm tắt hay không?*

1. So sánh trung bình, trung vị, SD, IQR trước/sau thay đổi.
2. Tóm tắt nào bền vững hơn?
3. Báo cáo chỉ viết "trung bình $=$ -10.27" đã che điều gì?
4. Đề xuất **một cặp tóm tắt bằng số** và **một đồ thị**.
5. Phản biện: "Trung bình âm chứng tỏ phần lớn dữ liệu là số âm."

Đáp án — W02-CH02

Dữ liệu gốc: trung bình ≈ 8.455, trung vị $= 8$, SD mẫu ≈ 1.695, IQR $= 2.5$.

Thay 6 bằng -200: trung bình ≈ -10.273, trung vị $= 8$, SD mẫu ≈ 62.943, IQR $= 2.5$.

Trung vị/IQR bền vững hơn trước thay đổi cực đoan này; trung bình/SD phản ứng mạnh. Chỉ báo "trung bình = -10.27" che việc **10/11** quan sát vẫn nằm từ 7 đến 11.

> *Với mục tiêu "giá trị điển hình", nên báo **trung vị + IQR** và kèm đồ thị để lộ điểm -200.*

W02-CH01 [CHALLENGE] — Chọn mẫu số trong bảng lỗi kỹ thuật

Tình huống giả định. Một đợt kiểm thử ghi nhận:

Loại thiết bị	Không lỗi	Lỗi tạm thời	Lỗi nghiêm trọng	Tổng
A	72	18	10	100
B	150	30	20	200
Tổng	**222**	**48**	**30**	**300**

Không nêu tên công thức; hãy tự chọn mẫu số phù hợp:

1. Trong số thiết bị **A**, bao nhiêu phần gặp lỗi nghiêm trọng?
2. Trong số **mọi lỗi nghiêm trọng**, bao nhiêu phần thuộc loại A?
3. Trong **toàn bộ 300 thiết bị**, bao nhiêu phần vừa là A vừa lỗi nghiêm trọng?
4. Một kỹ sư nói: "B nguy hiểm gấp đôi A vì 20 lỗi nghiêm trọng > 10." Phản biện.

Đáp án — W02-CH01

1. Trong A: $10/100 = 10\%$.
2. Trong mọi lỗi nghiêm trọng: $10/30 \approx 33.3\%$ là A.
3. Trên toàn bộ: $10/300 \approx 3.3\%$ vừa A vừa lỗi nghiêm trọng.
4. So sánh 20 với 10 dùng **số đếm thô** trong hai nhóm có kích thước khác nhau. Tỉ lệ lỗi nghiêm trọng đều bằng 10% ở A và B, nên bảng này không ủng hộ kết luận "B có tỉ lệ lỗi gấp đôi A".

Cùng tử số hoặc cùng ô có thể trả lời nhiều câu hỏi khác nhau khi mẫu số thay đổi.

W02-CH03 [DESIGN] — Chứng minh hoặc bác bỏ: trung bình = trung vị ⇒ đối xứng

Xét mệnh đề:

> *"Nếu một bộ dữ liệu có trung bình bằng trung vị thì phân phối phải đối xứng."*

Chứng minh hoặc bác bỏ. Nếu bác bỏ, hãy **tự xây một bộ dữ liệu gồm 5 giá trị** có trung bình = trung vị nhưng không đối xứng, rồi giải thích rõ tiêu chí nào làm nó không đối xứng.

Không được trả lời chỉ bằng một hình dung mơ hồ về skewness; cần một phản ví dụ kiểm tra được bằng số.

Đáp án — W02-CH03

Mệnh đề **sai**. Phản ví dụ: $(-4, -1, 0, 2, 3)$. Trung bình $= 0$ vì tổng bằng 0; trung vị $= 0$. Nhưng bộ dữ liệu không đối xứng quanh 0: chẳng hạn -4 không có đối tác $+4$, và các khoảng hai phía không ghép cặp đối xứng. Trung bình $=$ trung vị không đủ để suy ra hình dạng.

W02-CH04 [DESIGN] — Cùng trung bình và SD, khác hẳn hình dạng

Bác bỏ mệnh đề:

> *"Hai bộ dữ liệu có cùng trung bình và cùng độ lệch chuẩn thì về cơ bản là giống nhau."*

Hãy **tự xây hai bộ dữ liệu nhỏ** thỏa:

1. cùng số quan sát;
2. cùng trung bình;
3. cùng SD mẫu;
4. hình dạng/phân bố giá trị rõ ràng khác nhau.

Không được chỉ đổi thứ tự các phần tử. Sau khi xây, hãy giải thích **thông tin nào trung bình và SD đã làm mất**.

Đáp án — W02-CH04

Một phản ví dụ với 6 quan sát:

$$A = (-1, -1, -1, 1, 1, 1), \qquad B = (-2, 0, 0, 0, 1, 1).$$

Cả hai đều có

$$\bar{x} = 0, \qquad \sum (x_i - \bar{x})^2 = 6, \qquad s = \sqrt{6/5}.$$

Nhưng A đối xứng, chỉ có hai mức -1 và 1; còn B tập trung ba quan sát tại 0 và có đuôi trái đến -2. Trung bình + SD **không xác định duy nhất hình dạng** của phân phối.

W02-CH05 [CHALLENGE] — Tóm tắt thay đổi thế nào khi đổi thang đo?

Cho dữ liệu $X = (x_1, \dots, x_n)$ và biến đổi

$$Y = aX + b, \qquad a \neq 0.$$

Không tra công thức. Hãy suy luận tác động lên:

1. trung bình;
2. trung vị;
3. SD mẫu;
4. IQR.

Sau đó trả lời:

- tại sao SD và IQR dùng $|a|$ chứ không phải a?
- nếu $a < 0$, điều gì xảy ra với thứ tự các quan sát?

Đáp án — W02-CH05

Trung bình

$$\bar{y} = \frac{1}{n}\sum(ax_i + b) = a\bar{x} + b.$$

Trung vị

Một phép biến đổi affine đơn điệu chỉ đổi vị trí theo thang đo; với $a < 0$ thứ tự bị đảo, nhưng giá trị giữa vẫn biến đổi thành

$$\mathrm{Med}(Y) = a\,\mathrm{Med}(X) + b.$$

Độ lệch chuẩn

$$\begin{aligned} s_Y^2 &= \frac{1}{n-1}\sum[a(x_i - \bar{x})]^2 \\ &= a^2 s_X^2, \end{aligned}$$

nên $s_Y = |a| s_X$.

Khoảng tứ phân vị

Khoảng cách không thể âm, nên

$$IQR_Y = |a| IQR_X.$$

Hằng số b chỉ **dịch chuyển vị trí**; hệ số a vừa co/giãn, vừa đảo trật tự nếu âm.

W02-CH06 [DESIGN] — Xây dữ liệu mà trung bình mô tả "điển hình" rất kém

Hãy tự xây một bộ dữ liệu gồm **7 giá trị** sao cho:

- ít nhất 5 giá trị nằm trong khoảng $[9, 11]$;
- nhưng trung bình của cả bộ dữ liệu **nhỏ hơn 0**.

Sau đó:

1. tính trung bình và trung vị;
2. giải thích vì sao trung bình là một mô tả "điển hình" kém trong ví dụ của bạn;
3. đề xuất một tóm tắt bằng số và một đồ thị phù hợp hơn.

Đáp án — W02-CH06

Một cách xây:

$$9, 9, 10, 10, 10, 11, -100.$$

Có 6/7 giá trị nằm trong $[9, 11]$, nhưng

$$\bar{x} = \frac{-41}{7} \approx -5.86, \qquad \text{Med} = 10.$$

Một quan sát cực đoan kéo trung bình ra xa cụm chính. Nếu mục tiêu là mô tả một quan sát điển hình, **trung vị + IQR** cùng histogram/biểu đồ chấm sẽ trung thực hơn về cấu trúc dữ liệu.

Nội dung chính — Phần 4/5

1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. $\rightarrow$ **Phản biện, bài tập và tình huống tổng hợp**
5. Python/pandas và tổng kết

   Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Bài tập cuối chương — chọn lọc

Bốn bài sau được **chuyển thể** (không chép nguyên văn) từ bài tập cuối chương của hai sách OpenIntro:

- OpenIntro Statistics 4e, Chương 2;
- Introduction to Modern Statistics 2e, Chương 4–5.

Mục tiêu là luyện **statistical thinking**, không tăng tải lập trình.

W02-EX10 [REASONING] — OpenIntro 4e: bài kiểm tra bù

Trong một lớp 25 sinh viên, 24 bạn thi cùng ngày. Điểm của 24 bạn có:

- trung bình $=$ **74**;
- độ lệch chuẩn mẫu $=$ **8.9**.

Bạn còn lại thi bù và được **64** điểm.

1. Trung bình mới tăng hay giảm?
2. Tính trung bình mới.
3. Sample SD mới tăng hay giảm một chút? Giải thích trực giác.

Bài tập chuyển thể từ OpenIntro Statistics 4e, Chương 2, Bài tập 27 cuối chương "Make-up exam".

Đáp án — W02-EX10

Trung bình mới:

$$\bar{x}_{\text{new}} = \frac{24(74) + 64}{25} = 73.6.$$

Tổng bình phương cũ:

$$SS_{\text{old}} = 23(8.9)^2 = 1821.83.$$

Hai phần tăng thêm:

$$24(74 - 73.6)^2 = 3.84,$$
$$(64 - 73.6)^2 = 92.16.$$

Do đó

$$s_{\text{new}} = \sqrt{\frac{1821.83 + 3.84 + 92.16}{24}} \approx 8.94.$$

*SD chỉ tăng nhẹ vì điểm mới chỉ chiếm **1/25** lớp.*

W02-EX11 [REASONING] — OpenIntro 4e: điểm thi và biểu đồ hộp

20 điểm thi đã sắp tăng dần:
57, 66, 69, 71, 72, 73, 74, 77, 78, 78, 79, 79, 81, 81, 82, 83, 83, 88, 89, 94
Tóm tắt năm số:

$$57,\ 72.5,\ 78.5,\ 82.5,\ 94.$$

1. Tính IQR.
2. Tính hai hàng rào 1.5-IQR.
3. Điểm nào là ngoại lai tiềm năng?
4. Râu dưới dừng ở 57 hay 66? Vì sao?

Chuyển thể từ OpenIntro Statistics 4e, Chương 2, bài “Stats scores”.

Đáp án — W02-EX11

$IQR = 82.5 - 72.5 = 10$. Hàng rào: $72.5 - 15 = 57.5$ và $82.5 + 15 = 97.5$. Điểm 57 nằm dưới hàng rào dưới nên là điểm ngoại lai tiềm năng; 94 không vượt hàng rào trên. Với quy ước 1.5-IQR, râu dưới dừng ở **66**, còn 57 được vẽ riêng như điểm ngoại lai.

W02-EX12 [REASONING] — IMS2e: quan điểm về nhập cư

Phản hồi	Conservative	Liberal	Moderate	Tổng
Apply for citizenship	57	101	120	278
Guest worker	121	28	113	262
Leave the country	179	45	126	350
Not sure	15	1	4	20
Tổng	**372**	**175**	**363**	**910**

1. Tỉ lệ `Conservative` trong toàn mẫu?
2. Tỉ lệ chọn `Apply for citizenship` trong toàn mẫu?
3. Trong từng nhóm `ideology`, tỉ lệ chọn lựa chọn này là bao nhiêu?
4. Các tỉ lệ có điều kiện cho thấy mối liên hệ mô tả nào?

Chuyển thể từ IMS2e, Chương 4, bài “Views on immigration”.

Đáp án — W02-EX12

- `Conservative`: $372/910 \approx 40.9\%$.
- `Apply for citizenship` toàn mẫu: $278/910 \approx 30.5\%$.
- Theo `ideology`: conservative $57/372 \approx 15.3\%$; liberal $101/175 \approx 57.7\%$; moderate $120/363 \approx 33.1\%$.

Các tỉ lệ có điều kiện khác nhau rõ rệt, nên có **mối liên hệ mô tả** giữa `ideology` và phản hồi; bảng này không tự nó cho phép kết luận nhân quả.

W02-EX13 [REASONING] — IMS2e: chọn tóm tắt theo hình dạng

Với mỗi biến sau, dự đoán hình dạng và chọn cặp tóm tắt phù hợp hơn để mô tả **giá trị điển hình + độ phân tán**:

1. số thú cưng trong một hộ gia đình;
2. chiều cao nam trưởng thành;
3. điểm của một bài thi rất dễ.

Chọn giữa **trung bình + SD** và **trung vị + IQR**, rồi giải thích bằng hình dạng/tính bền vững thay vì học thuộc quy tắc.

Bài tập chuyển thể từ Introduction to Modern Statistics 2e, Chương 5, Bài tập 15 “Distributions and appropriate statistics”.

Đáp án — W02-EX13

Số thú cưng/hộ thường **lệch phải** $\rightarrow$ trung vị + IQR thường hữu ích cho giá trị điển hình/độ phân tán. Chiều cao nam trưởng thành thường gần **đối xứng** $\rightarrow$ trung bình + SD hợp lý. Điểm một bài thi rất dễ thường **lệch trái** vì nhiều điểm cao và một đuôi về phía thấp $\rightarrow$ trung vị + IQR thường bền vững hơn. Đây là quy tắc kinh nghiệm, không phải luật tuyệt đối.

Nội dung chính — Phần 4/5

1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. $\rightarrow$ **Phản biện, bài tập và tình huống tổng hợp**
5. Python/pandas và tổng kết

Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

W02-CASE01 [CHALLENGE] — Palmer Penguins (1/3)

Nguồn STAT20 cho bảng `species × island`:

Loài	Biscoe	Dream	Torgersen
Adelie	44	55	47
Chinstrap	0	68	0
Gentoo	119	0	0

Và trong phần dữ liệu số, STAT20 báo cáo cho `body_mass_g`:

- trung vị = **4050 g**;
- IQR = **1225 g**;
- phân phối toàn bộ được mô tả là **lệch phải**.

Các số liệu và mô tả đều từ STAT20 tiếng Việt, Chương 2; không phải dữ liệu tự tạo.

Palmer Penguins — lập luận với dữ liệu phân loại (2/3)

1. `species`, `island`, `body_mass_g` thuộc loại biến nào?
2. Chọn tóm tắt đầu tiên cho từng biến/cặp biến.
3. Diễn giải ô 55 trong bảng.
4. Tính tỉ lệ Adelie ở Dream trên **toàn bộ 333** chim.
5. Tính tỉ lệ Adelie ở Dream **trong số Adelie**.
6. Tính tỉ lệ Adelie **trong số chim ở Dream**.
7. Đánh giá mối liên hệ giữa `species` và `island`.

Đáp án — W02-CASE01 — dữ liệu phân loại

1. `species`, `island`: phân loại; `body_mass_g`: số.
2. `species`/`island`: số đếm/tỉ lệ; `species × island`: bảng liên hợp + tỉ lệ có điều kiện; `body_mass_g`: histogram/biểu đồ chấm + trung tâm/độ phân tán.
3. Ô $55 = 55$ chim Adelie ở Dream.
4. $55/333 \approx 16.5\%$ toàn bộ chim là Adelie ở Dream.
5. $55/146 \approx 37.7\%$ Adelie ở Dream.
6. $55/123 \approx 44.7\%$ chim ở Dream là Adelie.
7. `species` và `island` có mối liên hệ mô tả mạnh vì các phân phối có điều kiện thay đổi rõ.

Palmer Penguins — lập luận với dữ liệu số và phản biện (3/3)

8. Viết mô tả ngắn cho `body_mass_g` dựa trên hình dạng + trung tâm + độ phân tán đã cho.
9. Trung bình hay trung vị phù hợp hơn cho "khối lượng cơ thể điển hình"? Giải thích.
10. SD hay IQR phù hợp hơn cho độ phân tán trong bối cảnh trên? Giải thích.
11. `pd.crosstab(..., normalize="index")` trả lời câu hỏi nào của tình huống này?
12. Phản biện: "Loài chim cánh cụt quyết định hòn đảo mà nó sống."

Đáp án — W02-CASE01 — dữ liệu số và phản biện

8. `body_mass_g` được nguồn mô tả lệch phải; trung vị = 4050 g, IQR = 1225 g.
9. Với mục tiêu "khối lượng cơ thể điển hình", trung vị là lựa chọn bền vững hợp lý; trung bình không vì thế mà "sai".
10. IQR ghép hợp lý với trung vị để mô tả 50% giữa.
11. `normalize="index"` trả lời phân bố island trong từng species.
12. "Loài quyết định hòn đảo" là khẳng định nhân quả; bảng chỉ cho mối liên hệ.

Nội dung chính — Phần 5/5

1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. Phản biện, bài tập và tình huống tổng hợp
5. $\rightarrow$ **Python/pandas và tổng kết**

   Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Minh họa ngắn bằng Python/pandas

Mục tiêu: **kiểm chứng một câu hỏi thống kê** bằng vài lệnh ngắn, không cần học nhiều cú pháp.

Giả sử `penguins` đã được nạp vào một `DataFrame`.

```
import pandas as pd

penguins["species"].value_counts()
penguins["species"].value_counts(normalize=True)
pd.crosstab(penguins["species"], penguins["island"], margins=T
```

Trước khi chạy: dự đoán kết quả nào là số đếm, kết quả nào là tỉ lệ, và `margins=True` sẽ thêm những tổng nào.

Đáp án — Minh họa Python/pandas

Các lệnh đầu tiên trả lời ba câu hỏi khác nhau:

- `penguins["species"].value_counts()` cho **số đếm** của từng loài;
- `value_counts(normalize=True)` cho **tỉ lệ** của từng loài trên toàn bộ quan sát hợp lệ;
- `pd.crosstab(..., margins=True)` tạo bảng liên hợp và thêm **tổng hàng, tổng cột, tổng chung**.

Điểm cần đọc trước mã lệnh là: mỗi kết quả đang dùng **mẫu số nào** và trả lời **câu hỏi thống kê nào**.

W02-PY01 [COMPUTE] — Mẫu số nằm trong mã lệnh ở đâu?

```
row_prop = pd.crosstab(
    penguins["species"], penguins["island"], normalize="index"
)
col_prop = pd.crosstab(
    penguins["species"], penguins["island"], normalize="columns"
)
```

1. Bảng nào trả lời "đảo trong từng loài"?
2. Bảng nào trả lời "loài trên từng đảo"?
3. Trong mỗi bảng, chiều nào cộng thành 1?
4. Không nhìn tài liệu hướng dẫn: hãy suy ra ý nghĩa của `"index"` và `"columns"` từ **câu hỏi thống kê**.

Đáp án — W02-PY01

`value_counts()` trả số đếm; `normalize=True` chia số đếm cho tổng số quan sát hợp lệ để thành tỉ lệ. Một ô `crosstab` là số quan sát ở một tổ hợp hai mức; `margins=True` thêm tổng hàng/cột và tổng chung. Với `crosstab`, `normalize="index"` $\rightarrow$ mỗi **hàng** tổng 1, trả lời phân bố `island` trong từng `species`; `normalize="columns"` $\rightarrow$ mỗi **cột** tổng 1, trả lời phân bố `species` trên từng `island`.

W02-PY05 [COMPUTE] — Kiểm chứng biến đổi thang đo

```
x = pd.Series([8, 11, 7, 7, 8, 11, 9, 6, 10, 7, 9])
y = 3*x + 5

for z in [x, y]:
    print(
        z.mean(),
        z.median(),
        z.std(),
        z.quantile(.75) - z.quantile(.25)
    )
```

Trước khi chạy mã, hãy dự đoán bốn tóm tắt của $Y = 3X + 5$ từ bốn tóm tắt của X.

Sau khi chạy, kiểm tra xem:

- vị trí có tăng thêm 5 rồi nhân theo hệ số 3 không;
- độ phân tán có tăng gấp 3 không.

Toán học trước, computation sau: *mã lệnh chỉ dùng để kiểm chứng lập luận.*

Đáp án — W02-PY05

Với X:

$$\bar{x} \approx 8.455, \quad \mathrm{Med}(X) = 8, \quad s_X \approx 1.695, \quad IQR_X = 2.5.$$

Với $Y = 3X + 5$:

$$\bar{y} \approx 30.364, \quad \mathrm{Med}(Y) = 29, \quad s_Y \approx 5.085, \quad IQR_Y = 7.5.$$

Đúng như suy luận: hai đại lượng vị trí biến đổi theo $3(\cdot) + 5$, còn SD và IQR chỉ bị nhân bởi 3. Mã lệnh **xác nhận**, không thay thế lập luận.

Nội dung chính — Phần 5/5

1. Dữ liệu phân loại
2. Dữ liệu số: hình dạng và trung tâm
3. Độ phân tán và biểu đồ hộp
4. Phản biện, bài tập và tình huống tổng hợp
5. $\rightarrow$ **Python/pandas và tổng kết**

   Câu hỏi xuyên suốt: ***Ta đang tóm tắt biến nào, để trả lời câu hỏi nào, và tóm tắt đó che giấu điều gì?***

Sơ đồ khái niệm — chọn tóm tắt từ câu hỏi

Bắt đầu từ câu hỏi và loại biến.

Biến phân loại

Số đếm / tỉ lệ
→ bảng liên hợp
→ phân phối có điều kiện
→ mối liên hệ mô tả

Câu hỏi then chốt: ***mẫu số là ai?***

Biến số

Đồ thị phân phối
→ hình dạng
→ trung tâm + độ phân tán
→ giá trị bất thường

Câu hỏi then chốt: ***tóm tắt nào phù hợp và bền vững?***

Mẫu số, hình dạng và mục tiêu phân tích đều là một phần của câu trả lời.

W02-Q06 [CORE] — Câu hỏi kết thúc

Một bạn nói:

> *"Tóm tắt dữ liệu chỉ là chọn một hàm trong phần mềm."*

Hãy viết lại phát biểu này thành một câu đúng hơn, có nhắc đến ít nhất **hai** trong các ý sau:

- loại biến;
- câu hỏi thống kê;
- mẫu số;
- tóm tắt bằng đồ thị so với tóm tắt bằng số;
- thông tin bị lược bỏ;
- **hàm mất mát / mục tiêu** khiến một tóm tắt trở nên hợp lý;
- diễn giải theo ngữ cảnh.

Đáp án — W02-Q06

Một cách viết tốt: “Tóm tắt dữ liệu là chọn bảng, biểu đồ hoặc đặc trưng số phù hợp với **loại biến và câu hỏi thống kê**, xác định đúng **mẫu số** khi dùng tỉ lệ, hiểu thông tin nào bị lược bỏ và diễn giải kết quả trong ngữ cảnh.”

Những điều quan trọng cần nhớ

Dữ liệu phân loại

- Loại biến + câu hỏi quyết định cách tóm tắt.
- Với tỉ lệ, **mẫu số là một phần của câu hỏi**.
- Tỉ lệ toàn bộ, theo hàng và theo cột có ý nghĩa khác nhau.
- Mối liên hệ mô tả **không tự động là quan hệ nhân quả**.

Cảnh giác: một tóm tắt đúng số học vẫn có thể gây hiểu nhầm nếu sai mẫu số hoặc che cấu trúc phân nhóm.

Dữ liệu số

- Mô tả **hình dạng – trung tâm – độ phân tán – giá trị bất thường**.
- Kết hợp đặc trưng số với đồ thị.
- Trung bình/SD nhạy với cực trị hơn trung vị/IQR.
- **Cùng trung bình và SD không có nghĩa cùng phân phối.**
- Với $Y = aX + b$: vị trí biến đổi theo $a(\cdot) + b$, còn SD/IQR nhân $|a|$.
- Trung bình tối thiểu hóa mất mát bình phương: $\bar{x} = \arg\min_c \sum_i (x_i - c)^2$.

Công cụ: Python/pandas dùng để kiểm chứng; lập luận thống kê phải có trước mã lệnh.

Chuẩn bị cho Tuần 03

Tuần 02 tập trung vào câu hỏi **"nên dùng tóm tắt nào và tóm tắt đó nói gì?"**

Tuần 03 sẽ đi sâu vào cách xây dựng biểu đồ từ:

- **dữ liệu**;
- **thuộc tính hình ảnh**;
- **hình học biểu diễn**;

và cách **điều kiện hóa dữ liệu** để so sánh các nhóm một cách có hệ thống.