Tuần 03 — Tóm tắt dữ liệu (2/3)

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Khoa Công nghệ Thông tin (VNU-UET-FIT)

Nguồn và học liệu tham khảo

Bài giảng được **biên soạn mới** cho học phần **UET.MAT1052 — Xác suất thống kê**, dựa trên đề cương chính thức và tham khảo:

- **STAT 20**, University of California, Berkeley;
- Freedman, Pisani & Purves, *Statistics*, 4th ed.;
- Diez, Çetinkaya-Rundel & Barr, *OpenIntro Statistics*, 4th ed.;
- Çetinkaya-Rundel & Hardin, *Introduction to Modern Statistics*, 2nd ed.

Nguồn và giấy phép.
Tài nguyên được tái sử dụng trực tiếp từ nguồn bên ngoài, nếu có, được ghi nguồn và giấy phép tại vị trí tương ứng hoặc trong phần tài liệu tham khảo.

Nội dung chính

1. **Ngữ pháp đồ họa** — dữ liệu → thuộc tính hình ảnh → dạng hình học
2. **Số ca sinh theo thời gian** — cùng dữ liệu, thay đổi cách biểu diễn
3. **Python và Ngữ pháp đồ họa** — đọc và xây dựng biểu đồ theo lớp
4. **Điều kiện hóa** — lọc để tập trung vào quan sát quan tâm
5. **Chuỗi xử lý và phép toán theo nhóm** — từ câu hỏi tới tóm tắt có cấu trúc
6. **Thử thách và tổng kết** — khi biểu đồ hay tóm tắt gộp che mất cấu trúc

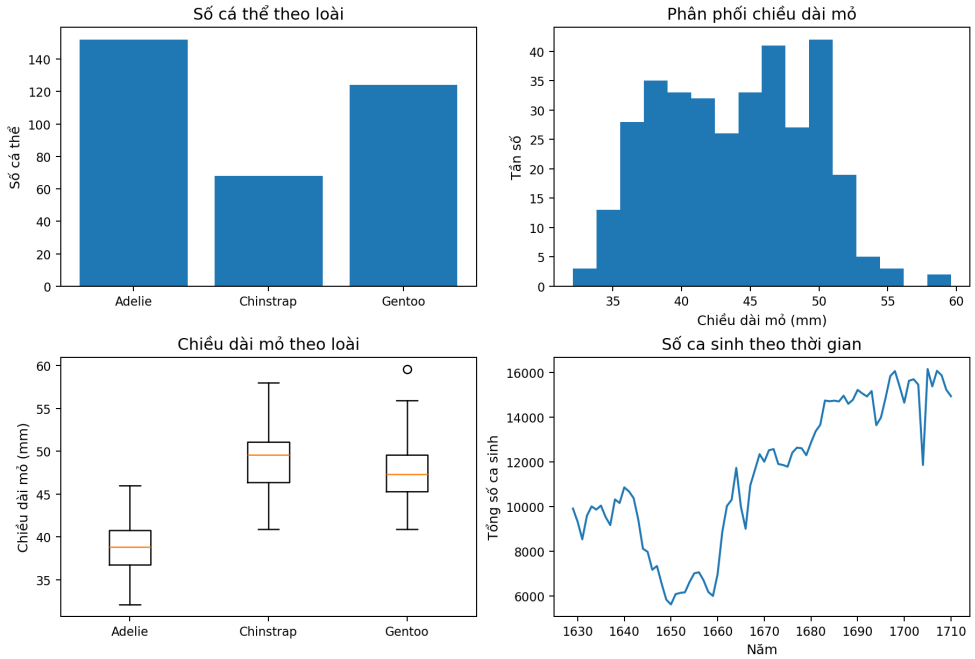
Từ "chọn biểu đồ" đến "xây dựng biểu đồ"

Tuần trước, ta đã dùng nhiều dạng trực quan:

- biểu đồ cột;
- biểu đồ tần suất (histogram);
- biểu đồ hộp;
- biểu đồ điểm.

Câu hỏi mới:

Có một cấu trúc chung nào đứng sau các biểu đồ rất khác nhau này không?



Dữ liệu và ý tưởng biểu diễn chuyển thể từ STAT20; hình được tái dựng để Việt hóa nhãn hiển thị.

W03-Q01 Mức độ 1 — Điều gì lặp lại?

Quan sát bộ sưu tập biểu đồ ở slide trước. Hãy nêu **ba loại quyết định** mà người phân tích phải đưa ra trước khi có một biểu đồ hoàn chỉnh.

Không cần gọi đúng thuật ngữ ngay từ đầu. Hãy mô tả bằng lời.

W03-Q01 — Đáp án

Ba quyết định cốt lõi là:

1. **Dùng dữ liệu nào?** Biến nào phải có trong dữ liệu?
2. **Mã hóa biến bằng dấu hiệu trực quan nào?** Ví dụ: vị trí trên trục x, trục y, màu, kích thước.
3. **Biểu diễn quan sát bằng dạng hình học nào?** Ví dụ: điểm, đường, cột, biểu đồ hộp.

Đó chính là trực giác dẫn tới **Ngữ pháp đồ họa**.

Nội dung chính

1. **Ngữ pháp đồ họa** — dữ liệu $\rightarrow$ thuộc tính hình ảnh $\rightarrow$ dạng hình học
2. Số ca sinh theo thời gian
3. Python và Ngữ pháp đồ họa
4. Điều kiện hóa
5. Chuỗi xử lý và phép toán theo nhóm
6. Thử thách và tổng kết

Phần 1

Ngữ pháp đồ họa

Một biểu đồ có thể được "phân tích cú pháp"

Giống như ngữ pháp mô tả cấu trúc của câu, **Ngữ pháp đồ họa** mô tả cấu trúc của biểu đồ thống kê.

Một phiên bản nhập môn hữu ích:

$$\begin{aligned}\text{Biểu đồ} = \text{Dữ liệu} + \text{Ánh xạ} + \text{Dạng hình học} \\ + \text{Nhóm / ô phân nhỏ (khi cần).}\end{aligned}$$

Ba thành phần đầu tạo nên lõi của biểu đồ; **nhóm / ô phân nhỏ (faceting)** là cách có hệ thống để biểu diễn cấu trúc theo một biến thứ ba.

Các lựa chọn này không phải "trang trí". Chúng quyết định **thông tin nào được giữ lại, thông tin nào có thể bị che**, và **thông điệp nào được nhấn mạnh**.

Khung khái niệm theo STAT20, dựa trên *Grammar of Graphics* của Leland Wilkinson.

Thành phần 1 — Dữ liệu

Trước khi chọn màu hay loại biểu đồ, phải hỏi:

> ***Dữ liệu hiện có có chứa những biến cần thiết để trả lời câu hỏi không?***

Ví dụ, để biểu diễn kích thước mỏ chim cánh cụt theo loài, ta cần tối thiểu:

Biến	Ý nghĩa
`bill_length_mm`	chiều dài mỏ, mm
`bill_depth_mm`	độ sâu mỏ, mm
`species`	loài

Một biểu đồ không thể "bổ sung" một biến mà dữ liệu không hề quan sát hay suy ra hợp lệ.

Thành phần 2 — Thuộc tính hình ảnh

Ánh xạ một biến nghĩa là để biến đó điều khiển một đặc trưng trực quan.

Với biểu đồ chim cánh cụt:

- `bill_length_mm` $\rightarrow$ vị trí trên trục x;
- `bill_depth_mm` $\rightarrow$ vị trí trên trục y;
- `species` $\rightarrow$ màu.

Các thuộc tính thường gặp:

`x`, `y`, `color`, `alpha`, `size`, `shape`, `fill`.

Không phải thuộc tính nào cũng phù hợp với mọi loại biến hoặc mọi câu hỏi.

Thành phần 3 — Dạng hình học

Dạng hình học quyết định quan sát được thể hiện bằng dấu hiệu nào.

Dạng hình học	Nhấn mạnh
điểm	từng quan sát; quan hệ hai biến số
đường	diễn biến theo thứ tự có ý nghĩa
cột	số đếm/tỉ lệ theo mức phân loại
biểu đồ tần suất	hình dạng phân phối một biến số
biểu đồ hộp	trung tâm và độ phân tán theo nhóm

*Cùng dữ liệu và cùng ánh xạ có thể cho **thông điệp khác** khi thay dạng hình học.*

Thành phần 4 — Nhóm và ô phân nhỏ

Khi một biến thứ ba có ý nghĩa, ta có thể dùng nó để:

- **nhóm** quan sát bằng màu / hình dạng / kiểu nét;
- hoặc chia thành các **ô phân nhỏ (facets)** để xem từng nhóm riêng.

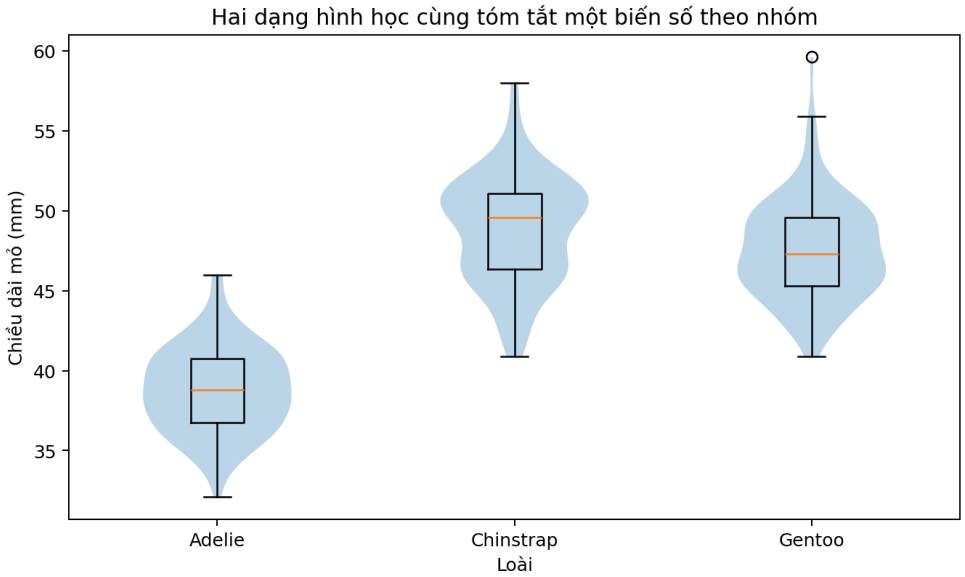
Ví dụ với `penguins`:

$$\text{hai số đo mỏ} \quad + \quad \text{nhóm theo 'species'}$$

giúp trả lời một câu hỏi khác với biểu đồ gộp tất cả cá thể.

*Nhóm / faceting là một cách trực quan của **điều kiện hóa**: xem cấu trúc của dữ liệu trong từng mức của một biến phân nhóm.*

Chọn dạng hình học theo câu hỏi

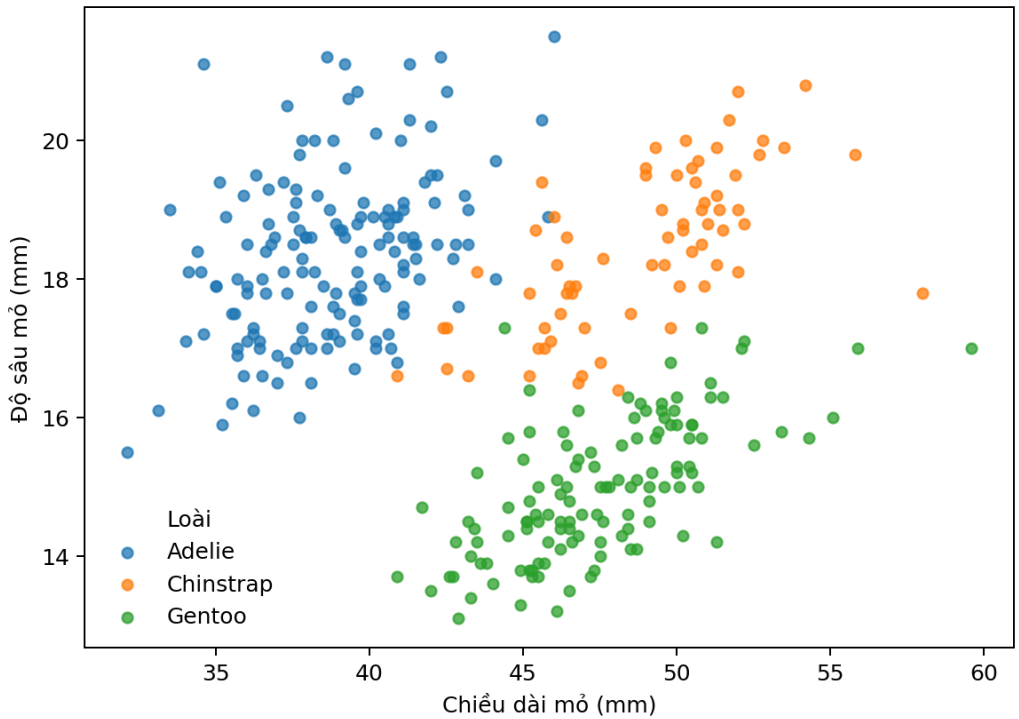


Cùng thang đo, các dạng tóm tắt khác nhau giúp so sánh **phân phối giữa các nhóm** theo những cách khác nhau.

> *Chọn dạng hình học theo **câu hỏi** và **đơn vị quan sát**, không theo thói quen.*

Bổ sung cách so sánh phân phối theo nhóm từ *Introduction to Modern Statistics* 2e, Chương 4–5.

W03-EX01 Mức độ 2 — Phân tích cú pháp một biểu đồ



Với biểu đồ bên trái:

1. Dữ liệu cần chứa những biến nào?
2. Biến nào được ánh xạ tới x, y và màu?
3. Dạng hình học là gì?
4. Nếu bỏ `species`, thông tin nào biến mất?
5. **Tình huống giả định:** bản trích dữ liệu chỉ có ba biến trên. Có thể dùng nó để so sánh theo `island` không?

W03-EX01 — Đáp án

1. Cần `bill_length_mm`, `bill_depth_mm`, `species`.
2. `bill_length_mm` $\rightarrow$ x; `bill_depth_mm` $\rightarrow$ y; `species` $\rightarrow$ màu.
3. Dạng hình học là **điểm**.
4. Nếu bỏ `species`, ta vẫn thấy các cặp chiều dài–độ sâu mỏ nhưng không còn biết các cụm điểm tương ứng với loài nào.
5. **Không.** Nếu `island` không có trong bản trích dữ liệu, biểu đồ không thể mã hóa biến đó nếu ta chưa bổ sung dữ liệu hợp lệ.

Điểm quan trọng: một ánh xạ mới không chỉ "đổi màu"; nó có thể làm lộ **cấu trúc phân nhóm** mà biểu đồ hai biến ban đầu che mất.

W03-EX02 Mức độ 2 — Ánh xạ hay thiết lập?

Hai đoạn mã đều nhắc tới màu:

```
ggplot(
    penguins,
    aes(
        x="bill_length_mm",
        y="bill_depth_mm",
        color="species")
) + geom_point()
```

```
ggplot(
    penguins,
    aes(
        x="bill_length_mm",
        y="bill_depth_mm")
) + geom_point(color="steelblue")
```

Hai cách chỉ định màu đóng vai trò thống kê giống nhau hay khác nhau?

W03-EX02 — Đáp án

Khác nhau.

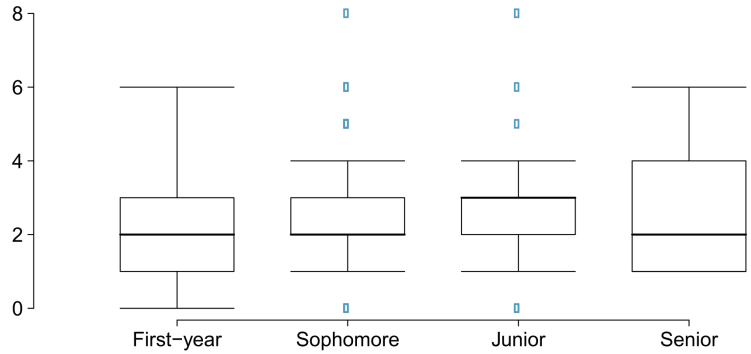
- `aes(color="species")`: màu **thay đổi theo dữ liệu** → ánh xạ.
- `geom_point(color="steelblue")`: mọi điểm có **một màu cố định** → thiết lập.

Quy tắc tư duy:

Ánh xạ *trả lời "biến nào điều khiển thuộc tính này?";* ***thiết lập*** *chỉ quyết định cách hiển thị.*

W03-CH01 Mức độ 3 — Dạng hình học có phải chỉ là phong cách?

OpenIntro dùng biểu đồ sau để so sánh **số câu lạc bộ sinh viên tham gia** giữa các **năm học**.



Một sinh viên đề nghị thay toàn bộ biểu đồ hộp bằng các điểm rồi **nối các điểm bằng đường**, vì "năm học có thứ tự". Hãy đánh giá đề nghị đó bằng Ngữ pháp đồ họa.

W03-CH01 — Đáp án

Đề nghị đó **không tương đương** với biểu đồ gốc.

- Dữ liệu có một biến nhóm (năm học) và một biến số (số câu lạc bộ).
- Biểu đồ hộp tóm tắt **phân phối trong từng nhóm**: trung vị, khoảng tứ phân vị và các giá trị bất thường.
- Nối các điểm của những sinh viên khác nhau bằng đường sẽ ngầm tạo ra một "quỹ đạo" giữa các cá thể mà dữ liệu không có.
- Việc **năm học** có thứ tự không đủ để biện minh cho đường nối giữa **các đơn vị quan sát khác nhau**.

Dạng hình học phải phù hợp với **đơn vị quan sát** và **câu hỏi**, không chỉ với kiểu dữ liệu của trục x.

Hình giữ nguyên đường dẫn từ OpenIntro Statistics 4e, Chương 2.

Nội dung chính

1. Ngữ pháp đồ họa
2. **Số ca sinh theo thời gian** — cùng dữ liệu, thay đổi cách biểu diễn
3. Python và Ngữ pháp đồ họa
4. Điều kiện hóa
5. Chuỗi xử lý và phép toán theo nhóm
6. Thử thách và tổng kết

Phần 2

Số ca sinh theo thời gian

Bối cảnh dữ liệu London thế kỷ 17

STAT20 sử dụng hồ sơ sinh/rửa tội tại London để minh họa câu hỏi:

Tổng số ca sinh thay đổi theo thời gian như thế nào?

Khung dữ liệu có **82 hàng**; mỗi hàng tương ứng với **một năm**.

Hai biến cốt lõi:

- `year`: năm quan sát;
- `total`: tổng số ca sinh được ghi lại trong năm.

Trong các đoạn mã minh họa, ta gọi khung dữ liệu này là `births`.

Nguồn: STAT20, "Ví dụ: Số ca sinh theo thời gian".

Sáu hàng đầu của `births`

year	total
1629	9901
1630	9315
1631	8524
1632	9584
1633	9997
1634	9855

Mỗi hàng là một năm; vì vậy `year` có một **thứ tự thời gian có ý nghĩa**.

Một biểu đồ đường trả lời điều gì?



Phân tích cú pháp

- dữ liệu: 82 năm;
- `year` $\to$ x;
- `total` $\to$ y;
- dạng hình học: **đường**.

Đường làm nổi bật **diễn biến tổng thể theo thời gian**.

W03-Q02 Mức độ 1 — Đổi dạng hình học, đổi thông điệp?

Giữ nguyên dữ liệu và hai ánh xạ `year` → `x`, `total` → `y`.

Nếu thay **đường** bằng **điểm**, điều gì trở nên dễ nhìn hơn và điều gì trở nên kém nổi bật hơn?

W03-Q02 — Đáp án

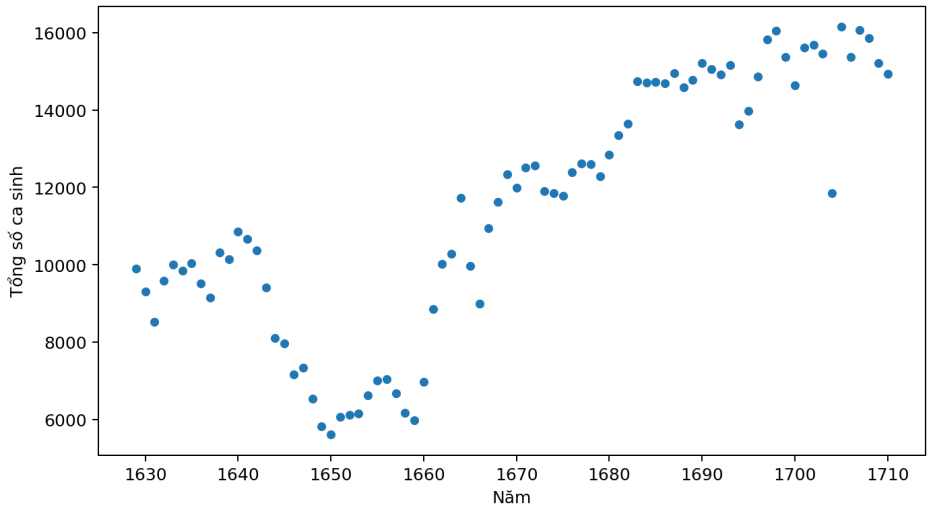
- **Điểm** làm rõ từng giá trị `total` của từng năm.
- **Đường** làm rõ hơn tính liên tục về thứ tự thời gian và xu hướng chung.

Không có dạng hình học "tốt nhất" trong chân không. Câu hỏi đúng hơn là:

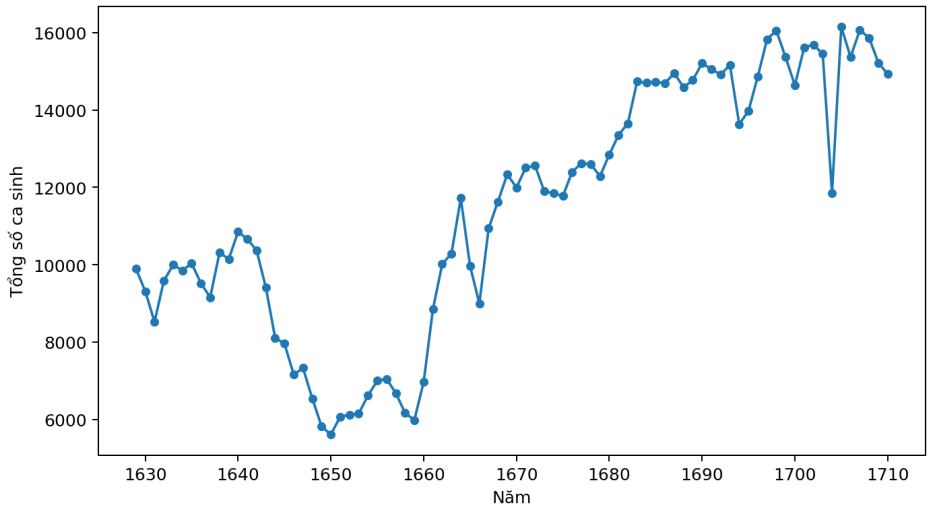
Dạng nào phục vụ thông điệp đang cần truyền đạt?

Điểm so với đường + điểm

Điểm



Đường + điểm



Kết hợp nhiều lớp có thể làm xuất hiện **nhiều loại thông tin**, nhưng cũng làm tăng tải thị giác.

W03-EX03 Mức độ 2 — "Càng nhiều lớp càng tốt"?

Phản biện khẳng định:

> *"Biểu đồ đường + điểm luôn tốt hơn biểu đồ chỉ có đường vì nó chứa nhiều thông tin hơn."*

Hãy nêu ít nhất **hai lý do**.

W03-EX03 — Đáp án

Khẳng định **sai**.

1. Thêm điểm giúp đọc từng quan sát nhưng có thể làm đường xu hướng khó nhìn hơn.
2. Một biểu đồ tốt tối ưu cho **một câu hỏi hoặc thông điệp**, không tối đa hóa số dấu hiệu trực quan.
3. Khi dữ liệu dày, nhiều lớp có thể gây chồng lấp và làm tăng tải nhận thức.

Nguyên tắc: thêm lớp khi lớp đó cung cấp thông tin cần thiết cho câu hỏi, không chỉ vì phần mềm cho phép.

Nội dung chính

1. Ngữ pháp đồ họa
2. Số ca sinh theo thời gian
3. **Python và Ngữ pháp đồ họa** — từ ý tưởng tới biểu đồ
4. Điều kiện hóa
5. Chuỗi xử lý và phép toán theo nhóm
6. Thử thách và tổng kết

Phần 3

Python và Ngữ pháp đồ họa

Python phản chiếu cấu trúc Ngữ pháp đồ họa: thư viện `plotnine`

Các đoạn mã sau dùng thư viện `plotnine`.

[QUAN TRỌNG] Học liệu: Xem hướng dẫn đầy đủ về cách trực quan hóa dữ liệu với Python/plotnine trên Canvas LMS.

```
from plotnine import (
    ggplot,
    aes,
    geom_point,
    geom_line,
    labs,
)
```

Python phản chiếu cấu trúc Ngữ pháp đồ họa

```
p = ggplot(
    penguins,
    aes(
        x="bill_length_mm",
        y="bill_depth_mm",
        color="species")
)
p + geom_point()
```

Ta đọc theo ba câu hỏi:

1. **Dữ liệu nào?** `penguins`.
2. **Ánh xạ nào?** `bill_length_mm` → `x`, `bill_depth_mm` → `y`, `species` → `color`.
3. **Dạng hình học nào?** `geom_point()` — mỗi quan sát là một điểm.

Mục tiêu là đọc **logic thống kê**, không học thuộc cú pháp.

Xây dựng từng bước — dữ liệu và ánh xạ

Bước 1 — chọn dữ liệu cần dùng

```
data = penguins[["bill_length_mm", "bill_depth_mm"]]
```

Bước 2 — ánh xạ biến vào trục

```
p = ggplot(
    data,
    aes(
        x="bill_length_mm",
        y="bill_depth_mm",
    ),
)
```

Xây dựng từng bước — thêm dạng hình học

Bước 3 — dạng hình học

```
p + geom_point()
```

Ta vẫn đọc cấu trúc theo thứ tự:
dữ liệu → ánh xạ → dạng hình học.

`plotnine` làm cấu trúc này hiện rõ trong cú pháp: dữ liệu + ánh xạ + lớp hình học.

W03-PY01 Mức độ 1 — Đọc mã, không chạy mã

```
ggplot(
    penguins,
    aes(x="bill_length_mm", y="bill_depth_mm",
        color="species")
) + geom_point()
```

Không chạy Python, hãy trả lời:

1. Ba biến nào xuất hiện trong biểu đồ?
2. Biến nào điều khiển màu?
3. Mỗi điểm đại diện cho gì?
4. Hai hàng thiếu `bill_length_mm` hoặc `bill_depth_mm` có thể được vẽ không?

W03-PY01 — Đáp án

1. `bill_length_mm`, `bill_depth_mm`, `species`.
2. `species` điều khiển màu.
3. Mỗi điểm đại diện cho một cá thể chim cánh cụt có đủ hai số đo mỏ.
4. Không. Trong 344 hàng của `penguins`, chỉ 342 hàng có đủ hai số đo này để xuất hiện trên biểu đồ.

Đọc mã có giá trị vì ta có thể kiểm tra **logic thống kê** trước cả khi chạy chương trình.

W03-PY02 Mức độ 2 — Chỉ đổi một thành phần

Hai đoạn mã có cùng dữ liệu và ánh xạ:

```
plot_A = (
    ggplot(births, aes(x="year", y="total"))
    + geom_line()
)

plot_B = (
    ggplot(births, aes(x="year", y="total"))
    + geom_point()
)
```

1. Thành phần nào của Ngữ pháp đồ họa thay đổi?
2. Vì sao không nên nói "B chứa dữ liệu khác A"?
3. Nếu mục tiêu là nhấn mạnh diễn biến liên tục theo năm, bạn chọn A hay B? Giải thích.

W03-PY02 — Đáp án

1. Chỉ **dạng hình học** thay đổi: `geom_line()` tạo đường, `geom_point()` tạo các điểm.
2. Dữ liệu và ánh xạ `year` → `x`, `total` → `y` giữ nguyên. Hai biểu đồ chỉ **mã hóa cùng quan sát theo hai cách khác nhau**.
3. Với mục tiêu nhấn mạnh diễn biến theo thời gian, A hợp lý hơn vì đường nối sử dụng thứ tự năm có ý nghĩa.

Đây là lợi ích của một ngữ pháp: ta có thể chỉ ra chính xác **quyết định nào** đã đổi.

W03-Q04 Mức độ 1 — Biến hay nhãn?

Đoạn mã dùng các biến `bill_length_mm`, `bill_depth_mm` và `species`. Khi làm biểu đồ tiếng Việt, có nên đổi tên ba biến trong dữ liệu chỉ để nhãn trục và chú giải hiển thị bằng tiếng Việt không? Vì sao?

W03-Q04 — Đáp án

Không cần. Tên biến là một phần của cấu trúc bộ dữ liệu; nhãn hiển thị là phần giao tiếp với người đọc. Ta có thể giữ nguyên tên biến và Việt hóa nhãn của biểu đồ.

```
p + labs(
    x="Chiều dài mỏ (mm)",
    y="Độ sâu mỏ (mm)",
    color="Loài",
)
```

Các lệnh trên đổi **nhãn hiển thị**, không đổi tên biến trong dữ liệu.

Nội dung chính

1. Ngữ pháp đồ họa
2. Số ca sinh theo thời gian
3. Python và Ngữ pháp đồ họa
4. **Điều kiện hóa** — lọc và tập trung vào nhóm quan tâm
5. Chuỗi xử lý và phép toán theo nhóm
6. Thử thách và tổng kết

Phần 4

Điều kiện hóa

"Điều kiện hóa" ở Tuần 03 nghĩa là gì?

Trong tuần này, **điều kiện hóa dữ liệu** nghĩa là nghiên cứu một biến hoặc một mối liên hệ **bên trong từng mức của một biến khác**:

$$\text{nghiên cứu } Y \text{ hoặc mối liên hệ } (X, Y) \quad \text{trong } Z = z.$$

Các thao tác thực tế có thể là:

- lọc một tập con;
- chia dữ liệu thành nhóm;
- so sánh cùng một thống kê giữa các nhóm;
- tách biểu đồ theo nhóm.

Không nhầm với Tuần 05: ở phần xác suất, "điều kiện" sẽ được hình thức hóa bằng xác suất có điều kiện. Tuần 03 chỉ dùng điều kiện hóa theo nghĩa **phân tích dữ liệu theo tập con / nhóm**.

Tỉ lệ biên và tỉ lệ có điều kiện

Giả sử ta quan tâm đến kết quả `success` và một biến phân nhóm `difficulty`.

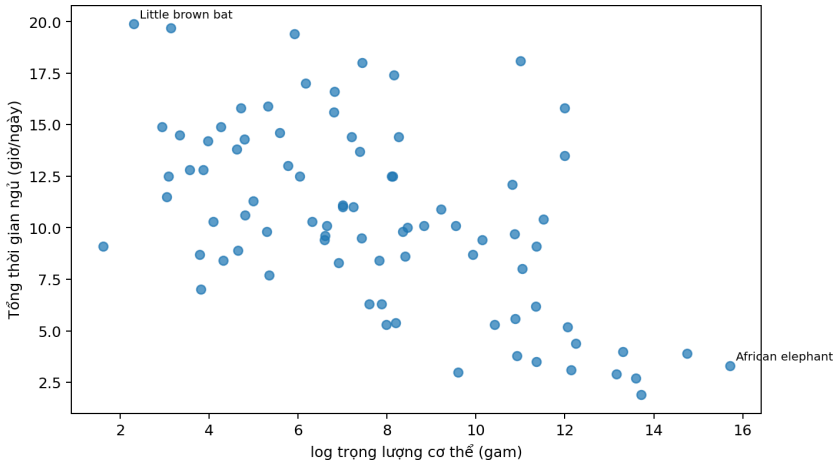
- **Tỉ lệ biên (marginal):** gộp mọi mức `difficulty` rồi tính một tỉ lệ chung.
- **Tỉ lệ có điều kiện:** tính tỉ lệ **riêng trong từng mức** `difficulty = z`.

Hai loại tỉ lệ trả lời hai câu hỏi khác nhau:

gộp mọi nhóm so với xét trong từng nhóm.

Một kết luận đúng ở mức biên **không buộc** phải đúng trong mọi nhóm.

Lọc giữ hàng, không chọn cột



Lọc là giữ các **hàng** thỏa một điều kiện trên giá trị biến.

```
large = msleep.query("log_bodywt > 12")
```

- số cột không đổi;
- số hàng giảm;
- các hàng còn lại thỏa điều kiện.

`msleep` mô tả đặc điểm ngủ của 83 loài động vật có vú; STAT20 dùng `log_bodywt` cho logarit tự nhiên của trọng lượng cơ thể.

Lọc hợp lệ và chọn lọc tùy tiện

Lọc là thao tác phân tích hợp lệ khi tiêu chí xuất phát từ **câu hỏi nghiên cứu**.

> *Vấn đề không nằm ở thao tác lọc, mà ở việc thay đổi tiêu chí sau khi xem kết quả chỉ để đạt kết luận mong muốn.*

Câu hỏi tự kiểm tra:

- điều kiện lọc có được xác định từ mục tiêu phân tích không?
- có báo cáo rõ tập con đang được phân tích không?
- kết luận có bị diễn đạt như thể áp dụng cho toàn bộ dữ liệu không?

Chuẩn bị cùng cấu trúc biến `msleep` như STAT20

Các ví dụ dùng năm biến của bảng STAT20: `name`, `sleep_total`, `log_bodywt`, `vore`, `conservation`.

Giả sử dữ liệu gốc đã được nạp thành `DataFrame` pandas tên `msleep_raw`. Ta tái tạo `log_bodywt` rồi giữ năm biến cần dùng:

```
import numpy as np

msleep = (
    msleep_raw
    .assign(log_bodywt=np.log(msleep_raw["bodywt"] * 1000))
    [["name", "sleep_total", "log_bodywt", "vore", "conservation"]]
)
```

Đây là **bước chuẩn bị dữ liệu**; trọng tâm tiếp theo là thao tác lọc.

Toán tử so sánh

Toán tử	Đọc là
==	bằng
!=	không bằng
<	nhỏ hơn
>	lớn hơn
<=	nhỏ hơn hoặc bằng
>=	lớn hơn hoặc bằng

Điều kiện lọc là một **mệnh đề cho từng hàng**.

Ví dụ:

```
msleep.query("log_bodywt > 12 and sleep_total < 5")
```

Một hàng được giữ nếu **cả hai** điều kiện đều đúng.

W03-PY03 Mức độ 1 — Đọc một phép lọc

```
large = msleep.query("log_bodywt > 12")
```

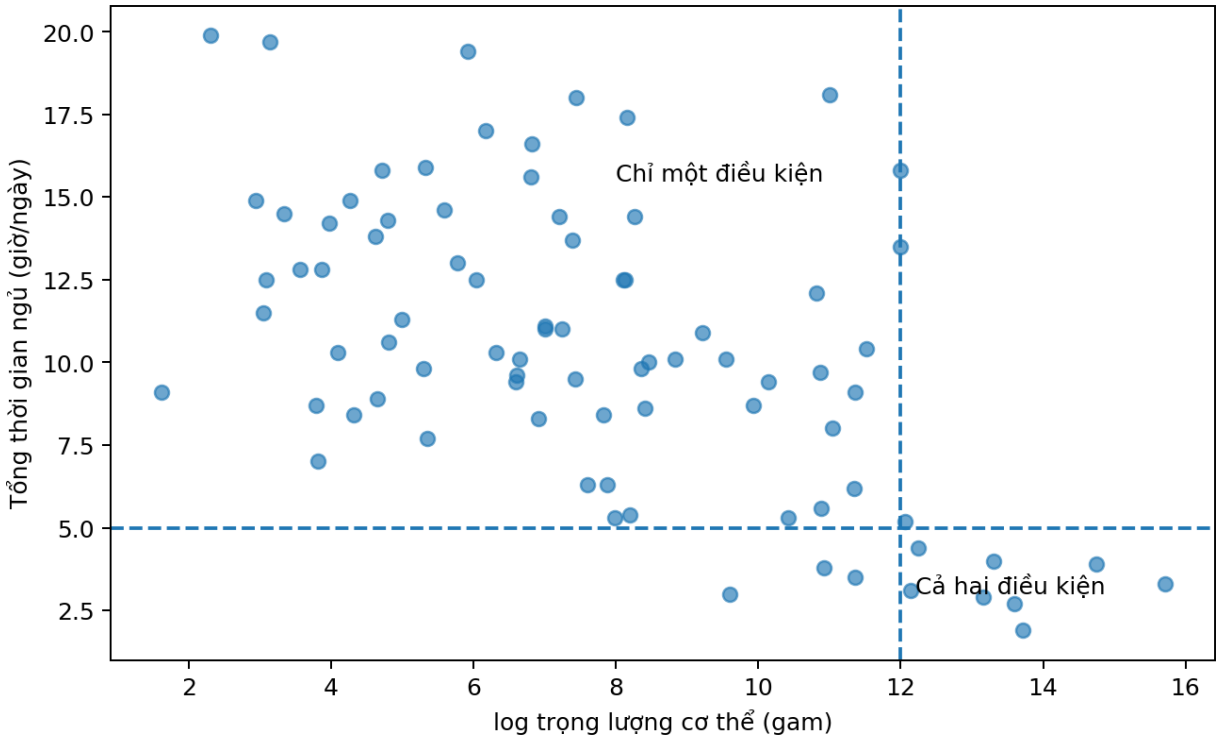
1. Kết quả có bao nhiêu hàng?
2. Số cột có thay đổi không?
3. Dòng lệnh trên chọn "biến lớn" hay chọn "động vật lớn"?
4. `log_bodywt > 12` là điều kiện trên biến nào?

W03-PY03 — Đáp án

1. Có **9 hàng**.
2. Không: vẫn giữ các cột của khung dữ liệu đang dùng.
3. Nó chọn **các quan sát/động vật** thỏa điều kiện, không chọn một biến.
4. Điều kiện áp dụng lên `log_bodywt`.

Các quan sát gồm African elephant, Asian elephant, Giraffe, Pilot whale, Cow, Horse, Brazilian tapir, Donkey và Bottle-nosed dolphin.

Nhiều điều kiện: "và" so với "hoặc"



- **"và"** lấy phần giao của các điều kiện → tập con thường nhỏ hơn.
- **"hoặc"** lấy phần hợp → tập con thường lớn hơn.

Trong `DataFrame.query()` có thể viết `and` / `or` cho các điều kiện kiểu này.

W03-EX04 Mức độ 2 — Giao hay hợp?

Xét hai phép lọc với `msleep`:

A. `msleep.query("log_bodywt > 12 and sleep_total < 5")`

B. `msleep.query("log_bodywt > 12 or sleep_total < 5")`

Không cần liệt kê mọi hàng. Hãy dự đoán:

1. Tập A hay B lớn hơn?
2. Vì sao A có thể được xem là điều kiện "chặt hơn"?
3. Nếu một động vật nhỏ nhưng ngủ dưới 5 giờ, nó thuộc A, B hay không thuộc cả hai?

W03-EX04 — Đáp án

1. B không thể nhỏ hơn A vì B là **hợp**, còn A là **giao**.
2. A yêu cầu **đồng thời** hai mệnh đề đúng.
3. Động vật nhỏ nhưng ngủ dưới 5 giờ thuộc **B** nhưng không thuộc A.

Trong dữ liệu nguồn, điều kiện A giữ **8** trong 9 động vật có `log_bodywt > 12`; Bottle-nosed dolphin bị loại vì `sleep_total = 5.2`.

Nội dung chính

1. Ngữ pháp đồ họa
2. Số ca sinh theo thời gian
3. Python và Ngữ pháp đồ họa
4. Điều kiện hóa
5. **Chuỗi xử lý và phép toán theo nhóm** — nhiều bước, một câu hỏi
6. Thử thách và tổng kết

Phần 5

Chuỗi xử lý và phép toán theo nhóm

Chuỗi xử lý dữ liệu là một lập luận

Một phân tích thực tế thường cần nhiều bước:

$$\text{dữ liệu ban đầu} \to \text{lọc} \to \text{sắp xếp} \to \text{nhóm} \to \text{tóm tắt} \to \text{diễn giải.}$$

Điểm quan trọng không phải "viết ít dòng mã", mà là:

Mỗi bước làm thay đổi dữ liệu như thế nào, và tại sao bước đó cần cho câu hỏi?

Chuỗi lời gọi phương thức trong pandas

```
(
    msleep
    .query("log_bodywt > 12")
    .sort_values("log_bodywt", ascending=False)
)
```

Ta có thể đọc gần như một câu:

> *Lấy `msleep` → giữ các động vật có `log_bodywt > 12` → sắp xếp giảm dần theo `log_bodywt`.*

Khi chuỗi trở nên dài và khó đọc, **tách bước và đặt tên trung gian** tốt hơn cố nối tất cả vào một biểu thức.

W03-PY04 Mức độ 1 — Viết mã thành tiếng Việt

```
(
    msleep
    .query("log_bodywt > 12")
    .sort_values("log_bodywt", ascending=False)
)
```

1. Bước nào làm giảm số hàng?
2. Bước nào chỉ thay đổi thứ tự hàng?
3. Nếu đảo hai bước, tập quan sát cuối có thay đổi không? Thứ tự cuối có thay đổi không?

W03-PY04 — Đáp án

1. `.query(...)` làm giảm số hàng.
2. `.sort_values(...)` chỉ thay đổi thứ tự hàng.
3. Với hai thao tác này, đảo thứ tự vẫn giữ cùng **tập 9 quan sát** và nếu cuối cùng vẫn sắp xếp giảm dần thì thứ tự đầu ra cũng giống nhau.

Nhưng không phải mọi cặp thao tác đều đổi chỗ được. Khi có **tóm tắt theo nhóm**, thứ tự có thể thay đổi câu hỏi thống kê.

W03-EX05 Mức độ 3 — Thứ tự thay đổi câu hỏi

Xét hai chuỗi:

A

```
A = (
    msleep
    .query("sleep_total > 8")
    .groupby("vore", dropna=False).size()
    .reset_index(name="n_gt_8")
    .query("n_gt_8 > 18")
)
```

B

```
B = (
    msleep
    .groupby("vore", dropna=False).size()
    .reset_index(name="n")
    .query("n > 18")
)
```

Hai chuỗi trả lời hai câu hỏi nào?

W03-EX05 — Đáp án

A: Chế độ ăn nào có **hơn 18 loài ngủ trên 8 giờ**?

- `herbi`: 19
- `omni`: 19

B: Chế độ ăn nào có **hơn 18 loài trong toàn bộ dữ liệu**?

- `carni`: 19
- `herbi`: 32
- `omni`: 20

Lọc **trước** khi đếm nhóm và lọc **sau** khi đếm nhóm không phải cùng một thao tác.

W03-Q03 Mức độ 1 — Lọc hay nhóm?

Chọn thao tác phù hợp cho từng câu hỏi:

1. "Thời gian ngủ trung bình của **động vật ăn thịt** là bao nhiêu?"
2. "Thời gian ngủ trung bình của **từng chế độ ăn** là bao nhiêu?"

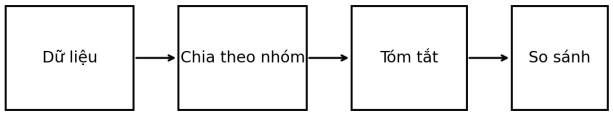
Nên **lọc** hay **nhóm**?

W03-Q03 — Đáp án

1. Một nhóm cụ thể → **lọc** `vore == "carni"`, rồi tóm tắt.
2. Cùng một phép tóm tắt cho mọi mức `vore` → **nhóm** theo `vore`, rồi tóm tắt.

Lọc làm giảm dữ liệu xuống một tập con. Nhóm giữ các quan sát nhưng thay đổi cách phép toán tiếp theo được áp dụng.

Nhóm rồi tóm tắt



Tư duy: chia theo nhóm → cùng một phép tính trong từng nhóm → so sánh kết quả.

Python:

```
summary = msleep
    .groupby("vore", dropna=False)
    .agg(
        mean_sleep=("sleep_total", "mean"),
        n=("sleep_total", "size")
    )
```

`dropna=False` giữ nhóm có `vore` bị thiếu, phù hợp với cách STAT20 trình bày ví dụ này.

W03-PY05 Mức độ 2 — Một hàng của kết quả nghĩa là gì?

```
(
    msleep
    .assign(gt_8=msleep["sleep_total"] > 8)
    .groupby("vore", dropna=False)
    .agg(
        p_gt_8hrs=("gt_8", "mean"),
        n=("sleep_total", "size")
    )
)
```

1. Một hàng của bảng kết quả đại diện cho gì?
2. Vì sao trung bình của biến logic gt_8 là một tỉ lệ?
3. n dùng làm gì khi diễn giải tỉ lệ?

W03-PY05 — Đáp án

Mỗi hàng là **một mức của `vore`**. Kết quả nguồn:

vore	p_gt_8hrs	n
carni	0.684	19
herbi	0.594	32
insecti	1.000	5
omni	0.950	20
thiếu	0.714	7

Biến logic nhận `True/False`, tương ứng 1/0 khi lấy trung bình; vì vậy trung bình là **tỉ lệ quan sát thỏa điều kiện**.

`n` giúp ta không đánh đồng một tỉ lệ 100% từ 5 quan sát với một tỉ lệ gần tương tự từ hàng chục quan sát.

W03-EX06 Mức độ 2 — Tóm tắt theo nhóm có khớp biểu đồ?

Với `penguins`, tính trung bình hai số đo mỏ theo `species`:

```
(
    penguins
    .groupby("species", observed=True)
    .agg(
        mean_length=("bill_length_mm", "mean"),
        mean_depth=("bill_depth_mm", "mean")
    )
)
```

Trước khi xem kết quả, hãy dự đoán nhóm nào có `mean_depth` nhỏ nhất dựa trên biểu đồ chim cánh cụt.

W03-EX06 — Đáp án

species	mean_length	mean_depth
Adelie	38.79	18.35
Chinstrap	48.83	18.42
Gentoo	47.50	**14.98**

Gentoo có độ sâu mỏ trung bình nhỏ nhất, phù hợp với cụm điểm Gentoo nằm thấp hơn rõ rệt trên trục y.

Đây là một kiểm tra chéo hữu ích:

biểu đồ → dự đoán → tóm tắt số → diễn giải.

W03-EX07 Mức độ 3 — Từ tỉ lệ có điều kiện tới nghịch lý Simpson

Tình huống giả định. Hai thuật toán A và B được đánh giá trên hai loại tác vụ: **dễ** và **khó**. "Thành công" nghĩa là hoàn thành tác vụ trong ngưỡng thời gian yêu cầu.

Độ khó	A: thành công / tổng	B: thành công / tổng
Dễ	81 / 90	19 / 20
Khó	1 / 10	16 / 80

1. Tính tỉ lệ thành công của A và B **trong từng mức độ khó**.
2. Tính tỉ lệ thành công **gộp** của A và B.
3. Thuật toán nào có tỉ lệ cao hơn trong từng nhóm? Thuật toán nào cao hơn khi gộp?
4. Điều gì tạo ra sự đảo chiều?

W03-EX07 — Đáp án

Trong từng nhóm:

Độ khó	A	B	Cao hơn
Dễ	$81/90 = 90\%$	$19/20 = 95\%$	B
Khó	$1/10 = 10\%$	$16/80 = 20\%$	B

Nhưng khi gộp:

$$A: \ \frac{82}{100} = 82\%, \qquad B: \ \frac{35}{100} = 35\%.$$

Vì vậy **B cao hơn trong cả hai nhóm**, nhưng **A cao hơn khi gộp**.

Đây là một dạng **nghịch lý Simpson**: dấu / thứ tự của mối liên hệ có thể đổi khi chuyển giữa tóm tắt biên và tóm tắt có điều kiện.

Vì sao lại đảo chiều? — cơ chế trọng số

Tỉ lệ gộp là **trung bình có trọng số** của các tỉ lệ trong nhóm.

Với A:

$$0.90(0.90) + 0.10(0.10) = 0.82.$$

Với B:

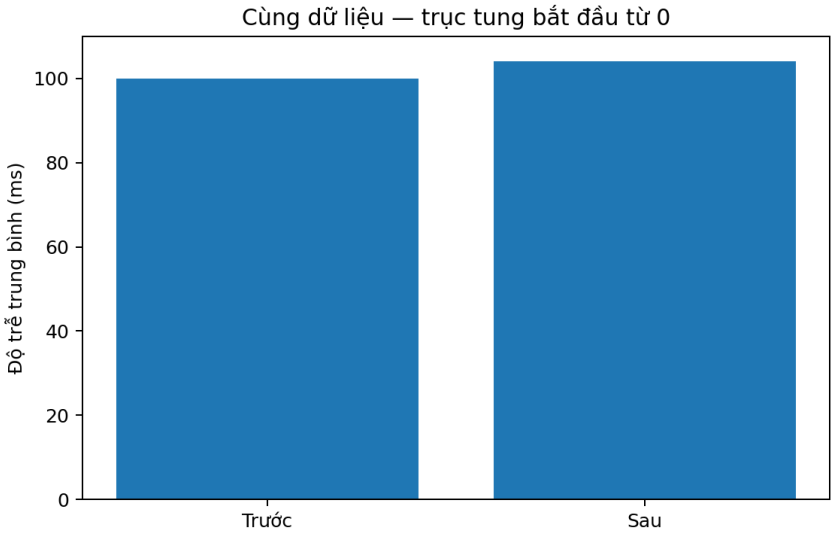
$$0.20(0.95) + 0.80(0.20) = 0.35.$$

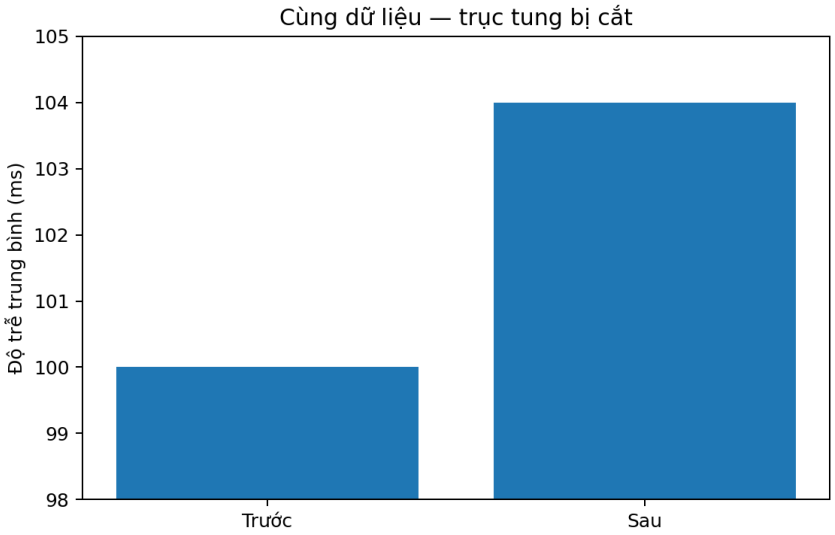
- A xử lý **90% tác vụ dễ**.
- B xử lý **80% tác vụ khó**.
  *Sự khác nhau về **cơ cấu nhóm** có thể lấn át so sánh trong từng nhóm.*

Không có thông tin về cơ chế phân công tác vụ, ví dụ này **không cho phép kết luận nhân quả** rằng một thuật toán "tốt hơn" thuật toán kia.

W03-EX08 Mức độ 2 — Cùng dữ liệu, hai đồ họa khuyến khích hai ấn tượng

Tình huống giả định. Độ trễ trung bình của một hệ thống tăng từ 100 ms lên 104 ms.





1. Hai hình dùng cùng số liệu hay khác số liệu?
2. Vì sao hình bên phải có thể làm mức tăng trông lớn hơn nhiều?
3. Hãy đề xuất một cách trình bày trung thực hơn cho câu hỏi "độ trễ tăng bao nhiêu?".

W03-EX08 — Đáp án

1. **Cùng dữ liệu:** 100 ms và 104 ms.
2. Biểu đồ cột mã hóa giá trị bằng **chiều dài cột**. Cắt trục tung ở 98 ms làm chênh lệch 4 ms chiếm phần lớn chiều cao hiển thị, nên thị giác dễ phóng đại thay đổi.
3. Có thể:
   - dùng trục tung bắt đầu từ 0 nếu vẫn dùng chiều dài cột;
   - hoặc dùng một biểu đồ điểm / đường với nhãn trực tiếp mức thay đổi **+4 ms = +4%**.

Thiết kế đồ họa phải trung thành với câu hỏi; "đúng số" chưa đủ để bảo đảm "đúng ấn tượng".

Nội dung chính

1. Ngữ pháp đồ họa
2. Số ca sinh theo thời gian
3. Python và Ngữ pháp đồ họa
4. Điều kiện hóa
5. Chuỗi xử lý và phép toán theo nhóm
6. **Thử thách và tổng kết** — điều gì bị tóm tắt gộp che mất?

Phần 6

Thử thách và tổng kết

W03-CH02 Mức độ 3 — Một con số đúng nhưng kết luận yếu

Trong `penguins`, xét biến `body_mass_g`.

Trong 342 cá thể có khối lượng cơ thể được ghi lại, **172 cá thể** có khối lượng trên 4000 g:

$$\frac{172}{342} \approx 50.3\%.$$

Tình huống giả định: một báo cáo viết:

> *"Khoảng một nửa chim cánh cụt vượt 4000 g; vì vậy loài không giúp ta hiểu nhiều về khả năng một cá thể vượt ngưỡng này."*

Kết luận này có được hỗ trợ bởi tỉ lệ gộp 50.3% không? Bạn sẽ điều kiện hóa theo biến nào để kiểm tra?

W03-CH02 — Đáp án

Tỉ lệ gộp **không đủ** để kết luận loài ít liên quan. Hãy điều kiện hóa theo `species`:

species	trên 4000 g	số có dữ liệu	tỉ lệ
Adelie	35	151	23.2%
Chinstrap	15	68	22.1%
Gentoo	122	123	**99.2%**

Tóm tắt gộp 50.3% che mất một cấu trúc rất mạnh giữa các nhóm.

Điều kiện hóa không "sửa số liệu"; nó thay đổi câu hỏi từ toàn bộ dữ liệu sang phân phối/tóm tắt trong từng nhóm.

W03-CH03 Mức độ 3 — Tự dựng một nghịch lý Simpson

Hãy tự xây dựng một bảng $2 \times 2 \times 2$ với:

- hai phương án A và B;
- hai nhóm $Z = 1, 2$;
- kết quả thành công / không thành công;

sao cho:

1. B có tỉ lệ thành công **cao hơn A trong cả hai nhóm**;
2. nhưng A có tỉ lệ thành công **cao hơn B khi gộp hai nhóm**.

Không có số liệu cho sẵn. Hãy giải thích cơ chế trọng số tạo ra sự đảo chiều.

W03-CH03 — Đáp án (1/2): cách dựng

Một chiến lược:

1. Chọn một nhóm có tỉ lệ thành công cao và một nhóm có tỉ lệ thấp.
2. Trong **mỗi nhóm**, đặt B nhỉnh hơn A.
3. Cho A nhận phần lớn quan sát từ nhóm "dễ", còn B nhận phần lớn quan sát từ nhóm "khó".

Một nghiệm:

Nhóm	A	B
Dễ	$36/40 = 90\%$	$19/20 = 95\%$
Khó	$1/10 = 10\%$	$12/50 = 24\%$

W03-CH03 — Đáp án (2/2): kiểm tra đảo chiều

Trong từng nhóm:

- Dễ: $95\% > 90\%$;
- Khó: $24\% > 10\%$.

Nhưng khi gộp:

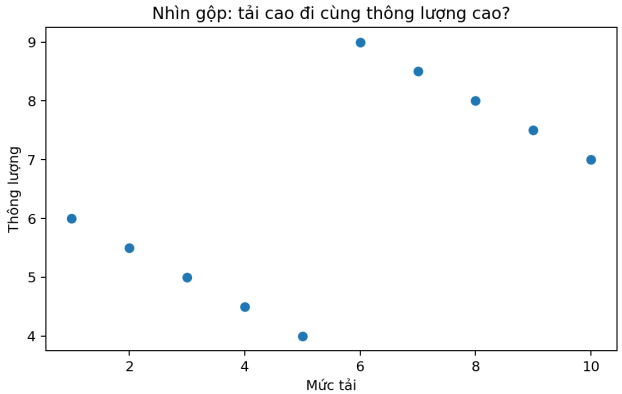
$$A = \frac{37}{50} = 74\%, \qquad B = \frac{31}{70} \approx 44.3\%.$$

Vậy B cao hơn **trong từng nhóm**, còn A cao hơn **ở mức biên**.

Cơ chế: A nhận trọng số lớn ở nhóm dễ; B nhận trọng số lớn ở nhóm khó.

W03-CH04 Mức độ 3 — Nhóm ẩn có thể đảo cách ta đọc biểu đồ

Tình huống giả định. Mỗi điểm là một lần đo máy chủ; x là mức tải, y là thông lượng.

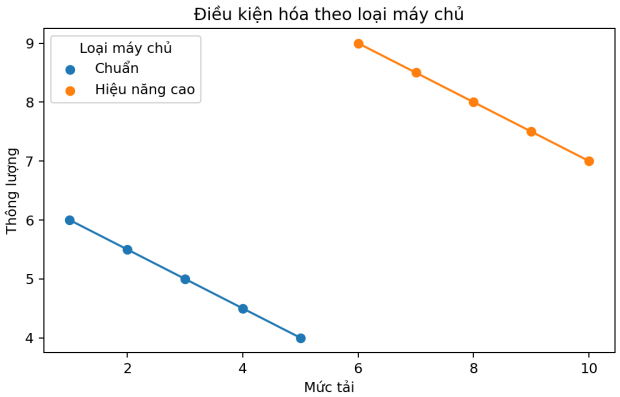


Nhìn gộp, tải cao dường như đi cùng thông lượng cao.

1. Hãy đề xuất một biến thứ ba hợp lý có thể giải thích mẫu hình này.
2. Có thể xảy ra chuyện **trong từng nhóm**, tải tăng lại đi cùng thông lượng giảm không?
3. Ta cần đổi gì trong biểu đồ để kiểm tra giả thuyết đó?

W03-CH04 — Đáp án: điều kiện hóa làm lộ cấu trúc

Biến thứ ba hợp lý: **loại máy chủ**.



- Máy hiệu năng cao thường vừa chịu tải cao hơn vừa có thông lượng cao hơn.
- **Trong từng loại máy**, thông lượng lại giảm khi tải tăng.
- Biểu đồ gộp trộn **khác biệt giữa loại máy** với **thay đổi theo tải trong cùng loại máy**.

Câu hỏi cần hỏi: *mối liên hệ đang được nhìn ở mức biên hay trong từng nhóm?*

W03-CH05 Mức độ 3 — Bác bỏ hai suy luận quá mạnh

Hãy đánh giá hai khẳng định:

(A) "Nếu một mối liên hệ xuất hiện trong toàn bộ dữ liệu, nó phải xuất hiện cùng chiều trong mọi nhóm."

(B) "Nếu điều kiện hóa theo một biến làm mối liên hệ rõ hơn, ta đã chứng minh được quan hệ nhân quả."

Với mỗi khẳng định: **đúng hay sai?** Nếu sai, nêu phản ví dụ hoặc lý do.

W03-CH05 — Đáp án

(A) Sai. Ví dụ Simpson ở W03-EX07 là một phản ví dụ trực tiếp: B có tỉ lệ thành công cao hơn trong cả hai nhóm nhưng thấp hơn khi gộp.

(B) Sai. Điều kiện hóa có thể giảm một nguồn **trộn lẫn** do biến đã quan sát, nhưng:

- vẫn có thể còn biến ẩn;
- cách hình thành các nhóm có thể mang tính chọn lọc;
- dữ liệu quan sát không tự tạo ra cơ chế so sánh phản thực.
  Điều kiện hóa giúp mô tả cấu trúc tốt hơn; nó không tự động biến một liên hệ thành tác động nhân quả.

W03-CASE01 Mức độ 3 — Từ câu hỏi tới biểu đồ và tóm tắt

Tình huống giả định dựa trên dữ liệu `penguins`: một nhóm phân tích muốn tập trung vào các cá thể:

- không thuộc `Adelie`;
- có `bill_length_mm` từ 40 đến 50 mm, kể cả hai đầu mút.

Sau khi lọc, họ muốn:

1. so sánh `bill_length_mm` và `bill_depth_mm` giữa các loài còn lại;
2. vẽ biểu đồ hai số đo mỏ, tô màu theo `species`;
3. giải thích vì sao chỉ nhìn trung bình chiều dài mỏ có thể bỏ lỡ một khác biệt quan trọng.

Hãy thiết kế chuỗi phân tích. Không cần nhớ cú pháp hoàn hảo; ưu tiên đúng logic.

W03-CASE01 — Đáp án (1/4): lọc

```
subset = penguins.query(
    "species != 'Adelie' and 40 <= bill_length_mm <= 50"
)
```

Chuỗi lọc giữ các cá thể:

- không thuộc `Adelie`;
- có `bill_length_mm` nằm trong đoạn từ 40 đến 50 mm.

Đây là bước **điều kiện hóa**: câu hỏi tiếp theo chỉ xét tập con vừa tạo.

W03-CASE01 — Đáp án (2/4): tóm tắt theo nhóm

```
(
    subset
    .groupby("species", observed=True)
    .agg(
        n=("bill_length_mm", "size"),
        mean_length=("bill_length_mm", "mean"),
        mean_depth=("bill_depth_mm", "mean")
    )
)
```

Mỗi hàng đầu ra tương ứng với một loài còn lại trong `subset`.

W03-CASE01 — Đáp án (3/4): đọc bảng tóm tắt

species	n	mean_length	mean_depth
Chinstrap	38	46.52	17.82
Gentoo	101	46.52	14.78

Hai nhóm có **cùng trung bình chiều dài mỏ đến hai chữ số thập phân**, nhưng khác rõ về độ sâu mỏ.

Điều này gợi ý rằng chỉ tóm tắt `bill_length_mm` là chưa đủ để mô tả sự khác biệt giữa hai nhóm.

W03-CASE01 — Đáp án (4/4): quay lại biểu đồ

```
(
    ggplot(
        subset,
        aes(
            x="bill_length_mm",
            y="bill_depth_mm",
            color="species",
        ),
    )
    + geom_point()
    + labs(
        x="Chiều dài mỏ (mm)",
        y="Độ sâu mỏ (mm)",
        color="Loài",
    )
)
```

Biểu đồ hai chiều giúp thấy cấu trúc mà một tóm tắt đơn biến có thể che mất.

> *Tóm tắt số và biểu đồ nên **kiểm tra chéo** lẫn nhau, thay vì thay thế lẫn nhau.*

Những điều cần nhớ

- Một biểu đồ có thể phân tích thành **dữ liệu + ánh xạ thuộc tính hình ảnh + dạng hình học**.
- Ánh xạ cho biết biến nào điều khiển đặc trưng trực quan; thiết lập chỉ định một giá trị hiển thị cố định.
- Dạng hình học không chỉ là phong cách: nó quyết định điều gì được nhấn mạnh và phải phù hợp với đơn vị quan sát.
- **Lọc** giữ các hàng thỏa điều kiện; **nhóm** thay đổi cách phép tóm tắt tiếp theo được áp dụng.
- Một chuỗi xử lý tốt phải đọc được như một lập luận từ câu hỏi tới kết quả.
- Thứ tự thao tác có thể thay đổi **câu hỏi thống kê** mà đoạn mã trả lời.
- Tóm tắt **biên** và tóm tắt **có điều kiện** có thể dẫn tới kết luận rất khác; nghịch lý Simpson là trường hợp đảo chiều cực đoan.
- Điều kiện hóa giúp làm lộ cấu trúc bị trộn lẫn, nhưng **không tự động chứng minh nhân quả**.

Tự kiểm tra

Bạn đã có thể giải thích bằng lời một phân tích dạng sau chưa?

$$\text{câu hỏi} \to \text{dữ liệu} \to \text{lọc/nhóm} \to \text{tóm tắt}$$
$$\to \text{ánh xạ} \to \text{dạng hình học} \to \text{diễn giải.}$$

Tự hỏi với một đoạn mã bất kỳ:

> ***Mỗi dòng đang thay đổi dữ liệu, biểu đồ hay câu hỏi theo cách nào?***

Chuẩn bị cho Tuần 04

Tuần tới, ta chuyển từ:

"Biểu diễn và chia dữ liệu như thế nào?"

sang:

"Hai hay nhiều biến số liên hệ với nhau như thế nào?"

Các khái niệm chính sẽ gồm:

- biểu đồ phân tán như công cụ mô tả quan hệ số;
- hệ số tương quan;
- hồi quy tuyến tính đơn giản;
- hồi quy tuyến tính đa biến và diễn giải hệ số.